Université de Montréal
Science des données

IFT-6758 – Examen Intra

2021/10/28

Nom Complet (Prénom NOM)

Numéro de matricule (UdeM)

Instructions

- Aucune ressource externe n'est autorisée.
- La **version française** de l'examen est **au verso (à gauche)** et les versions anglaises correspondantes sont au recto (à droite) du livret.
- Écrivez votre nom complet et votre numéro de matricule étudiant clairement et lisiblement sur les deux côtés de cette feuille (recto et verso).
- Veuillez donner de brèves explications pour vos réponses et être précis pour ne traiter que ce qui est exactement demandé dans les questions. Vous recevrez également un crédit partiel des points pour un bon raisonnement.
- Pour les questions de type vrai/faux ou pour choisir parmi une liste d'options, encerclez **uniquement** l'option que vous choisissez. Sans justifications, vous ne recevrez aucun point pour celles-ci.
- Il y a une page supplémentaire à la fin. Si vous l'utilisez, assurez-vous d'écrire clairement la question et le numéro de partie pour qu'il soit pris en compte pour l'évaluation.
- $(x_i, y_i)_{1 \leq i \leq n} = (x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ and $(x_i)_{1 \leq i \leq n} = x_1, x_2, \dots, x_n$

  $\|x_i - x_j\|_2 =$ La distance euclidienne entre les points x_i et x_j

  $A \setminus B =$ La différence d'ensemble = Les éléments dans A mais pas dans B

Distribution des points

Question	Points	Score
1	5	
2	3	
3	3	
4	6	
5	5	
6	5	
7	10	
8	5	
9	8	
10	10	
Total:	60	

1. **Contrôle de version :** Supposons qu'il y a deux travailleurs (Alice et Bob) qui travaillent dans une entreprise (Entreprise X). Ils veulent collaborer sur un projet particulier. Depuis le dépôt distant, ils ont chacun cloné sur leur ordinateur le plus récent état du dépôt décrit sur la Figure 1.

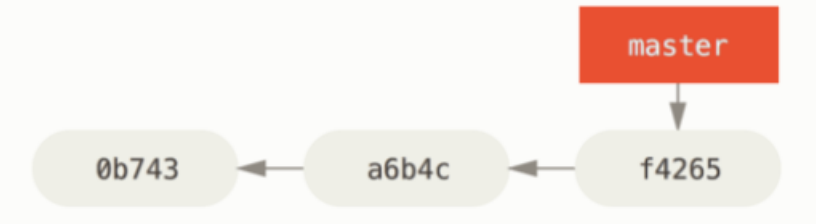


Figure 1: État initial du dépôt distant sur le serveur de l'entreprise X.

Aujourd'hui est une date limite. Alice et Bob veulent coder **en parallèle** deux fonctionnalités différentes pour leur projet qui doivent être **sur le même fichier** `feature.py`.

(a) (3 points) En termes de comamndes `add`, `commit`, `push` et `pull` de `git`, **décrivez** comment ils peuvent travailler sur le même fichier en parallèle puis synchroniser leur travail sur le dépôt distant (*remote repo*) de l'entreprise. Plus précisément, **expliquez** à quelle étape il y aura un problème (potentiel) de fusion. *(vous n'avez pas besoin d'exactement écrire les commandes utilisés, vous pouvez seulement décrire les étapes (en expliquant) nécessaires)*

(b) (2 points) **Dessinez** l'état final du dépôt distant (comme la fig. 1) à la fin du processus que vous avez décrit en (a).

2. ***Tidy Data* :** Pour chacun des trois tableaux de données suivants illustrés sur la Figure 2, **indiquez si les données sont propres** *(tidy data)*. Sinon, **proposez une version *tidy*** des mêmes données.

ville	année	M-U20	F-U20	M-O20	F-O20
Springfield	2000	10	12	15	16
Springfield	2001	12	15	16	18
Gotham	2000	14	15	19	20
Gotham	2001	16	17	21	22

(a) Population de différentes villes correspondant à différents groupes d'âge (moins [U] ou plus [O] de 20 ans) et sexe à la naissance (Homme [M] ou Femme [F]).

	A	B
John Doe	1	20
Jane Doe	2	18
William Tremblay	20	10

(b) Efficacité (notée de 1 à 20) de deux traitements (A et B)

ville	date	type	valeur
Montréal	2004	min	-30
Montréal	2004	max	30
Québec	2003	min	-40
Québec	2003	max	28

(c) Température minimale et maximale enregistrée au cours d'une année donnée dans différentes villes

Figure 2: Tables de données différentes.

(a) (1 point) Table (a)

(b) (1 point) Table (b)

(c) (1 point) Table (c)

3. Les scientifiques ont accès à un ensemble de données comprenant des détails et des mesures sur les fossiles de dinosaures et leur âge correspondant en années. Ils veulent utiliser complètement cet ensemble de données pour estimer l'âge y d'un mystérieux fossile de dinosaure x avec un âge a priori inconnu.

   (a) (1 point) **Encerclez** le type correct de tâche d'apprentissage automatique qu'ils ont l'intention d'effectuer.
   `Classification` `Régression` `Clustering` `Réduction de dimensionnalité`

   (b) (2 points) **Justifiez** votre réponse.

4. Les scientifiques de données travaillant sur les données souhaitent repenser leur encodage de chacune des variables catégorielles. Ils hésitent entre choisir l'`encodage étiqueté` (*labeled encoding*) et l'`encodage one-hot`.

   Pour chacun des cas suivants, **encerclez exactement un** type d'encodage qu'ils doivent préférablement utiliser et **expliquez pourquoi**.

   (a) (2 points) La première variable catégorique est la couleur du fossile. Il existe 5 nuances de gris différentes pour les fossiles du gris clair au gris foncé.

   `encodage étiqueté` `encodage one-hot` `aucun d'eux`

   (b) (2 points) La deuxième variable catégorique correspond au pays où le fossile a été trouvé (il y a 10 pays dans l'ensemble de données).

   `encodage étiqueté` `encodage one-hot` `aucun d'eux`

   (c) (2 points) La troisième variable catégorique est la composition chimique de la pierre. Il existe plus de 10^{23} de combinaisons chimiques possibles.

   `encodage étiqueté` `encodage one-hot` `aucun d'eux`

5. **Détection des valeurs aberrantes :** Dans cette section, nous présentons un contexte et un algorithme, et posons éventuellement des questions sur l'utilisation de l'algorithme dans le contexte donné pour la détection des valeurs aberrantes (*outliers*).

   Supposons que nous ayons accès à l'ensemble de données $(x_i, y_i)_{1 \leq i \leq n}$ où $x_i \in \mathbb{R}^d$ correspondent aux caractéristiques des fossiles de dinosaures et $y_i \in \mathbb{R}$ est leur âge en années. Soit $x \in \mathbb{R}^d$ les fossiles d'intérêt. Soit k un entier positif qui est un hyper-paramètre de l'algorithme. Pour prédire l'âge y de x, les scientifiques veulent utiliser l'algorithme k-**PPV**/k-*NN* (k-*Plus Proches Voisins*) suivant :

   - Trouver k différents points de données $x_{i_1}, \ldots, x_{i_k}$ (notez que $1 \leq i_1, \ldots, i_k \leq n$) tels que $\|x_{i_1} - x\|_2 \leq \ldots \|x_{i_k} - x\|_2 \leq \|x_i - x\|_2 \,, \forall i \in \{1, \ldots, n\} \setminus \{i_1, \ldots, i_k\}$.
     En clair, $x_{i_1}, \ldots, x_{i_k}$ sont les k-*voisins les plus proches* (dans l'ensemble de données) de x.
   - Prédire $y(x) = \frac{1}{k} \sum_{i=1}^{k} y_{i_k}$.
     En clair, la prédiction est l'âge moyen des k-voisins les plus proches.

   Les scientifiques des données ont remarqué qu'il y avait **deux** types de valeurs aberrantes dans les données. Le premier type de valeurs aberrantes (**type 1**) sont les points de données (x_k, y_k) qui ont une entrée x_k qui est très éloignée de la plupart des points de données d'entrée $(x_i)_{1 \leq i \leq n}$. Le deuxième type de valeurs aberrantes (**type 2**) sont les points de données (x_k, y_k) qui ont une valeur y_k significativement différente des points de données avec une entrée proche de x_k.

   (a) (3 points) Comment pourriez-vous utiliser les k-*voisins les plus proches* pour détecter chaque type (**type 1** et **type 2**) de valeurs aberrantes dans votre ensemble d'apprentissage?

   (b) (2 points) Discutez de l'importance de la valeur de k dans chacune de ces détections (**type 1** et **type 2**).

6. Indiquez si vous êtes d'accord ou en désaccord avec chacune des affirmations suivantes (en **encerclant**) et **expliquez pourquoi** :

   (a) (1 point) La ACP (*PCA*) a d'autres utilisations au-delà de la réduction des dimensions des données.

   D'ACCORD DÉSACCORD

   (b) (2 points) Plus il y a de caractéristiques dans les données, plus la variance capturée par la première composante principale est faible.

   D'ACCORD DÉSACCORD

   (c) (2 points) Chaque composante principale obtenue en ACP dépend également de toutes les caractéristiques.

   D'ACCORD DÉSACCORD

7. **Clustering :** Votre équipe de science des données souhaite utiliser le clustering sur les données sur les fossiles de dinosaures pour les comprendre. Vous sélectionnez les échantillons de données de différentes espèces (1 chacun) addressés comme $\mathbf{A}, \mathbf{B}, ..., \mathbf{T}$ et appliquez un clustering (groupement) hiérarchique avec un lien approprié (mesure de distance). Vous les visualisez dans le dendrogramme obtenu à partir du clustering comme le montre la Fig. 3. Certain.e.s biologistes travaillant en étroite collaboration avec votre équipe examinent et suggèrent que le clustering obtenu est scientifiquement précis et représente clairement les familles de ces espèces.

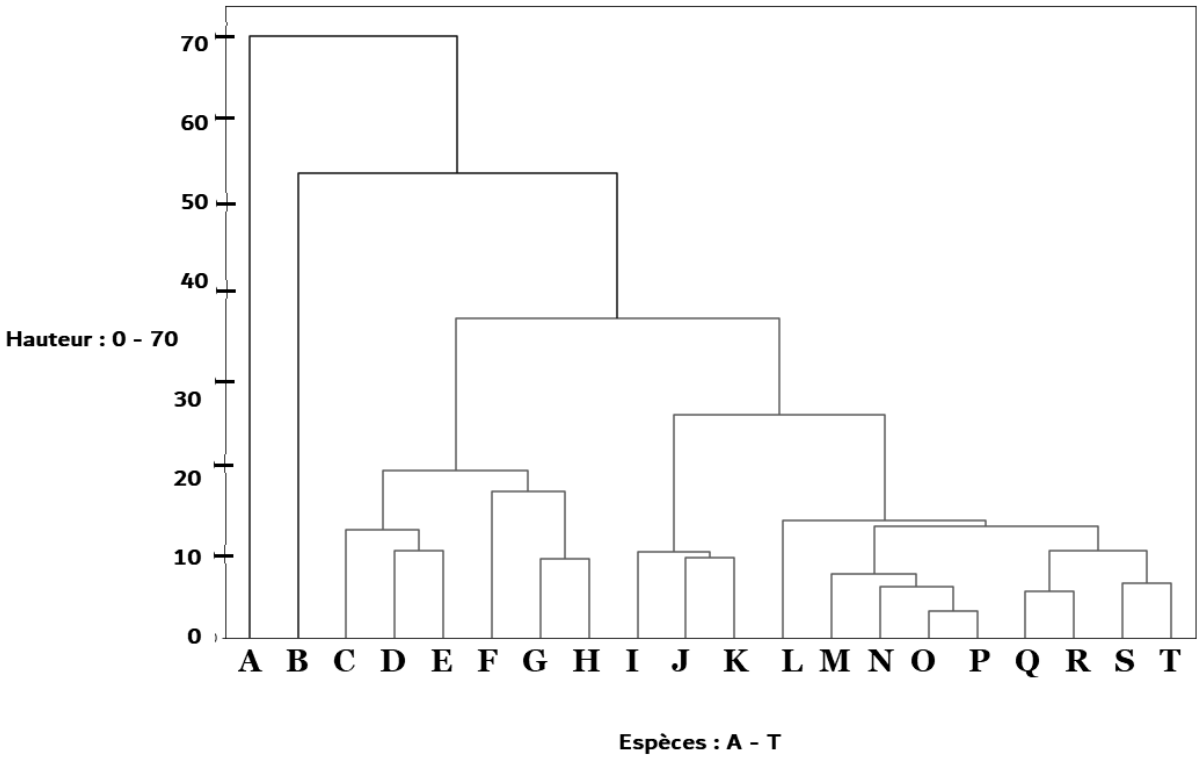


Figure 3

(a) (2 points) D'après le dendrogramme, nommez l'espèce ($\mathbf{A} - \mathbf{T}$) qui est la plus semblable et l'espèce la plus dissemblable à l'espèce **H**. **Justifiez**.

(b) (3 points) Les biologistes disent qu'ils voient 6 familles différentes (*clusters*/groupes) d'espèces dans les données. Obtenez un tel **clustering** à partir de ce dendrogramme. **Comment avez-vous obtenu** cela?
(Exemple d'expression d'un clustering avec 3 clusters : $\{Z, V, X\}, \{U, W\}, \{Y\}$ *)*

(c) (2 points) Les biologistes déterminent que les espèces **L** et **R** appartiennent à la même famille (*cluster*). Suggérez un **clustering** (groupement) à partir de ce dendrogramme qui respecte cette condition.
Quelle est la valeur *approximative* de la distance intra-cluster maximale parmi les clusters du clustering (groupement) que vous avez suggéré? **Justifiez**.

(d) (1 point) Après une analyse génétique effectuée à des fins de vérification, il s'avère qu'il y avait un échantillon de données appartenant à une espèce de lézard sauvage (ce n'est pas un dinosaure) qui s'est mélangé parmi les 20 échantillons que vous avez considérés ici. Quelle espèce ($\mathbf{A} - \mathbf{T}$) est la plus susceptible d'être ce lézard? **Donnez une raison valable**.

(e) (2 points) Obtiendriez-vous nécessairement le même clustering qu'en (a) lorsque vous appliquez le clustering k-moyennes sur ces 20 échantillons avec $k = 6$? **Pourquoi/Pourquoi pas**?

8. Après avoir découvert la technique du bootstrap, certains scientifiques décident de l'utiliser pour valider les performances de leurs modèles d'apprentissage automatique.

   (a) (2 points) Les scientifiques décident de générer un ensemble de validation $(\tilde{x}_i, \tilde{y}_i)$ en utilisant le bootstrapping. (c'est-à-dire que $\tilde{x}_i, \tilde{y}_i$ sont échantillonnés au hasard avec remplacement à partir de $(x_i, y_i)_{1 \leq i \leq n}$). Ils observent que l'erreur de prédiction sur l'ensemble de test est sous-estimée par cette technique (de manière équivalente, on pourrait dire que la précision sur l'ensemble de test a été surestimée). **Expliquez pourquoi**

   (b) (3 points) Ils finissent par revenir aux techniques de validation croisée standard et vous demandent d'effectuer une validation croisée avec différentes divisions.

   1. Dans le **cas X** vous considérez les deux divisions $(x_i, y_i)_{1 \leq i \leq n-1}$ et $(x_i, y_i)_{2 \leq i \leq n}$.
   2. Dans le **cas Y** vous considérez les deux divisions $(x_i, y_i)_{1 \leq i \leq n/2}$ et $(x_i, y_i)_{n/2 < i \leq n}$.

   Vous avez deux modèles $\hat{f}_1$ et $\hat{f}_2$ respectivement entraînés sur le premier ou le deuxième divisions, et vous les appliquez à un ensemble de validation $\{x_i^*\}$, pour obtenir des ensembles de prédictions $\hat{f}_1(x_i^*)$ et $\hat{f}_2(x_i^*)$. La figure 4 ci-dessous affiche les paires des points $\left(\hat{f}_1(x_i^*), \hat{f}_2(x_i^*)\right)$. Pour chaque tracé, **indiquez dans la table** (ci-dessous) s'il est plus cohérent avec le **cas X** ou le **cas Y** et **expliquez votre choix** (sur la page suivante).

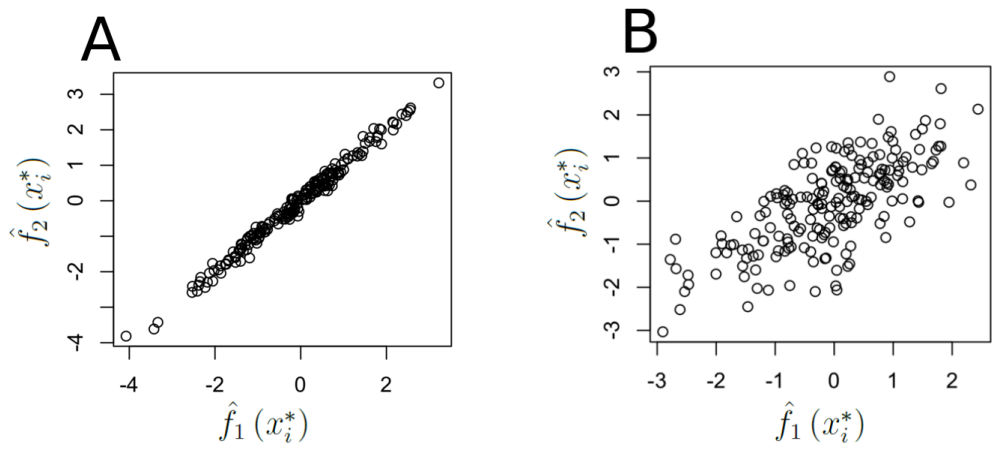


Figure 4

Tracé	Cas
A	
B	

9. Vous êtes un.e consultant.e proposant des solutions de science des données. Vous avez des entreprises clientes qui présentent les descriptions suivantes concernant leurs données et leurs besoins. Avec uniquement ces informations, choisissez la meilleure méthode de sélection de caractéristiques dans la liste des méthodes ci-dessous pour chacun des clients A, B, C et D. Justifiez votre choix dans chaque cas.

   Notez qu'il existe de(s) méthode(s) supplémentaire(s) qui ne corresponde(nt) à aucune description de problème. Vous recevrez 0 point pour les réponses sans justification pertinente.

   Les méthodes de sélection des caractéristiques

   - La méthode Wrapper avec recherche avant (*forward search*)
   - Régularisation de la norme L1 (alias LASSO)
   - T-score
   - La méthode Wrapper avec recherche arrière (*backward search*)
   - L'informations mutuelle

   (a) (2 points) L'entreprise A a besoin d'une approche simple pour réduire le coût d'entraînement (*training*) pour une tâche de classification binaire. Ils n'ont aucune redondance de caractéristiques.

(b) (2 points) L'entreprise B a peur du sur-ajustement (*overfitting*) et ne se soucie pas du coût de calcul. Ils veulent obtenir de bonnes performances de généralisation tout en pouvant expliquer le comportement de l'algorithme.

(c) (2 points) L'entreprise C obtient un large éventail de nouvelles caractéristiques et préfère utiliser son algorithme d'apprentissage automatique actuel pour sa tâche. Ils souhaitent développer leur ensemble de caractéristiques actuel pour obtenir de bonnes performances.

(d) (2 points) L'entreprise D a besoin d'une approche efficace capable de gérer à la fois la pertinence (*relevance*) des caractéristiques et la redondance. Ils n'ont pas de caractéristiques continues.

10. Votre camarade de classe a du mal à déboguer du code Python qu'il/elle a écrit pour un devoir. Trouvez **5 bogues** (erreurs logiques) dans le code ci-dessous, **expliquant chaque bogue et comment le corriger**. Vous obtiendrez +1 point pour chaque bug correctement identifié, +1 pour identifier la correction appropriée. Si une ligne comporte plusieurs erreurs, veuillez indiquer chaque erreur séparément. **Supposons que tous les modules nécessaires ont été importés correctement**.

```
data = pandas.read_csv(data_path,
                       names=[['NoteGlobale',
                               'NoteDevoir1',
                               'NoteDevoir2',
                               'NoteQuiz',
                               'Departement'],
                                na_values='?')

#Corriger les données manquantes
data['Departement'].fillna('manquant')
data.loc['NoteDevoir1'==numpy.nan]=0
data_target = data.loc[:,'NoteGlobale']
data_attrs = data.iloc[:,1:]


#Faire une sélection de caractéristiques Chi-carré
featureselector = SelectKBest(chi2, k=5)
featureselector.fit_transform(data_attrs)

#Tracer les données
data_attrs.hist()

#Générer des plis de CV
kfolds = KFold(data.size, n_folds=3)
for train, test in kfolds:
  data_training = data_attrs[train]
  data_testing = data_attrs[test]

  #Entraîner deux classifieurs
  dtree0 = DecisionTreeClassifier()
  dtree0.fit(data_training, data_target)
  predict0 = dtree0.predict(data_testing)

  dtree1 = DecisionTreeClassifier(max_leaf_nodes=5)
  dtree1.fit(data_training, data_target)
  predict1 = dtree1.predict(data_testing)

  #Effectuer un t-test pour comparer les prédictions
  print(ttest_ind(predict0, predict1))
```

(a) (10 points) Écrivez votre solution ici. **Indiquez le numéro de ligne** pour chaque bogue.

Page supplémentaire (si nécessaire)

Utilisez clairement les numéros de question et de partie si cette page doit être prise en compte