Université de Montréal
Sciences des Données

IFT-6758/3700 – Examen Intra

2024/10/30

Nom Complet (Prénom Nom)

Numéro de matricule (UdeM) | | | | | | | | |

Instructions

- Aucune ressource externe n'est autorisée.
- Donnez de brèves explications pour vos réponses. Nous accorderons un crédit partiel pour un bon raisonnement.
- Pour les questions avec une boîte a remplir, indiquer votre réponse dans la boîte.
- Il y a des pages supplémentaires à la fin de l'examen.

Notations and rappels:

- $\|x_i - x_j\|_2^2 = \sum_{k=1}^{d}([x_i]_k - [x_j]_k)^2$ = Euclidean distance between points x_i and x_j
- $A \setminus B$ = Complémentaire d'un ensemble: éléments dans A mais pas dans B
- $H(X) = -\sum_{i=1}^{d} p(X = x_i)\log(X = x_i)$, entropie d'un variable aléatoire discrète X.
- $I(X,Y) = \sum_{i,j}^{n} p(X = x_i, Y = y_i)\log\left(\frac{p(X=x_i,Y=y_i)}{p(X=x_i)p(Y=y_i)}\right)$ information mutuelle (ou gain d'information) entre deux variables aléatoires X et Y.
- Taux de vrai positifs : $=\frac{\#(\text{prédiction}=+|\text{vrai valeur}=+)}{\#(\text{vrai valeur}=+)}$, Taux de vrai négatifs: $=\frac{\#(\text{prédiction}=-|\text{vrai valeur}=-)}{\#(\text{vrai valeur}=-)}$

Distribution des Points

Question	Points	Score
1	2	
2	15	
3	10	
4	14	
5	10	
6	13	
7	11	
8	13	
Total:	88	

1. **Échauffement**
   (a) (1 point) Écrire correctement et lisiblement votre nom complet et numéro de matricule (voir Figure 1).
   (b) (1 point) (À la fin) Mettre sa copie dans la bonne pile (marquée par la **première lettre** de votre **prénom**)

Full Name (Firstname LASTNAME)

Harry James POTTER

Student ID (UdeM matricule)

	3	1	7	1	9	8	0

Instructions

Figure 1: ou comment marquer un point facilement.

2. **Puissance d'un test.** La boite courriel utilise un classifieur f pour détecter les pourriels. L'entreprise a estimé que 20% des courriels envoyés étaient des pourriels (Vrai positifs). Le Taux de vrais positifs du classifieur est de 80%, c'est à dire que 80% des pourriels sont détectés comme tels par le test. De plus, on sait que l'exactitude (taux de prediction correctes) du classifieur est de 90%.

   Pour remplir le tableau suivant nous supposerons que 100 courriel ont été envoyés.

	Prédit positif	Prédit négatif
Vrai positif		
Vrai négatif		

Table 1: Nombre de courriels dans chaque situation (sur une base de 100 courriels).

(a) (4 points) Complétez les quatre cellules du tableau 1.

(b) (2 points) Quel est le taux de vrai négatifs?

RÉPONSE (sous forme de fraction): $\frac{\cdot}{\cdot}$ (expliquez pourquoi)

(c) (2 points) Un courriel a été signalé comme pourriel (prédit positif) par le classificateur. Il vient d'*un émetteur* ***n'a jamais été*** *signalé auparavant.* Quelle est la probabilité que le courriel soit un véritable pourriel ?

RÉPONSE (sous forme de fraction): $\frac{\cdot}{\cdot}$ (expliquez pourquoi)

(d) (2 points) Un courriel n'a été signalé comme pourriel (prédit negatif) par le classificateur. Il vient d'*un émetteur* ***n'a jamais été*** *signalé auparavant.* Quelle est la probabilité le courriel soit un véritable pourriel?

RÉPONSE (sous forme de fraction): $\frac{\cdot}{\cdot\cdot}$ (**expliquez** pourquoi)

(e) (2 points) Dans ce contexte, est-il préférable de maximizer le taux de vrai positif ou le taux de vrais negatifs? (**expliquez** pourquoi)

(f) (3 points) Nommez 3 caractéristiques pertinentes à considérer pour la détection de pourriel.

3. **Détection d'Anomalies**

Un chercheur analyse la relation entre la hauteur et l'âge des arbres dans une région forestière spécifique et a recueilli les données présentées en Figure 2:

(a) (2 points) Lequel des faits suivants est **toujours** vrai concernant les valeurs aberrantes :

(a) Les valeurs aberrantes peuvent affecter significativement la moyenne empirique ☐

(b) Les valeurs aberrantes peuvent affecter significativement la médiane empirique ☐

(c) Les valeurs aberrantes sont identifiable avec une inspection visuelle des données. ☐

(d) Les valeurs aberrantes proviennent d'erreurs dans la collecte des données. ☐

(e) (2 points) Y a t-il un example abbérant dans la Figure 2?
RÉPONSE: Oui ☐, Non ☐. (Si oui lequel? **et expliquez** pourquoi)

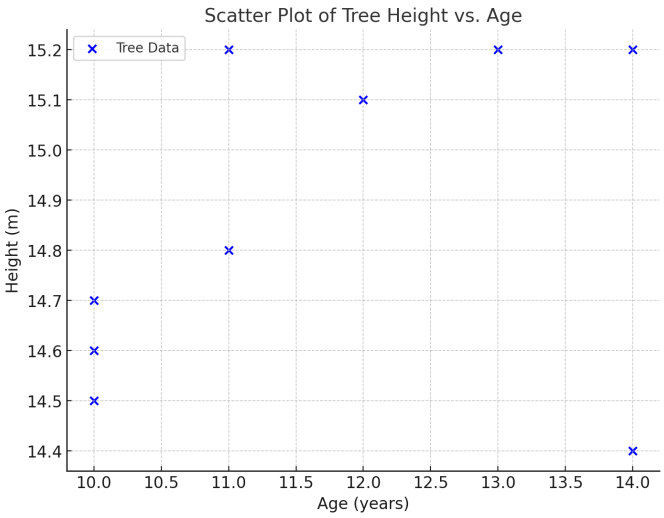


Figure 2: Visualisation des données

Hauteur (m)	Âge (années)
14.5	10
14.8	11
15.1	12
14.7	10
14.9	13
15.2	11
14.6	10
15.2	14
14.4	14

Table 2: Hauteur et taille des arbres.

(f) (2 points) Décrivez la méthode de l'intervalle interquartile (IQR) pour détecter les données aberrantes. (Rappel: cette méthode utilise les 25éme et le 75éme centiles).

(g) (2 points) Est-ce que l'IQR detecterait un example abberant dans les données du Tableau 2?
RÉPONSE: Oui ☐, Non ☐. (Si oui lequel? **et expliquez** pourquoi)

(h) (2 points) Proposer une autre méthode et expliquer comment elle pourrait détecter un example abberant dans ce cas précis.

4. **Visualisation des données et Ingénierie des caractéristiques**

Considérons le dataset suivant, qui représente des données clients pour une entreprise de commerce électronique. Un échantillon de lignes et de colonnes est présenté ci-dessous:

ID	Âge	Rev.	Gen.	Fréq.Ach	Ann.Memb	Rég.	Sat.	Pop.	Score.Client
101	45	75K	M	Élevée	5	NE	Très Satisfait	8M	85
102	30	52K	F	Moyenne	2	O	Satisfait	120K	92
103	62	120K	M	Faible	10	S	Insatisfait	5M	85
104	25	45K	F	Élevée	1	E	Neutre	150K	91
105	55	90K	M	Moyenne	8	NE	Très Satisfait	8M	84

Description des colonnes :

- **ID** : Identifiant unique pour chaque client (identifiant)
- **Âge** : Âge du client
- **Rev** : Revenu annuel du client en dollars
- **Gen** : Genre du client
- **Fréq.Ach** : Fréquence des achats du client, catégorisée en “Faible”, “Moyenne” ou “Élevée”
- **Ann.Memb** : Nombre d’années d’adhésion du client, avec une distribution asymétrique à droite (certain client ont un nombre d’années d’adhésion plus grand d’un ordre de grandeur de plus que la valeur mediane)
- **Rég** : Région géographique du client (N, E, O, S, NE, NO, SE, SO)
- **Sat** : Niveau de satisfaction avec les produits achetés, catégorisé de Très Satisfait” à “Insatisfait”
- **Pop** : Population de la ville du client, avec significativement plus de clients venant de grandes villes
- **Score.Client** : Score du client, représentant le score obtenu en grattant une carte ou attribué pour révéler un prix chanceux

(a) (2 points) Pour la colonne **Reg**, recommandez une technique pour représenter cette caractéristique. Expliquez votre choix en fonction des valeurs de cette colonne.
Technique [ ] Justification

(b) (2 points) Considérez la colonne **Fréq.Ach**. Décrivez une technique de codage appropriée pour cette colonne et expliquez pourquoi cette méthode est adaptée.
Technique [ ] Justification

(c) (3 points) La colonne **Inc** a une large gamme de valeurs. Suggérez une technique de transformation pour cette colonne afin de réduire l'effet des grandes disparités de revenus.
Technique [ ] Justification

(d) (2 points) Il est donné que plus de clients viennent des grandes villes (avec des populations plus élevées) que des petites. Quel type de graphique utiliserez-vous pour visualiser la caractéristique **Pop**? Dessinez un exemple de graphique que vous attendez pour cela et étiquetez les axes. **Justifiez** votre choix.

(e) (1 point) La colonne **Memb.Yrs** est asymétrique à droite (il y a beaucoup plus de clients récents que d'anciens). Quelle transformation ou méthode de mise à l'échelle pourrait être appropriée pour cette caractéristique afin d'améliorer son utilité dans le modèle? Justifiez votre réponse.
Transformation [ ] Justification

(f) (2 points) Certaines colonnes peuvent devoir être supprimées car elles sont non pertinentes ou redondantes. Décrivez une technique de visualisation pour identifier quelles caractéristiques sont pertinentes, non pertinentes ou redondantes. Expliquez pourquoi cette visualisation aiderait à déterminer quelles caractéristiques supprimer.
Technique [ ] Justification

(g) (2 points) Dessinez un exemple de graphique pour illustrer dans quelle mesure la caractéristique *Score.Client.* est corrélée avec à la caractéristique *Age.* Justifiez.

5. **Sélection de caractéristiques**

(a) (8 points) Ci-dessous sont décrites quatre méthodes de sélection de caractéristiques. Pour chaque méthode, identifiez si elle est une méthode *wrapper* (emballage), *filter* (filtre) ou

embedded (intégrée), et fournissez une brève justification de votre réponse.

Méthode A : Cette méthode évalue les caractéristiques en ajustant plusieurs fois le modèle avec des sous-ensembles de caractéristiques, en éliminant les moins efficaces sur la base de la performance du modèle, jusqu'à ce qu'il ne reste qu'un sous-ensemble performant de caractéristiques.

wrapper ☐ filter ☐ embedded ☐

Méthode B : Cette méthode sélectionne les caractéristiques en mesurant leur relation avec la variable cible, en conservant celles qui dépassent un seuil spécifié.

wrapper ☐ filter ☐ embedded ☐

Méthode C : Lors du processus d'entraînement du modèle, cette méthode conserve automatiquement les caractéristiques qui contribuent le plus directement aux prédictions du modèle en assignant des poids internes à chaque caractéristique et en supprimant celles dont le poids est inférieur à un certain seuil.

wrapper ☐ filter ☐ embedded ☐

Méthode D : Cette méthode classe et sélectionne les caractéristiques en fonction de leurs propriétés inhérentes, comme la corrélation ou la variance, indépendamment de tout modèle prédictif.

wrapper ☐ filter ☐ embedded ☐

(b) (2 points) Dans un ensemble de données contenant un grand nombre de caractéristiques fortement corrélées, l'objectif est d'améliorer à la fois l'interprétabilité et la performance du modèle. Comparez l'applicabilité de la *Méthode A* et de la *Méthode B* pour ce scénario. Discutez quelle méthode pourrait être plus efficace et les compromis potentiels impliqués.

---

6. **Apprentissage non supervisé**

Le *dataset des pingouins* comprend des mesures des espèces de pingouins *Adélie*, *Gentoo* et *Chinstrap* de l'archipel Palmer, en Antarctique. Les principales caractéristiques incluent: l'*espèce*, l'*île*, la longueur et la *profondeur du culmen (bec)*, la *longueur des nageoires*, la *masse corporelle* et le *sexe*. Les scientifiques qui ont collecté les données souhaitent utiliser l'apprentissage non supervisé pour l'analyse et la visualisation.

La Figure 3 montre les pingouins projetés sur les deux composantes principales (PC1 et PC2).

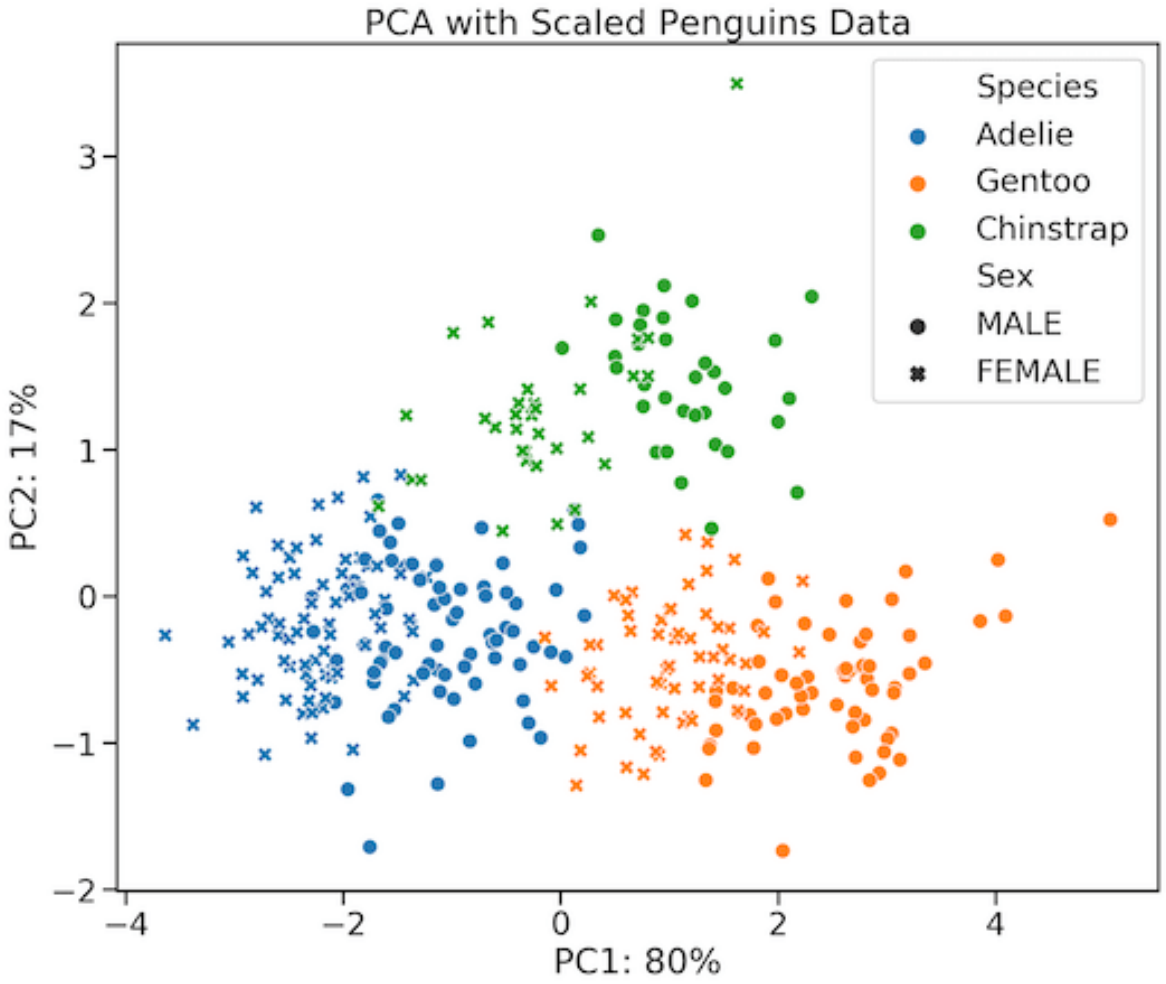


Figure 3: Graphique ACP du dataset des pingouins montrant un regroupement par espèce et par sexe.

(a) (1 point) Décrivez brièvement comment le concept de variance est lié aux composantes principales.

(b) (2 points) En vous basant sur le graphique, décrivez la distribution des *espèces* de pingouins en termes des deux premières composantes principales (PC1 et PC2). Que suggère le regroupement des espèces quant à leurs différences?

(c) (2 points) Commentez la séparation des pingouins par *sexe* au sein de chaque espèce.

L'ACP indique-t-elle une forte contribution de la variance liée au sexe? Justifiez votre réponse en vous basant sur le graphique.

(d) (2 points) Si le vecteur PC1 montre des valeurs élevées pour la caractéristique *longueur du culmen* et la caractéristique *longueur des nageoires*, interprétez ce que cela implique quant aux différences entre les espèces.

(e) (2 points) Supposons que PC2 ait des valeurs élevées pour les caractéristiques "profondeur du culmen" et la "masse corporelle". Que cela suggère-t-il à propos de la variance capturée par PC2 et de la manière dont elle pourrait aider à distinguer les individus au sein d'une espèce ?

(f) (2 points) Sachant que PC1 capture 80% de la variance et PC2 en capture 17%, pensez-vous qu'il soit nécessaire de considérer des composantes principales supplémentaires pour ce jeu de données ? Quelles pourraient être les raisons de les considérer ou de les ignorer ?

(g) (2 points) Si une nouvelle caractéristique était ajoutée au dataset (par exemple, la longueur des plumes), quel impact cette nouvelle caractéristique pourrait-elle avoir sur les composantes principales existantes ?

7. **Test d'hypothèse.** Cette section évaluera la compréhension de l'utilisation des tests d'hypothèse.

Dans la Figure 4, nous montrons la carte STM de Montréal. Dans cette question, nous voulons comprendre s'il est préférable de prendre le bus ou le métro. Nous avons 37 échantillons de personnes prenant le métro et 18 échantillons de personnes prenant le bus pour se rendre à l'UdeM.

(a) (1 point) Quelle est l'hypothèse nulle ?

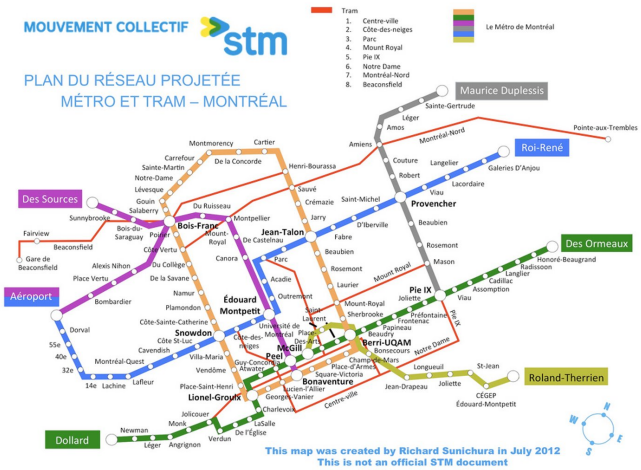


Figure 4: Carte de la STM.

Une variable qui n'a pas encore été assignée. ☐ Une quantité égale à 0. ☐ Un résultat qui n'est pas clair. ☐ Le cas oú les deux moyennes des distributions sont les mêmes. ☐

(b) (1 point) Si nous souhaitons effectuer un test-t quelles sont les quantitées que nous allons comparer?

(c) (2 points) Comment interpréter une valeur-p $< .05$? (Une seule bonne réponse)

"La valeur-p $< .05$ indique la probabilité que l'hypothèse nulle soit vraie est de moins de 5%" ☐

"Une valeur-p de < 0.05 signifie qu'il y a 5% de chances que notre résultat soit dû au hasard." ☐

"Si la valeur-p $< .05$, cela prouve que l'hypothèse alternative est vraie avec une probabilité supérieure à 95%" ☐

"La valeur-p $< .05$ indique que la probabilité d'obtenir un résultat aussi extrême que celui observé, en supposant que l'hypothèse nulle est inférieure à 5%" ☐

(d) (2 points) Quelles hypothèses sont **suffisantes** afin de pouvoir utiliser un test t pour vérifier si les données indiquent que prendre le métro est en moyenne plus rapide que le bus ?

Les données sont uniformément distribuées ☐

Les données sont distribuées normalement ☐

Les données sont distribuées entre [0, 1) ☐

Les données ont une variance égale ☐

Il y a plus de 40 points de données dans chaque jeu de données ☐

Il y a moins de 40 points de données dans chaque jeu de données ☐

Expliquer.

(e) (1 point) Si nous utilisons un test t pour comparer les moyennes des deux distributions et que nous obtenons une valeur de 0,7, cette valeur est-elle une bonne ou une mauvaise nouvelle? Bonne ☐, Mauvaise ☐, Pourquoi ?

(f) (2 points) Nous voulons maintenant savoir la conduite (38 échantillons), le vélo (41 échantillons), le métro ou le bus est une meilleure option pour se rendre à l'UdeM. Nous effectuons un test t pour chacun des temps moyens et nous observons une valeur-p de .02 pour la différence entre le temps en vélo et celui en bus. Pouvons nous rejeter l'hypothèse nulle et dire qu'il y a une différence significative (avec un seuil de tolérance de .05)? Oui ☐ ; Non ☐.
Si oui justifier, et si non , proposer une alternative (ou une valeur de p qui serait suffisante).

(g) (2 points) Si nous n'obtenons pas une valeur p suffisante lors de notre première collecte de données, pouvons-nous essayer de collecter plus de données et refaire le même test ? Oui ☐, Non ☐. Pourquoi ?

---

8. **Sélection optimale des hyperparamètres** Dans cette section, nous allons travailler sur le processus de recherche des hyperparamètres optimaux.

   (a) (2 points) Quelle est la différence entre les paramètres et les hyperparamètres ?

(b) (2 points) Chaque sélection d'hyperparamètres influence laquelle des options suivantes ? Le nombre de paramètres du modèle : ☐ La valeur finales des paramètres : ☐ Le temps d'entraînement : ☐ La performance du modèle : ☐ Justifier

(c) (2 points) Entourez la sous-figure qui représente le modèle le mieux ajusté.

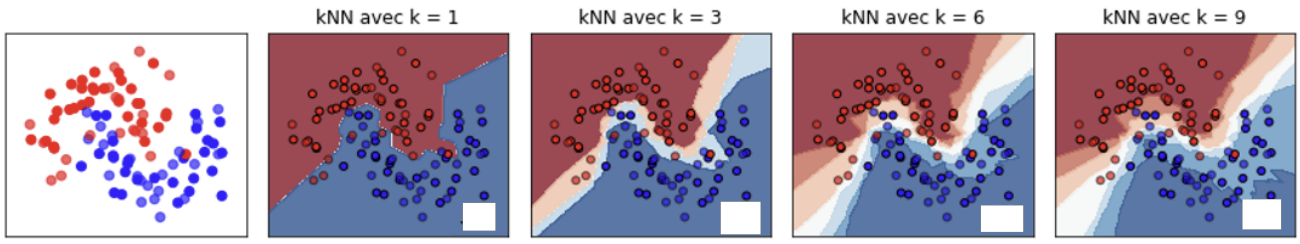


Figure 5: Le jeu de données d'entrée est à gauche, et les figures de droite montrent l'ajustement du modèle pour différents nombres de k.

(d) (3 points) Mettez ces étapes dans l'ordre correct (de 1 à 5) pour décrire le processus de sélection du modèle optimal : Entraîner le modèle : ☐ Préparation et nettoyage des données : ☐ Définir les hyperparamètres : ☐ Définir les bornes sur les hyperparamètres : ☐ Déployer le modèle : ☐

Nous avons 3 principaux types d'algorithmes d'optimisation d'hyperparamètres : (1) basé sur une grille régulière, (2) échantillonnage aléatoire uniforme et (3) échantillonnage bayésien. Pour chaque situation, indiquez quel algorithme est normalement le meilleur à utiliser dans ce cas.

(e) (1 point) Nous avons une configuration avec 3 hyperparamètres, chacun avec 8 valeurs possibles, et nous **n'avons pas** assez de puissance de calcul pour toutes les configurations. ☐

(f) (1 point) Nous avons une configuration avec 10 hyperparamètres, chacun avec des valeurs continues, et nous avons un budget de 200 tâches que nous pouvons exécuter. ☐

(g) (1 point) Nous avons une configuration avec 3 hyperparamètres, chacun avec 4 paramètres possibles, et nous avons assez de puissance de calcul pour exécuter tous les paramètres en parallèle. ☐

(h) (1 point) Nous avons une configuration avec 3 hyperparamètres, chacun avec des valeurs continues. ☐

Page Additionnelle 1 (si nécessaire)

Mentionner clairement le numéros de question pour que cette page soit prise en compte.

Page Additionnelle 2 (si nécessaire)

Mentionner clairement le numéros de question pour que cette page soit prise en compte.