

Apprentissage pour la science des données

Cours 2: Apprentissage automatique pour la science des données

Glen Berseth

Université de Montréal and Mila Québec AI Institute

September 9, 2026



Université  de Montréal



Mila

CIFAR

Plan

Science des données


Catégories d'apprentissage automatique

Régression: applications

Classification: applications

Apprentissage non supervisé — pourquoi?

Science des données



- Pourquoi voulons-nous faire de l'apprentissage automatique?
- Source: <https://www.datasciencecourse.org/slides/intro.pdf>

Catégories d'apprentissage automatique

- Deux grandes catégories principales:

Catégories d'apprentissage automatique

- Deux grandes catégories principales:
- Apprentissage supervisé — Notre définition (approximative): entraîner un modèle θ quand nous avons seulement des paires entrée-sortie (x_i, y_i)

Catégories d'apprentissage automatique

- Deux grandes catégories principales:
- Apprentissage supervisé — Notre définition (approximative): entraîner un modèle θ quand nous avons seulement des paires entrée-sortie (x_i, y_i)
- Apprentissage non supervisé — Notre définition (approximative): entraîner un modèle θ quand nous avons seulement les entrées (x_i)

Catégories d'apprentissage automatique

- Deux grandes catégories principales:
- Apprentissage supervisé — Notre définition (approximative): entraîner un modèle θ quand nous avons seulement des paires entrée-sortie (x_i, y_i)
- Apprentissage non supervisé — Notre définition (approximative): entraîner un modèle θ quand nous avons seulement les entrées (x_i)
- Quelques catégories intermédiaires (vues plus tard dans le cours):
 - Apprentissage par renforcement (comparaison relative entre données $x_i > x_j$)
 - apprentissage semi-supervisé (seule une partie de la sortie est disponible pour chaque x_i),
 - apprentissage autosupervisé (crée automatiquement les étiquettes/cible y_i)

Apprentissage supervisé: entrée - sortie

- Dans de nombreuses applications, nous voulons modéliser une variable de sortie en fonction de plusieurs entrées,

Apprentissage supervisé: entrée - sortie

- Dans de nombreuses applications, nous voulons modéliser une variable de sortie en fonction de plusieurs entrées,
- Profil génétique $\rightarrow$ Risque de développer une maladie

Apprentissage supervisé: entrée - sortie

- Dans de nombreuses applications, nous voulons modéliser une variable de sortie en fonction de plusieurs entrées,
- Profil génétique → Risque de développer une maladie
- Caractéristiques d'une personne → Si elle va voter

Apprentissage supervisé: entrée - sortie

- Dans de nombreuses applications, nous voulons modéliser une variable de sortie en fonction de plusieurs entrées,
- Profil génétique → Risque de développer une maladie
- Caractéristiques d'une personne → Si elle va voter
- Plan marketing → Montant total des ventes

Apprentissage supervisé: entrée - sortie

- Dans de nombreuses applications, nous voulons modéliser une variable de sortie en fonction de plusieurs entrées,
- Profil génétique $\rightarrow$ Risque de développer une maladie
- Caractéristiques d'une personne $\rightarrow$ Si elle va voter
- Plan marketing $\rightarrow$ Montant total des ventes
- Valeurs des pixels d'une image $\rightarrow$ chat ou chien



$$x_i = (x_i^1, \dots, x_i^m) \leftarrow \text{toutes les entrées}$$

$$\hat{y}_i \leftarrow f(x_i|\theta) \leftarrow \text{relation entre entrées et sortie}$$

Apprendre une fonction reliant entrée et sortie

- f est une fonction « simple » qui décrit la relation entre l'entrée x et la sortie $\hat{y}$, paramétrée par θ :


$$\hat{y} \leftarrow f(x|\theta)$$

Apprendre une fonction reliant entrée et sortie

- f est une fonction « simple » qui décrit la relation entre l'entrée x et la sortie $\hat{y}$, paramétrée par θ :

$$\hat{y} \leftarrow f(x|\theta)$$

- ϵ_i représente l'erreur, la différence entre la sortie du modèle et la vraie valeur.




Apprentissage supervisé: entrée - sortie

Old label: pier
Real: dock; pier;
speedboat; sandbar;
seashore




Old label: hammer
Real: screwdriver;
hammer; power drill;
carpenter's kit



- Objectif: étant donné une entrée x , prédire une sortie y
- Ce que nous avons: des observations:
- Pourquoi c'est « difficile »:
- Les étiquettes peuvent être stochastiques:
- La prédiction peut être « complexe » (non linéaire en haute dimension)
- Seulement quelques paires observées (mauvaises étiquettes)
- Formellement: (x_i, y_i) , $i = 1, \dots, n$


Apprentissage supervisé: classification

- Prédiction de classes discrètes (ex: chats vs chiens)
- Exemple ici:
 - Entrée: position 2D
 - Sortie (étiquettes): bleu ou jaune
- Objectif: chaque région de l'espace devrait être bleue ou jaune.
- Évaluation: perte 0-1 sur l'ensemble de test




Apprentissage supervisé: régression

- Prédiction d'étiquettes continues (ex: température)
- Exemple ici:
 - Entrée: position 2D
 - Sortie: valeur (représentée par une couleur)
- Objectif: chaque région de l'espace devrait avoir une valeur



Apprentissage supervisé: régression

- Prédiction d'étiquettes continues (ex: température)
- Exemple ici:
 - Entrée: position 2D
 - Sortie: valeur (représentée par une couleur)
- Objectif: chaque région de l'espace devrait avoir une valeur
- Évaluation: perte de précision sur un ensemble de test.



Apprentissage supervisé: régression vs classification

- Plus liées qu'il n'y paraît.

Apprentissage supervisé: régression vs classification

- Plus liées qu'il n'y paraît.
- Considérons un problème de classification avec 2 classes.

Apprentissage supervisé: régression vs classification

- Plus liées qu'il n'y paraît.
- Considérons un problème de classification avec 2 classes.
- Difficile à apprendre avec la perte 0-1 (en fait NP-difficile)! (Land and Doig, 2009)

Apprentissage supervisé: régression vs classification

- Plus liées qu'il n'y paraît.
- Considérons un problème de classification avec 2 classes.
- Difficile à apprendre avec la perte 0-1 (en fait NP-difficile)! (Land and Doig, 2009)
- Nous essayons plutôt d'apprendre la fonction f :
 - (**probabilité** que l'étiquette soit y étant donné l'entrée x)
 - Nous avons maintenant un problème de régression!!!

Apprentissage supervisé: régression vs classification

- Plus liées qu'il n'y paraît.
- Considérons un problème de classification avec 2 classes.
- Difficile à apprendre avec la perte 0-1 (en fait NP-difficile)! ([Land and Doig, 2009](#))
- Nous essayons plutôt d'apprendre la fonction f :
 - (**probabilité** que l'étiquette soit y étant donné l'entrée x)
 - Nous avons maintenant un problème de régression!!!
- Q: il reste tout de même des différences par rapport à une tâche de régression: lesquelles voyez-vous?

$$f(x|\theta) = \mathbb{P}(y = 1|x) \in [0, 1]$$

Apprentissage supervisé: régression vs classification


- Plus liées qu'il n'y paraît.
- Considérons un problème de classification avec 2 classes.
- Difficile à apprendre avec la perte 0-1 (en fait NP-difficile)! (Land and Doig, 2009)
- Nous essayons plutôt d'apprendre la fonction f :
 - (**probabilité** que l'étiquette soit y étant donné l'entrée x)
 - Nous avons maintenant un problème de régression!!!
- Q: il reste tout de même des différences par rapport à une tâche de régression: lesquelles voyez-vous?

$$f(x|\theta) = \mathbb{P}(y = 1|x) \in [0, 1]$$

- Que faire si notre donnée contenait un y de valeur 7,8?

Aide au diagnostic médical

- Objectif: prédire la probabilité de présence de la Covid-19 dans les poumons des patients selon les facteurs suivants:
- Radiographies
- Tests de laboratoire
- Dossier médical
- Mode de vie




- COVID-19 catch-up: New AI tool detects affected lung tissue by analyzing X-Ray images | Silicon Channels


Prévisions météorologiques

- Objectifs: prédire les précipitations mondiales à partir de
- Images satellites
- Relevés de bouées
- Observations historiques
- Années El Niño et La Niña
- etc


- Source:
<https://www.deepmind.com/blog/now-the-next-hour-of-rain>




Target



DGMR




PySTEPS



UNet

Prévisions d'offre et de demande


- Objectifs: prévoir les aspects suivants pour une entreprise de commerce international
- Évolution des stocks
- Évolution de la demande



- True Stock | Top 5 Benefits of using Machine Learning for Demand Forecasting

Reconnaissance d'objets

- Objectif: reconnaître les types d'objets présents dans une image malgré les variations d'objets et de poses.



- A. Krizhevsky, I. Sutskever and G.E. Hinton. Imagenet Classification with Deep Convolutional Neural Networks. In Advances in Neural Information Processing Systems, 2012.

Reconnaissance de caractères manuscrits


- Objectif: reconnaître chaque caractère malgré les différents styles d'écriture.



- By Josef Steppan, CC BY-SA-4.0.
<https://commons.wikimedia.org/wiki/File:Mni>

Traitement du langage naturel

- Objectif: reconnaître des combinaisons et arrangements de mots pour filtrer les pourriels (SPAM).




- Decision Trees

Reconnaissance vocale

- Objectifs: identifier un locuteur à partir de
- La dépendance temporelle de l'information.
- Dictionnaires de mots/structures valides.




- ABC



- Siri richtig nutzen: nützliche Tipps & Befehle auf einen Blick (sparhandy.de)

Voiture autonome

- Objectif:
- identifier les pixels correspondant à ces éléments:
- piétons
- bâtiments
- arbres
- types de terrain
- malgré les mouvements des objets et de la voiture!
- Nous nous intéressons aux zones de l'image contenant des objets du même type (sémantique).




L'importance d'avoir des systèmes robustes

- Robustes à différentes situations.
- Surtout celles qui n'ont jamais été vécues auparavant.
- Les humains gèrent très bien la variabilité.




Prédiction du prochain jeton (LLM)




- Les transformeurs (transformers) ont été développés pour résoudre les problèmes de traduction automatique et de transduction de séquences... mais ils font tellement plus!

Prédiction du prochain jeton (LLM)




- Les transformeurs (transformers) ont été développés pour résoudre les problèmes de traduction automatique et de transduction de séquences... mais ils font tellement plus!
- Excellente performance en vision par ordinateur, comme ViT (Dosovitskiy, 2020)

Prédiction du prochain jeton (LLM)




- Les transformeurs (transformers) ont été développés pour résoudre les problèmes de traduction automatique et de transduction de séquences... mais ils font tellement plus!
- Excellente performance en vision par ordinateur, comme ViT (Dosovitskiy, 2020)
- Classification d'images (Transformeur CoCa)

Prédiction du prochain jeton (LLM)



- Les transformeurs (transformers) ont été développés pour résoudre les problèmes de traduction automatique et de transduction de séquences... mais ils font tellement plus!
- Excellente performance en vision par ordinateur, comme ViT (Dosovitskiy, 2020)
- Classification d'images (Transformeur CoCa)
- Segmentation sémantique (ex: Transformeur FD-SwinV2-G)

Prédiction du prochain jeton (LLM)



- Les transformeurs (transformers) ont été développés pour résoudre les problèmes de traduction automatique et de transduction de séquences... mais ils font tellement plus!
- Excellente performance en vision par ordinateur, comme ViT (Dosovitskiy, 2020)
- Classification d'images (Transformeur CoCa)
- Segmentation sémantique (ex: Transformeur FD-SwinV2-G)
- Détection d'objets (ex: Transformeur FD-SwinV2-G)

Regroupement (clustering): inférer des étiquettes sur des données non étiquetées

- Que pouvons-nous faire quand nous n'avons pas les étiquettes y ???

Regroupement (clustering): inférer des étiquettes sur des données non étiquetées

- Que pouvons-nous faire quand nous n'avons pas les étiquettes y ???
- Hypothèse: un point x avec la même étiquette devrait être similaire

Regroupement (clustering): inférer des étiquettes sur des données non étiquetées

- Que pouvons-nous faire quand nous n'avons pas les étiquettes y ???
- Hypothèse: un point x avec la même étiquette devrait être similaire
- Regroupement (clustering): modèle visant à regrouper les points de données d'entrée « similaires ».

Regroupement (clustering): inférer des étiquettes sur des données non étiquetées

- Que pouvons-nous faire quand nous n'avons pas les étiquettes y ???
- Hypothèse: un point x avec la même étiquette devrait être similaire
- Regroupement (clustering): modèle visant à regrouper les points de données d'entrée « similaires ».
- Une grande partie de la complexité tient à comment nous définirons « similaire »

Regroupement (clustering): inférer des étiquettes sur des données non étiquetées

- Que pouvons-nous faire quand nous n'avons pas les étiquettes y ???
- Hypothèse: un point x avec la même étiquette devrait être similaire
- Regroupement (clustering): modèle visant à regrouper les points de données d'entrée « similaires ».
- Une grande partie de la complexité tient à comment nous définirons « similaire »
- Exemple: des points de données proches selon une certaine distance (quelle distance???)

Regroupement (clustering): inférer des étiquettes sur des données non étiquetées


- Que pouvons-nous faire quand nous n'avons pas les étiquettes y ???
- Hypothèse: un point x avec la même étiquette devrait être similaire
- Regroupement (clustering): modèle visant à regrouper les points de données d'entrée « similaires ».
- Une grande partie de la complexité tient à comment nous définirons « similaire »
- Exemple: des points de données proches selon une certaine distance (quelle distance???)
- Importance des bonnes caractéristiques: capturera mieux la similarité.

Regroupement

- À l'œil, nous voyons clairement qu'il y a 4 groupes!
- Importance de la visualisation de données!!!!
(nous savons maintenant qu'il faut chercher 4 groupes)



Regroupement



Réduction de dimensionnalité: inférer la structure de données non étiquetées

- Problème: les données peuvent être en très haute dimension, par exemple des images.
- Hypothèse: il existe une variété latente de faible dimension z qui capture suffisamment les données.
 - Cette hypothèse est appelée l'hypothèse de la variété (manifold hypothesis): dans plusieurs cas, il existe un espace de plus faible dimension qui capture quand même les données. (Cayton and others, 2005)

Réduction de dimensionnalité: inférer la structure de données non étiquetées

- Problème: les données peuvent être en très haute dimension, par exemple des images.
- Hypothèse: il existe une variété latente de faible dimension z qui capture suffisamment les données.
 - Cette hypothèse est appelée l'hypothèse de la variété (manifold hypothesis): dans plusieurs cas, il existe un espace de plus faible dimension qui capture quand même les données. (Cayton and others, 2005)
- Fonction: $\hat{z}_i \leftarrow f(x_i|\theta)$
 - $\hat{z}_i$ est souvent continu



Réduction de dimensionnalité

- Pourquoi cette hypothèse?
- Des exemples aléatoires uniformes ne ressemblent pas à de *vraies* données.



Réduction de dimensionnalité

- Pourquoi cette hypothèse?
- Des exemples aléatoires uniformes ne ressemblent pas à de *vraies* données.



- Exemple: MNIST (identification de lettres manuscrites):



$$\begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & .6 & .8 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & .7 & .1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & .7 & .1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & .5 & .1 & .4 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & .1 & .4 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & .1 & .4 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & .1 & .7 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & .1 & .1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & .9 & .1 & .1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & .3 & .1 & .1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$


Illustration de l'hypothèse de la variété

- Les données se situent approximativement sur une variété 1D:
- Objectif: apprendre le système de coordonnées de la variété



Illustration de l'hypothèse de la variété

- Les données se situent approximativement sur une variété 1D:
- Objectif: apprendre le système de coordonnées de la variété



Réduction de dimensionnalité: conclusion

- Peut-être le contexte le moins clair

Réduction de dimensionnalité: conclusion

- Peut-être le contexte le moins clair
- Idée générale: trouver de meilleures représentations

Réduction de dimensionnalité: conclusion

- Peut-être le contexte le moins clair
- Idée générale: trouver de meilleures représentations
- Exemple: analyse en composantes principales (couverte à la semaine 7)

Réduction de dimensionnalité: conclusion

- Peut-être le contexte le moins clair
- Idée générale: trouver de meilleures représentations
- Exemple: analyse en composantes principales (couverte à la semaine 7)
- Utile pour éventuellement résoudre d'autres tâches (ex: classification avec peu de données)
 - AA avec peu de caractéristiques

Conclusion (partie 1)

- Les tâches d'AA que vous pourriez rencontrer en SD dépendent de vos données (selon que vous ayez accès ou non aux étiquettes)

Conclusion (partie 1)

- Les tâches d'AA que vous pourriez rencontrer en SD dépendent de vos données (selon que vous ayez accès ou non aux étiquettes)
- Deux grands paradigmes:

Conclusion (partie 1)

- Les tâches d'AA que vous pourriez rencontrer en SD dépendent de vos données (selon que vous ayez accès ou non aux étiquettes)
- Deux grands paradigmes:
- Apprentissage supervisé (avec étiquettes)

Conclusion (partie 1)

- Les tâches d'AA que vous pourriez rencontrer en SD dépendent de vos données (selon que vous ayez accès ou non aux étiquettes)
- Deux grands paradigmes:
- Apprentissage supervisé (avec étiquettes)
- Apprentissage non supervisé (sans étiquettes)

Conclusion (partie 1)

- Les tâches d'AA que vous pourriez rencontrer en SD dépendent de vos données (selon que vous ayez accès ou non aux étiquettes)
- Deux grands paradigmes:
- Apprentissage supervisé (avec étiquettes)
- Apprentissage non supervisé (sans étiquettes)
- Partie 2: quelques algorithmes concrets d'apprentissage supervisé.

Conclusion (partie 1)

- Les tâches d'AA que vous pourriez rencontrer en SD dépendent de vos données (selon que vous ayez accès ou non aux étiquettes)
- Deux grands paradigmes:
- Apprentissage supervisé (avec étiquettes)
- Apprentissage non supervisé (sans étiquettes)
- Partie 2: quelques algorithmes concrets d'apprentissage supervisé.
- Suivez IFT 6390 si vous voulez en apprendre plus sur la théorie des algorithmes d'apprentissage supervisé.


Conclusion (partie 1)

- Les tâches d'AA que vous pourriez rencontrer en SD dépendent de vos données (selon que vous ayez accès ou non aux étiquettes)
- Deux grands paradigmes:
- Apprentissage supervisé (avec étiquettes)
- Apprentissage non supervisé (sans étiquettes)
- Partie 2: quelques algorithmes concrets d'apprentissage supervisé.
- Suivez IFT 6390 si vous voulez en apprendre plus sur la théorie des algorithmes d'apprentissage supervisé.
- Comment utiliser ces algorithmes en pratique (avec sk-learn) dans les prochains laboratoires.

Exemple détaillé: régression logistique

- Régression logistique:
 - Estimer $P(C_1|\mathbf{x})$
- Apprendre w et w_0 à partir de $\mathcal{X} = \{\mathbf{x}_i, y_i\}$,
 - avec les étiquettes $y_i \in \{0, 1\}$.
 - $\theta = w_1, w_0$

$$y = \hat{P}(C_1|\mathbf{x}) = \frac{1}{1 + \exp[-(\mathbf{w}^\top \mathbf{x} + w_0)]}$$




Régression logistique

Discrete distributions

The Bernoulli distribution

$$p(x) = P[X = x] = \begin{cases} q = 1 - p & x = 0 \\ p & x = 1 \end{cases}$$



$$X = \begin{cases} 1 & \text{Bernoulli trial} = \mathbf{S} \\ 0 & \text{Bernoulli trial} = \mathbf{F} \end{cases}$$

- y_i pour un $\mathbf{x}_i$ donné suit une distribution de Bernoulli de probabilité $\hat{y}_i = P(C_1|\mathbf{x}_i)$


Régression logistique

Discrete distributions

The Bernoulli distribution

$$p(x) = P[X = x] = \begin{cases} q = 1 - p & x = 0 \\ p & x = 1 \end{cases}$$

$$X = \begin{cases} 1 & \text{Bernoulli trial} = \mathbf{S} \\ 0 & \text{Bernoulli trial} = \mathbf{F} \end{cases}$$




- y_i pour un $\mathbf{x}_i$ donné suit une distribution de Bernoulli de probabilité $\hat{y}_i = P(C_1|\mathbf{x}_i)$
- Vraisemblance d'échantillonnage de $\mathcal{X}$ selon w et w_0 :

Régression logistique

Discrete distributions

The Bernoulli distribution

$$p(x) = P[X = x] = \begin{cases} q = 1 - p & x = 0 \\ p & x = 1 \end{cases}$$



$$X = \begin{cases} 1 & \text{Bernoulli trial} = \mathbf{S} \\ 0 & \text{Bernoulli trial} = \mathbf{F} \end{cases}$$

- y_i pour un $\mathbf{x}_i$ donné suit une distribution de Bernoulli de probabilité $\hat{y}_i = P(C_1|\mathbf{x}_i)$
- Vraisemblance d'échantillonnage de $\mathcal{X}$ selon w et w_0 :


- Erreur à maximiser: log-vraisemblance

Régression logistique

Discrete distributions

The Bernoulli distribution

$$p(x) = P[X=x] = \begin{cases} q=1-p & x=0 \\ p & x=1 \end{cases}$$



$$X = \begin{cases} 1 & \text{Bernoulli trial} = \text{S} \\ 0 & \text{Bernoulli trial} = \text{F} \end{cases}$$

- y_i pour un $\mathbf{x}_i$ donné suit une distribution de Bernoulli de probabilité $\hat{y}_i = P(C_1|\mathbf{x}_i)$
- Vraisemblance d'échantillonnage de $\mathcal{X}$ selon w et w_0 :

- Erreur à maximiser: log-vraisemblance
- Aussi appelée entropie croisée.

$$l(\mathbf{w}, w_0|\mathcal{X}) = \prod_i (\hat{y}_i)^{y_i} (1 - \hat{y}_i)^{(1-y_i)}$$

$$E_{entr}(\mathbf{w}, w_0|\mathcal{X}) = -\log l(\mathbf{w}, w_0|\mathcal{X}) = -\sum_i y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)$$

Algorithme d'apprentissage

- Regarder : descente de gradient (vidéo)
- Initialiser aléatoirement les poids, $w^j \sim U(-0.01, 0.01)$.
- Répéter jusqu'à convergence:
- Prédiction:

$$\hat{y}_i = \frac{1}{1 + \exp[-(\mathbf{w}^\top \mathbf{x}_i + w_0)]}, \quad i = 1, \dots, N(\text{lot})$$


- Pas de gradient:

$$w^j = w^j + \eta \sum_i (y_i - \hat{y}_i) x_i^j, \quad j = 1, \dots, D(\text{chaque caractéristique})$$

$$w_0 = w_0 + \eta \sum_i (y_i - \hat{y}_i)$$

Descente de gradient (vidéo)

1. Intuition



Cette figure dans la vidéo illustre le processus de calcul du gradient et son utilisation, ainsi que la droite qui s'ajuste le mieux aux données.

Interprétation



- Prédiction:

$$\hat{y} = \hat{P}(C_1|\mathbf{x}) = \frac{1}{1 + \exp[-(\mathbf{w}^\top \mathbf{x} + w_0)]}$$

- Interprétation des coefficients w^j :
 - plus w^j est grand, plus x^j est important pour la prédiction.
 - si w^j est nul, la caractéristique x^j n'affecte pas la prédiction.


Exemple sur le jeu de données IRIS

- 4 caractéristiques: la longueur et la largeur (en centimètres) des sépales et pétales des fleurs.
- Proposé par Fisher en 1936.
- Deux des trois espèces ont été récoltées en Gaspésie (Québec, Canada).



Arbre de décision

- Effectue un découpage hiérarchique de l'espace d'entrée
- Chaque nœud correspond à un test sur une caractéristique (variable d'entrée)
- Les feuilles de l'arbre correspondent aux prédictions



Caractéristiques des arbres de décision

- Ils sont construits de haut en bas

Caractéristiques des arbres de décision

- Ils sont construits de haut en bas
- Ils ont tendance à se sur-spécialiser et sur-apprendre
 - L'élagage des branches est souvent requis après construction pour simplifier la structure

Caractéristiques des arbres de décision

- Ils sont construits de haut en bas
- Ils ont tendance à se sur-spécialiser et sur-apprendre
 - L'élagage des branches est souvent requis après construction pour simplifier la structure
- Ils permettent d'obtenir des prédictions interprétables

Caractéristiques des arbres de décision


- Ils sont construits de haut en bas
- Ils ont tendance à se sur-spécialiser et sur-apprendre
 - L'élagage des branches est souvent requis après construction pour simplifier la structure
- Ils permettent d'obtenir des prédictions interprétables
- Classificateurs à faible biais et forte variance, menant à de l'instabilité

Caractéristiques des arbres de décision


- Ils sont construits de haut en bas
- Ils ont tendance à se sur-spécialiser et sur-apprendre
 - L'élagage des branches est souvent requis après construction pour simplifier la structure
- Ils permettent d'obtenir des prédictions interprétables
- Classificateurs à faible biais et forte variance, menant à de l'instabilité
- (le concept de biais et de variance sera vu plus en détail dans de futurs cours.)

Réseaux de neurones

Neurone artificiel



- Inspiré des neurones biologiques
- Un neurone est une fonction affine dont la sortie est soumise à une fonction d'activation
- Discriminant linéaire





$f(a) = \frac{1}{1+e^{-a}} \Rightarrow y = \hat{P}(C_1|\mathbf{x})$: notre régression logistique!

Couche

- Une couche est un ensemble de neurones empilés verticalement
- Chaque neurone traite une entrée et produit une sortie
- Discriminant linéaire

$\mathbf{y} = f(\mathbf{W}\mathbf{x} + \mathbf{w}_0)$, avec $\mathbf{W} \in \mathbb{R}^{K \times R}$ maintenant une matrice de poids (une ligne par neurone)



Perceptron multicouche

- Plusieurs couches connectées forment un réseau de neurones artificiels profond

Perceptron multicouche

- Plusieurs couches connectées forment un réseau de neurones artificiels profond
- Trois types de couches: entrée, sortie, couches cachées


Perceptron multicouche

- Plusieurs couches connectées forment un réseau de neurones artificiels profond
- Trois types de couches: entrée, sortie, couches cachées
- Les sorties d'une couche sont les entrées de la suivante


Perceptron multicouche

- Plusieurs couches connectées forment un réseau de neurones artificiels profond
- Trois types de couches: entrée, sortie, couches cachées
- Les sorties d'une couche sont les entrées de la suivante
- Discriminant linéaire ou non selon la fonction d'activation

Perceptron multicouche



$$\mathbf{y} = f(\mathbf{W}_3 f(\mathbf{W}_2 f(\mathbf{W}_1 \mathbf{x})))$$



Fonction d'activation

- Fonction appliquée à la sortie d'un neurone artificiel
- Il existe plusieurs fonctions dont l'utilité dépend du contexte:

- ReLU:

$$f(x) = \max(x, 0)$$

- Sigmoid:


$$f(x) = \frac{1}{1 + e^{-x}}, \quad x \in [-\infty, \infty], \quad f(x) \in [0, 1]$$

- Tangente hyperbolique:

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}, \quad x \in [-\infty, \infty], \quad f(x) \in [-1, 1]$$

Dernière couche


- La fonction d'activation de la dernière couche d'un réseau de neurones artificiel permet d'adapter la sortie à la tâche à accomplir



Exemple: classification binaire

- La fonction Sigmoid transforme une sortie en une probabilité entre 0 et 1
- Utile pour la classification binaire
- Sortie comparée à 0,5 (50 %)


$$f(x) = \frac{1}{1 + e^{-x}}$$



Exemple: classification multiclasse

- La fonction Softmax transforme un vecteur de sorties en une distribution de probabilité discrète

$$f(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$




Exemple: classification multiclasse

- La fonction Softmax transforme un vecteur de sorties en une distribution de probabilité discrète

$$f(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

- En effet, nous avons $f(\mathbf{z})_i \in [0, 1]$ et $\sum_{i=1}^K f(\mathbf{z})_i = 1$




Exemple: classification multiclasse

- La fonction Softmax transforme un vecteur de sorties en une distribution de probabilité discrète

$$f(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$


- En effet, nous avons $f(\mathbf{z})_i \in [0, 1]$ et $\sum_{i=1}^K f(\mathbf{z})_i = 1$
- Très utile pour la classification multiclasse



Exemple: classification multiclasse

- La fonction Softmax transforme un vecteur de sorties en une distribution de probabilité discrète

$$f(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$



- En effet, nous avons $f(\mathbf{z})_i \in [0, 1]$ et $\sum_{i=1}^K f(\mathbf{z})_i = 1$
- Très utile pour la classification multiclasse
- La classe avec la plus haute probabilité est choisie au moment du test

$$\hat{y} = \arg \max_i f(\mathbf{z})_i \leftarrow \text{classe choisie au moment du test}$$

Importance de la non-linéarité

- La fonction identité utilisée comme activation des couches cachées agit comme un discriminant linéaire

Importance de la non-linéarité

- La fonction identité utilisée comme activation des couches cachées agit comme un discriminant linéaire
- Les fonctions Sigmoides, Tanh, ReLU, etc. permettent de traiter des données non linéairement séparables

Importance de la non-linéarité

- La fonction identité utilisée comme activation des couches cachées agit comme un discriminant linéaire
- Les fonctions Sigmoides, Tanh, ReLU, etc. permettent de traiter des données non linéairement séparables
- Ces dernières fonctions apportent de la non-linéarité aux réseaux

Importance de la non-linéarité

- La fonction identité utilisée comme activation des couches cachées agit comme un discriminant linéaire
- Les fonctions Sigmoides, Tanh, ReLU, etc. permettent de traiter des données non linéairement séparables
- Ces dernières fonctions apportent de la non-linéarité aux réseaux
- La non-linéarité permet aux réseaux d'apprendre


Importance de la non-linéarité

- La fonction identité utilisée comme activation des couches cachées agit comme un discriminant linéaire
- Les fonctions Sigmoides, Tanh, ReLU, etc. permettent de traiter des données non linéairement séparables
- Ces dernières fonctions apportent de la non-linéarité aux réseaux
- La non-linéarité permet aux réseaux d'apprendre
- Sans non-linéarité, un réseau est un filtre linéaire



Exemple: classification de données avec un perceptron

- Distribution des données à classer
 - Données 2D
 - Deux classes bien séparées
 - Frontière non linéairement séparable




Exemple: réseau linéaire

Essayez-le vous-même sur [Google Colab](#)

- Une couche cachée: 4 neurones
- Fonction d'activation de la couche cachée: identité
- Le réseau sépare mal les données.


$$f(x) = x$$



Exemple: réseau non linéaire

Essayez-le vous-même sur [Google Colab](#)

- Une couche cachée: 4 neurones
- Fonction d'activation de la couche cachée: ReLU
- La non-linéarité de ReLU permet au réseau de bien séparer les données.



$$f(x) = \max(0, x)$$

Quelle méthode d'apprentissage utiliser?

- Connectez-vous avec votre prénom, et votre matricule comme nom de famille.
- Quelle méthode d'apprentissage convient-elle pour les exemples suivants
 - (A) Classification (B) Régression (C) Regroupement (D) Réduction de dimensionnalité
- Nous avons des données sur les habitudes des gens et voulons voir en quoi elles se ressemblent?

Quelle méthode d'apprentissage utiliser?

- Connectez-vous avec votre prénom, et votre matricule comme nom de famille.
- Quelle méthode d'apprentissage convient-elle pour les exemples suivants
 - (A) Classification (B) Régression (C) Regroupement (D) Réduction de dimensionnalité
- Nous avons des données sur les habitudes des gens et voulons voir en quoi elles se ressemblent?
- Nous voulons prévoir la météo (pluie, soleil, nuages) pour demain

Quelle méthode d'apprentissage utiliser?

- Connectez-vous avec votre prénom, et votre matricule comme nom de famille.
- Quelle méthode d'apprentissage convient-elle pour les exemples suivants
 - (A) Classification (B) Régression (C) Regroupement (D) Réduction de dimensionnalité
- Nous avons des données sur les habitudes des gens et voulons voir en quoi elles se ressemblent?
- Nous voulons prévoir la météo (pluie, soleil, nuages) pour demain
- Nous voulons prédire la température de demain

Quelle méthode d'apprentissage utiliser?

- Connectez-vous avec votre prénom, et votre matricule comme nom de famille.
- Quelle méthode d'apprentissage convient-elle pour les exemples suivants
 - (A) Classification (B) Régression (C) Regroupement (D) Réduction de dimensionnalité
- Nous avons des données sur les habitudes des gens et voulons voir en quoi elles se ressemblent?
- Nous voulons prévoir la météo (pluie, soleil, nuages) pour demain
- Nous voulons prédire la température de demain
- Nous avons des images de chats et de chiens, mais voulons seulement l'ordinal dans un tableau.

Quelle méthode d'apprentissage utiliser?

- Connectez-vous avec votre prénom, et votre matricule comme nom de famille.
- Quelle méthode d'apprentissage convient-elle pour les exemples suivants
 - (A) Classification (B) Régression (C) Regroupement (D) Réduction de dimensionnalité
- Nous avons des données sur les habitudes des gens et voulons voir en quoi elles se ressemblent?
- Nous voulons prévoir la météo (pluie, soleil, nuages) pour demain
- Nous voulons prédire la température de demain
- Nous avons des images de chats et de chiens, mais voulons seulement l'ordinal dans un tableau.
- Parfois la solution dépend des données, d'autres fois du résultat souhaité

Références utilisées pour construire ce cours

- Cours de science des données de Zico Kolter.
- MOOC IVADO
- (Witten *et al.*, 2016)

- Lawrence Cayton et al. Algorithms for manifold learning. *Univ. of California at San Diego Tech. Rep*, 12(1-17):1, 2005.
- Ailsa H Land and Alison G Doig. An automatic method for solving discrete programming problems. In *50 Years of Integer Programming 1958-2008: From the Early Years to the State-of-the-Art*, pages 105–132. Springer, 2009.
- Ian H. Witten, Eibe Frank, Mark A. Hall, and Christopher J. Pal. *Data Mining: Practical Machine Learning Tools and Techniques*. Morgan Kaufmann, Amsterdam, 4th edition, 2016.