

Apprentissage pour la science des données

Cours 3: Biais, variance, sur- et sous-apprentissage

Glen Berseth

Université de Montréal and Mila Québec AI Institute

September 17, 2026



Université  de Montréal



Mila

CIFAR


Sur- et sous-apprentissage

Que signifie « bien performer » pour un modèle ?

- Performance :
 - Si nous entraînons un modèle pour prédire $p(\text{chat ou chien} \mid x, \theta)$
- Il devrait bien modéliser cette probabilité
- Nous pouvons évaluer cela via l'ensemble de validation

Que signifie « bien performer » pour un modèle ?


- Performance :
 - Si nous entraînons un modèle pour prédire $p(\text{chat ou chien} \mid x, \theta)$
- Il devrait bien modéliser cette probabilité
- Nous pouvons évaluer cela via l'ensemble de validation
- Ce concept général est la généralisation
 - Découvrir les meilleurs facteurs pour déterminer si une image contient un chat ou un chien
 - Bons exemples : présence de moustaches, iris vertical, griffes ou non
 - Mauvais exemple : le pixel 20,47 est gris
- Nous étudions cela via le biais et la variance d'un modèle



- Exemple de validation croisée (cross-validation)

Apprendre le lien entrée-sortie

- $\hat{y}_i \leftarrow f(\mathbf{x}_i \mid \theta)$ est une fonction « simple » décrivant la relation entre x et y
- ϵ_i reflète des variations dont la source nous est inconnue, faute de features suffisantes ou parce que la fonction est trop complexe — exemple : un lancer de pièce



Biais

- Nous essayons d'entraîner plusieurs modèles simples $f(x_i \mid \hat{\theta})$.

Biais

- Nous essayons d'entraîner plusieurs modèles simples $f(x_i | \hat{\theta})$.
- Nous disposons de collections de données bruitées d'un signal $f(x_i)$.

Biais


- Nous essayons d'entraîner plusieurs modèles simples $f(x_i | \hat{\theta})$.
- Nous disposons de collections de données bruitées d'un signal $f(x_i)$.
- Peu importe la collection ; le modèle $f(x_i | \hat{\theta})$ produira des erreurs systématiques.

Biais

- Nous essayons d'entraîner plusieurs modèles simples $f(x_i | \hat{\theta})$.
- Nous disposons de collections de données bruitées d'un signal $f(x_i)$.
- Peu importe la collection ; le modèle $f(x_i | \hat{\theta})$ produira des erreurs systématiques.
- La moyenne des modèles $f(x_i | \hat{\theta})$ ne reproduit pas bien $f(x_i) \rightarrow$ biais élevé.

Biais

- Nous essayons d'entraîner plusieurs modèles simples $f(x_i | \hat{\theta})$.
- Nous disposons de collections de données bruitées d'un signal $f(x_i)$.
- Peu importe la collection ; le modèle $f(x_i | \hat{\theta})$ produira des erreurs systématiques.
- La moyenne des modèles $f(x_i | \hat{\theta})$ ne reproduit pas bien $f(x_i) \rightarrow$ biais élevé.
- Il y a peu de différences entre chaque modèle $\rightarrow$ petite variance



Variance

- Nous essayons d'entraîner un modèle plus complexe $f(x_i | \hat{\theta})$.

Variance


- Nous essayons d'entraîner un modèle plus complexe $f(x_i | \hat{\theta})$.
- Sur les données bruitées/noisy d'un signal $f(x_i)$.

Variance

- Nous essayons d'entraîner un modèle plus complexe $f(x_i | \hat{\theta})$.
- Sur les données bruitées/noisy d'un signal $f(x_i)$.
- Des ensemble de données différents produisent des ajustements différents, avec des oscillations irréalistes.

Variance

- Nous essayons d'entraîner un modèle plus complexe $f(x_i | \hat{\theta})$.
- Sur les données bruitées/noisy d'un signal $f(x_i)$.
- Des ensemble de données différents produisent des ajustements différents, avec des oscillations irréalistes.
- Il y a beaucoup de variations entre chaque modèle $\rightarrow$ variance élevée.



Le compromis biais-variance

Supposons que nous utilisions M collections différentes de N données chacune :

$$\{\mathbf{x}_i^j, y_i^j\}, \quad j = 1, \dots, M$$

générées à partir d'une fonction bruitée

$$y_i^j = f(\mathbf{x}_i^j) + e_i^j, \quad i = 1, \dots, N,$$

où $f(\mathbf{x})$ est une fonction inconnue/unknown et e est le bruit de mesure.

Le compromis biais-variance

Supposons que nous utilisions M collections différentes de N données chacune :

$$\{\mathbf{x}_i^j, y_i^j\}, \quad j = 1, \dots, M$$

générées à partir d'une fonction bruitée

$$y_i^j = f(\mathbf{x}_i^j) + e_i^j, \quad i = 1, \dots, N,$$

où $f(\mathbf{x})$ est une fonction inconnue/unknown et e est le bruit de mesure.

- Les valeurs de $\mathbf{x}_i$ sont les mêmes pour chaque jeu de données (seulement des sous-ensembles).
- Séparons les données en M ensembles d'entraînement et M ensembles de validation.

Le compromis biais-variance

Pour chaque ensemble de N données, nous entraînons un modèle $f(\mathbf{x} \mid \hat{\theta}_j)$.
La moyenne des modèles est

$$m(\mathbf{x}) = \frac{1}{M} \sum_{j=1}^M f(\mathbf{x} \mid \hat{\theta}_j)$$

Le biais est calculé avec la fonction:

$$b(\mathbf{x}) = m(\mathbf{x}) - f(\mathbf{x})$$

sur les données de validation. Idéalement, il devrait être nul partout.

Le compromis biais-variance

Les mesures suivantes sont calculées à partir du biais et des données de validation.

- $\text{Biais}^2(f(\mathbf{x} \mid \hat{\theta}_j)) :$

$$\frac{1}{N} \sum_{i=1}^N [b(\mathbf{x}_i)]^2$$

- $\text{Variance}(f(\mathbf{x} \mid \hat{\theta}_j)) :$

$$\frac{1}{NM} \sum_{i=1}^N \sum_{j=1}^M [m(\mathbf{x}_i) - f(\mathbf{x}_i \mid \hat{\theta}_j)]^2$$

- $\text{MSE}(f(\mathbf{x} \mid \hat{\theta}_j)) :$

$$\frac{1}{MN} \sum_{i=1}^N \sum_{j=1}^M [y_i - f(\mathbf{x}_i \mid \hat{\theta}_j)]^2$$

Le compromis biais-variance


La relation suivante entre la MSE (erreur quadratique moyenne) et les autres mesures peut être démontrée :

$$\text{MSE}(f(\mathbf{x} \mid \hat{\theta}_j)) = \text{Biais}^2(f(\mathbf{x} \mid \hat{\theta}_j)) + \text{Variance}(f(\mathbf{x} \mid \hat{\theta}_j)) + \sigma^2$$


Avec σ^2 la variance du bruit.

Pour en savoir plus, voir [ce lien](#).


Exemples de distributions de biais et de variance




Biais et variance élevés



Biais élevé, variance faible




Biais faible, variance élevée




Biais et variance faibles

- Pire/worst scénario possible
- Performance d'un joueur en début d'entraînement


Exemples de distributions de biais et de variance




Biais et variance élevés



Biais élevé, variance faible



Biais faible, variance élevée




Biais et variance faibles


- Pire/worst scénario possible
- Performance d'un joueur en début d'entraînement
- Meilleur scénario
- Performance d'un joueur bien entraîné.
- Faible/low biais et faible variance

Exemples de polynômes de degrés différents

- Polynômes de faible degré :
 - biais élevé
 - variance faible
 - les modèles sont très différents du signal
- Polynômes de degré élevé :
 - biais faible
 - variance élevée (proche de $x_i = 0$ et $x_i = 10$)
 - les modèles interpolent les données




Exemples de polynômes de degrés différents



- Cette figure montre comment l'erreur quadratique moyenne varie avec le degré du polynôme d'approximation pour $f(x \mid \hat{\theta})$.
- La MSE est dominée par le biais du modèle **trop simple** ou par la variance du **modèle trop complexe**.
- Nous utilisons cette courbe pour trouver le meilleur modèle pour analyser nos données.

$$\hat{y}_i \leftarrow f(\mathbf{x}_i \mid \theta)$$

Exemples de polynômes de degrés différents




- Cette figure montre comment l'erreur quadratique moyenne varie avec le degré du polynôme d'approximation pour $f(x \mid \hat{\theta})$.
- La MSE est dominée par le biais du modèle **trop simple** ou par la variance du **modèle trop complexe**.
- Nous utilisons cette courbe pour trouver le meilleur modèle pour analyser nos données.

$$\hat{y}_i \leftarrow f(\mathbf{x}_i \mid \theta)$$

- Quel est le meilleur degré ici ?

Erreur selon le compromis biais-variance

- Un autre modèle approximatif $f(\mathbf{x}_i \mid \hat{\theta}_j)$ aurait pu être utilisé, mais les résultats auraient été similaires.
- La figure suivante montre le comportement général.
- Le compromis biais-variance se révèle sur un ensemble de validation, pas sur l'ensemble d'entraînement !
 - $MSE_{validation}$, $MSE_{entraînement}$



Problèmes de biais et de variance

- **Biais**

- Erreur systématique non nulle
- Modèles trop simples (M différent)
- Révèle le sous-apprentissage (underfitting)
- Mesure: moyenne des prédictions d'un modèle

Problèmes de biais et de variance

- **Biais**

- Erreur systématique non nulle
- Modèles trop simples (M différent)
- Révèle le sous-apprentissage (underfitting)
- Mesure: moyenne des prédictions d'un modèle

- **Variance**


- Bons résultats en moyenne, mais trop variables en pratique
- Modèles trop complexes
- Révèle le surapprentissage (overfitting)
- Mesure: moyenne des prédictions d'un modèle

Sur- et sous-apprentissage

- Un modèle :
 - Apprend les détails et le bruit des données d'entraînement.
 - Donne de bons résultats sur les données d'entraînement, mais de mauvais résultats sur les données de validation et de test.



Sur- et sous-apprentissage

- Un modèle :
 - Apprend les détails et le bruit des données d'entraînement.
 - Donne de bons résultats sur les données d'entraînement, mais de mauvais résultats sur les données de validation et de test.
 - Mémorise les données au lieu d'apprendre et de comprendre leur tendance sous-jacente/trend.
 - Est incapable de généraliser sur de nouvelles données.
 - Faible biais mais forte variance.



Le problème de variance

- Le surapprentissage (overfitting) est parfois appelé le problème de variance.
- Un petit changement dans les données (point vert) affecte complètement le modèle ci-dessous.



Causes

- Le modèle est trop complexe.




Causes

- Le modèle est trop complexe.
- Le modèle a une variance élevée.




Causes

- Le modèle est trop complexe.
- Le modèle a une variance élevée.
- L'ensemble d'entraînement n'est pas assez grand.




Causes

- Le modèle est trop complexe.
- Le modèle a une variance élevée.
- L'ensemble d'entraînement n'est pas assez grand.
- Entraîné trop longtemps !





Qu'est-ce que le sous-apprentissage ?

- Modèle trop simple
 - Ne performe bien ni sur les données d'entraînement ni sur celles de validation.
 - Ne peut pas comprendre la relation entre les exemples d'entrée et les valeurs cibles.
- Faible variance mais fort biais
- Le modèle commet systématiquement des erreurs similaires aux mêmes endroits.



Faible variance, mais fort biais

- Le motif (pattern) ci-dessous varie peu quand le point vert est déplacé.
- Le modèle commet systématiquement des erreurs similaires aux différents endroits ; il est donc biaisé.



Causes

- Le modèle est trop simple.
- Le modèle a un biais élevé.




Causes

- Le modèle est trop simple.
- Le modèle a un biais élevé.
- L'ensemble d'entraînement (dataset) n'est pas assez grand.




Causes

- Le modèle est trop simple.
- Le modèle a un biais élevé.
- L'ensemble d'entraînement (dataset) n'est pas assez grand.
- Pas entraîné assez longtemps !




Le compromis biais-variance



- Sous-apprentissage


- Surapprentissage

Le compromis biais-variance



- Sous-apprentissage
 - Il existe un point optimal de complexité du modèle où les courbes d'erreur de biais et de variance se croisent, et où l'erreur est minimale.
- Surapprentissage


Exemples en régression



$$\hat{y}_i = \beta_0 + \beta_1 x_i$$

- Sous-apprentissage ; modèle trop simple pour reproduire la distribution des données.

Exemples en régression



$$\hat{y}_i = \beta_0 + \beta_1 x_i$$


- Sous-apprentissage ; modèle trop simple pour reproduire la distribution des données.



$$\hat{y}_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2$$

- Bon apprentissage : bon compromis biais-variance

Exemples en régression




$$\hat{y}_i = \beta_0 + \beta_1 x_i$$

- Sous-apprentissage ; modèle trop simple pour reproduire la distribution des données.



$$\hat{y}_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2$$


- Bon apprentissage : bon compromis biais-variance



$$\hat{y}_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3 + \beta_4 x_i^4$$

- Surapprentissage ; modèle si flexible qu'il reproduit la distribution des données bruitées.


Exemples en classification



Under-fitting


- Sous-apprentissage ;
modèle trop simple
pour reproduire la
distribution des
données.

Exemples en classification



Under-fitting


- Sous-apprentissage ;
modèle trop simple
pour reproduire la
distribution des
données.



Appropriate-fitting


- Bon apprentissage :
bon compromis
biais-variance

Exemples en classification




Under-fitting

- Sous-apprentissage ; modèle trop simple pour reproduire la distribution des données.



Appropriate-fitting

- Bon apprentissage : bon compromis biais-variance



Over-fitting

- Surapprentissage ; modèle si flexible qu'il reproduit la distribution des données bruitées.

Solutions au sous-apprentissage

- Ajouter des features
- Ajouter des interactions entre features
- Utiliser un modèle plus complexe
- Changer de modèle

Solutions au surapprentissage


- Retirer des features
- Réduction de dimensionnalité
- Régularisation

Solutions au surapprentissage

- Retirer des features
- Réduction de dimensionnalité
- Régularisation
- Ajouter des données
- Nettoyer les données (valeurs aberrantes)
- Simplifier le modèle
- Modifier le type de modèle

Stratégie utile pour trouver le modèle de complexité optimale

- Plusieurs modèles sont entraînés avec les mêmes données d'entraînement.
- Leur performance en généralisation est mesurée avec les mêmes données de validation.
- Le modèle le plus performant est celui de complexité optimale.




Sondage en classe : compromis biais-variance

- Connectez-vous avec votre prénom, et votre matricule comme nom de famille.

Q1 : Meilleur degré de polynôme pour ce modèle ?

(A) 2 (B) 4 (C) 6 (D) 10



Sondage en classe : compromis biais-variance



- Connectez-vous avec votre prénom, et votre matricule comme nom de famille.

Q1 : Meilleur degré de polynôme pour ce modèle ?

(A) 2 (B) 4 (C) 6 (D) 10


Q2 : Étiquettes retirées — quelle courbe est l'ensemble de validation ?

(A) grise (B) magenta (C) les deux (D) indéterminable



Sondage en classe : quel ajustement est le quel ?


(A)




(B)



(C)




(D)



- **Q1** : Quel graphique montre du sous-apprentissage ?

Sondage en classe : quel ajustement est le quel ?


(A)




(B)



(C)




(D)




- **Q1** : Quel graphique montre du sous-apprentissage ?
- **Q2** : Quel graphique montre du surapprentissage ?

Sondage en classe : quel ajustement est le quel ?


(A)




(B)



(C)



(D)



- **Q1** : Quel graphique montre du sous-apprentissage ?
- **Q2** : Quel graphique montre du surapprentissage ?
- **Q3** : Quel graphique est bien ajusté, malgré des données bruitées ?

Sources

- MOOC d'IVADO