

Apprentissage pour la science des données

Cours 8 : Ingénierie des caractéristiques

Glen Berseth

Université de Montréal et Institut québécois d'intelligence artificielle (Mila)

September 23, 2026



Université  de Montréal



Mila

CIFAR

Plan

Standardisation

Génération de jeux de données équilibrés

Augmentation de données de type image

Augmentation de données tabulaires

Dérive des données : une situation courante (common)

Standardisation

- La normalisation (ou normalisation min-max) ramène toutes les valeurs dans un intervalle fixe entre 0 et 1.

$$X_{norm} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

- Cette transformation garde la distribution de la caractéristique (feature).
- Mais comme les écarts-types diminuent, l'effet des valeurs aberrantes (outliers) augmente. Il faut donc traiter les valeurs aberrantes avant la normalisation.

Standardisation

- Exemple : mise à l'échelle min-max (min-max scaling)
- Elle utilise la formule suivante pour chaque valeur (X) du jeu de données :
- $X_{\min}$ est la valeur minimale de la caractéristique.
- $X_{\max}$ est la valeur maximale de la caractéristique.

$$X_{scaled} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

```
data = pd.DataFrame({'value':[2,45, -23, 85, 28, 2, 35, -12]})  
  
data['normalized'] = (data['value'] - data['value'].min()) /  
(data['value'].max() - data['value'].min())
```

	value	normalized
0	2	0.23
1	45	0.63
2	-23	0.00
3	85	1.00
4	28	0.47
5	2	0.23
6	35	0.54
7	-12	0.10

Standardisation

- La standardisation (ou normalisation par score Z (z-score)) met les valeurs à l'échelle en tenant compte de l'écart-type.
- Dans la formule de standardisation suivante, la moyenne est notée μ et l'écart-type est noté σ .

$$z = \frac{x - \mu}{\sigma}$$

- Si l'écart-type des caractéristiques est différent, leur étendue sera aussi différente. Cela réduit l'effet des valeurs aberrantes dans les caractéristiques.

Standardisation

- Exemple :


```
data = pd.DataFrame({'value':[2,45, -23, 85, 28, 2, 35, -12]})  
  
data['standardized'] = (data['value'] - data['value'].mean()) /  
data['value'].std()
```

	value	standardized
0	2	-0.52
1	45	0.70
2	-23	-1.23
3	85	1.84
4	28	0.22
5	2	-0.52
6	35	0.42
7	-12	-0.92

- Problèmes possibles :
 - Et si l'écart-type (stdev) est petit ou grand?
 - Nettoyer les données d'abord

Blanchiment des données

- Méthode basée sur l'analyse en composantes principales (ACP, PCA).
- Elle centre la moyenne des données x sur l'origine, supprime les covariances et rend la variance unitaire.
- Données originales x
- Centrage
- Rotation des axes principaux
- Données blanchies (whitened) z
- Normalisation et rotation inverse



Valeurs aberrantes

- Des valeurs aberrantes peuvent être introduites dans la population pendant la collecte des données
 - Quel nombre est la valeur aberrante potentielle ?

Players	Scores
Player1	500
Player2	350
Player3	10
Player4	300
Player5	450

- Erreur ?
- Différence ?

Traitement des valeurs aberrantes

- Origines courantes des valeurs aberrantes :

- Erreurs d'instrument
- Bruit naturel dans les données
- Mauvaises entrées dans un fichier Excel
- Données mal étiquetées
- Nouveau phénomène !



Clipart Of.com
#439431

- Pourquoi les valeurs aberrantes sont-elles un problème ?

- Elles peuvent causer de grandes pertes (losses)
- Beaucoup de modèles d'AA supposent une zone de données

Détection des valeurs aberrantes

- Valeur aberrante : un objet de données qui s'écarte beaucoup des objets normaux, comme s'il était généré par un autre mécanisme

Détection des valeurs aberrantes

- Valeur aberrante : un objet de données qui s'écarte beaucoup des objets normaux, comme s'il était généré par un autre mécanisme
- Ex. : achat inhabituel par carte de crédit ; sports : M. Jordan, W. Gretzky, ...
 - Les valeurs aberrantes sont différentes des données bruitées.
 - Le bruit est une erreur aléatoire ou une variance dans une variable mesurée
 - Le bruit doit être retiré avant la détection des valeurs aberrantes
 - Intéressantes : les valeurs aberrantes violent le mécanisme des données normales
 - Détection de valeurs aberrantes ou détection de nouveauté (novelty detection) : au début, valeur aberrante ; plus tard, intégrée au modèle

Détection des valeurs aberrantes

- Valeur aberrante : un objet de données qui s'écarte beaucoup des objets normaux, comme s'il était généré par un autre mécanisme
- Ex. : achat inhabituel par carte de crédit ; sports : M. Jordan, W. Gretzky, ...
 - Les valeurs aberrantes sont différentes des données bruitées.
 - Le bruit est une erreur aléatoire ou une variance dans une variable mesurée
 - Le bruit doit être retiré avant la détection des valeurs aberrantes
 - Intéressantes : les valeurs aberrantes violent le mécanisme des données normales
 - Détection de valeurs aberrantes ou détection de nouveauté (novelty detection) : au début, valeur aberrante ; plus tard, intégrée au modèle
- Applications :
 - Détection de fraude par carte de crédit
 - Détection de fraude en télécommunications
 - Segmentation de la clientèle
 - Analyse médicale

Types de valeurs aberrantes

- 3 types : globales, contextuelles ou groupées.
- Valeur aberrante **globale** :
 - La valeur s'écarte beaucoup du reste des données.
 - Exemple : détection d'intrusion dans un réseau informatique.
 - Problème : trouver une mesure d'écart adaptée.
- Valeur aberrante **contextuelle** :
 - La valeur s'écarte beaucoup dans un contexte particulier
 - Exemple : 40 degrés Celsius à Montréal en hiver.
 - Les attributs des données doivent être divisés en deux groupes :
 - Attributs contextuels, p. ex. heures, lieux,...
 - Attributs comportementaux : valeurs mesurées pouvant être aberrantes.

Types de valeurs aberrantes

- 3 types : globales, contextuelles ou groupées.
- Valeurs aberrantes **collectives** :
 - Un sous-ensemble des données s'écarte collectivement du jeu de données, même si chaque objet pris seul n'est pas aberrant.
 - Applications : p. ex. détection d'intrusion, quand des ordinateurs s'envoient sans cesse des paquets de déni de service
 - Détection des valeurs aberrantes collectives
 - Considérer le comportement de chaque objet, mais aussi celui de groupes d'objets.
 - Il faut connaître la relation entre les objets de données, p. ex. une mesure de distance ou de similarité.

Exemple de traitement de valeurs aberrantes en 2D




- Génération de données idéales



- Ajout de valeurs aberrantes


Exemple de traitement de valeurs aberrantes en 2D

Isolation Forest



- Valeurs restantes après l'élimination des valeurs aberrantes.

Local Outlier Factor



Trouver les valeurs aberrantes

- Outils de visualisation ou méthodes statistiques
 - Boîte à moustaches (box plot)
 - Un nuage de points
 - Score Z
 - Score IQR
- Détection avancée d'anomalies (cours de sélection de caractéristiques)

Trouver les valeurs aberrantes : boîte à moustaches

- Boîte à moustaches


Trouver les valeurs aberrantes : boîte à moustaches

- Boîte à moustaches
- Gauche de la boîte (Q1) : cette ligne marque le premier quartile. 25 % des points sont sous cette valeur.

Trouver les valeurs aberrantes : boîte à moustaches

- Boîte à moustaches
- Gauche de la boîte (Q1) : cette ligne marque le premier quartile. 25 % des points sont sous cette valeur.
- Ligne du milieu (médiane ou Q2) : c'est la médiane du jeu de données. Elle coupe les données en deux : 50 % des points sont en dessous, et 50 % au-dessus.

```
import seaborn as sns
sns.boxplot(x=boston_df['DIS'])
```



Boxplot — Distance to Employment Center

Trouver les valeurs aberrantes : boîte à moustaches

- Droite de la boîte (Q_3) : cette ligne marque le troisième quartile. 75 % des points sont sous cette valeur.


Trouver les valeurs aberrantes : boîte à moustaches

- Droite de la boîte (Q_3) : cette ligne marque le troisième quartile. 75 % des points sont sous cette valeur.
- Moustache droite/supérieure (whisker) : du troisième quartile (Q_3) au plus grand point dans les limites de Q_3 .

Trouver les valeurs aberrantes : boîte à moustaches


- Droite de la boîte (Q3) : cette ligne marque le troisième quartile. 75 % des points sont sous cette valeur.
- Moustache droite/supérieure (whisker) : du troisième quartile (Q3) au plus grand point dans les limites de Q3.
- Moustache gauche/inférieure : du premier quartile (Q1) au plus petit point dans les limites de Q1.
- <https://www.jmp.com/en/statistics-knowledge-portal/exploratory-data-analysis/box-plot>

```
import seaborn as sns
sns.boxplot(x=boston_df['DIS'])
```



Boxplot — Distance to Employment Center

Trouver les valeurs aberrantes : boîte à moustaches




Boxplot — Distance to Employment Center

- Trois points entre 10 et 12 -> aberrants, car ils ne sont pas inclus dans la boîte des autres observations, c.-à-d. loin des quartiles.
- Ici : valeur aberrante univariée, c.-à-d. seule la colonne DIS est utilisée pour chercher les valeurs aberrantes.
- Une analyse multivariée des valeurs aberrantes est aussi possible. Et avec une boîte à moustaches ? Cela dépend : une variable catégorielle peut être combinée à toute variable continue pour une analyse multivariée.

Valeurs aberrantes : boîtes à moustaches


- Boîte à moustaches avec regroupement imbriqué selon deux variables catégorielles
- `ax = sns.boxplot(x="day", y="total_bill", hue="smoker", ... data=tips, palette="Set3")`



Trouver les valeurs aberrantes : nuage de points

- Nuage de points (scatter plot) de deux variables du jeu de données sur le logement.

```
fig, ax = plt.subplots(figsize=(16,8))
ax.scatter(boston_df['INDUS'], boston_df['TAX'])
ax.set_xlabel('Proportion of non-retail business acres per town')
ax.set_ylabel('Full-value property-tax rate per $10,000')
plt.show()
```



Scatter plot — Proportion of non-retail business acres per town v/s Full value property tax

Trouver les valeurs aberrantes : écart-type

- Mesure pour identifier les valeurs aberrantes : l'écart-type
- Si la distance d'une valeur à la moyenne dépasse $x \times \text{écart-type}$, elle peut être considérée comme aberrante. Quelle valeur choisir pour x ?
- En général, une valeur entre 2 et 4 semble pratique.

$$\sigma = \sqrt{\frac{\sum (x_i - \mu)^2}{N}}$$

σ = écart-type de la population, N = taille de la population, x_i = chaque valeur de la population, μ = moyenne de la population

```
#Dropping the outlier rows with standard deviation
```

```
factor = 3
```

```
upper_lim = data['column'].mean () + data['column'].std () * factor
```

```
lower_lim = data['column'].mean () - data['column'].std () * factor
```

```
data = data[(data['column'] < upper_lim) & (data['column'] >  
lower_lim)]
```

Trouver les valeurs aberrantes

- Score Z
- Le score Z est le nombre signé d'écarts-types dont la valeur d'une observation ou d'un point de données dépasse la moyenne de ce qui est observé ou mesuré.
- Définition de Wikipédia
- L'intuition du score Z est de décrire chaque point de données par sa relation avec l'écart-type et la moyenne du groupe de points. Le score Z donne la distribution des données avec une moyenne de 0 et un écart-type de 1, c.-à-d. la loi normale.

Trouver les valeurs aberrantes : score Z

- Définition de Wikipédia :
 - Le score Z est le nombre signé d'écarts-types dont la valeur d'une observation ou d'un point de données dépasse la moyenne de ce qui est observé ou mesuré.
- Remettre à l'échelle et centrer les données
- Valeurs aberrantes : points de données trop loin de zéro.
- Dans la plupart des cas, un seuil de 3 ou -3 est utilisé

```
from scipy import stats
import numpy as np

z = np.abs(stats.zscore(boston_df))
print(z)
```

```
[[0.41771335 0.28482986 1.2879095 ... 1.45900038 0.44105193 1.0755623 ]
 [0.41526932 0.48772236 0.59338101 ... 0.30309415 0.44105193 0.49243937]
 [0.41527165 0.48772236 0.59338101 ... 0.30309415 0.39642699 1.2087274 ]
 ...
 [0.41137448 0.48772236 0.11573841 ... 1.17646583 0.44105193 0.98304761]
 [0.40568883 0.48772236 0.11573841 ... 1.17646583 0.4032249 0.86530163]
 [0.41292893 0.48772236 0.11573841 ... 1.17646583 0.44105193 0.66905833]]
```

Z-score of Boston Housing Data

Trouver les valeurs aberrantes

- Avec le code et la sortie ci-dessus, il est difficile de dire quel point est aberrant.
L'étape suivante : définir un seuil qui identifie les valeurs aberrantes.

```
threshold = 3  
print(np.where(z > 3))
```

```
(array([ 55,  56,  57, 102, 141, 142, 152, 154, 155, 160, 162, 163, 199,  
       200, 201, 202, 203, 204, 208, 209, 210, 211, 212, 216, 218, 219,  
       220, 221, 222, 225, 234, 236, 256, 257, 262, 269, 273, 274, 276,  
       277, 282, 283, 284, 347, 351, 352, 353, 353, 354, 355, 356,  
       357, 358, 363, 364, 364, 365, 367, 369, 370, 372, 373, 374, 374,  
       380, 398, 404, 405, 406, 410, 410, 411, 412, 412, 414, 414, 415,  
       416, 418, 418, 419, 423, 424, 425, 426, 427, 427, 429, 431, 436,  
       437, 438, 445, 450, 454, 455, 456, 457, 466], dtype=int64), array([ 1,  1,  1, 11, 12,  3,  3,  
 3,  3,  3,  3,  3,  1,  1,  1,  1,  1,  1,  
 1,  3,  3,  3,  3,  3,  3,  3,  3,  3,  3,  3,  5,  3,  3,  1,  5,  
 5,  3,  3,  3,  3,  3,  3,  1,  3,  1,  1,  7,  7,  1,  7,  7,  7,  
 3,  3,  3,  3,  3,  5,  5,  5,  3,  3,  3, 12,  5, 12,  0,  0,  0,  
 0,  5,  0, 11, 11, 11, 12,  0, 12, 11, 11,  0, 11, 11, 11, 11, 11,  
 11,  0, 11, 11, 11, 11, 11, 11, 11, 11, 11, 11, 11],  
dtype=int64))
```

List of row
indices

List of
column
indices

Data points where Z-scores is greater than 3

Trouver les valeurs aberrantes

- L'écart interquartile (IQR, interquartile range) :
 - Aussi appelé « midspread » ou « 50 % du milieu », ou techniquement H-spread, c'est une mesure de dispersion statistique, égale à la différence entre les 75^e et 25^e centiles, ou entre les quartiles supérieur et inférieur ;
 - $IQR = Q_3 - Q_1$.
- Remarque : c'est une mesure de dispersion comme l'écart-type ou la variance, mais beaucoup plus robuste aux valeurs aberrantes.

Trouver les valeurs aberrantes

- Les boîtes à moustaches utilisent l'IQR, qui peut aussi produire la liste des valeurs aberrantes, comme le score Z. La première étape : calculer l'IQR.

```
Q1 = boston_df_o1.quantile(0.25)
Q3 = boston_df_o1.quantile(0.75)
IQR = Q3 - Q1
print(IQR)
```

```
CRIM      3.565378
ZN        12.500000
INDUS     12.910000
CHAS       0.000000
NOX        0.175000
RM         0.738000
AGE        49.050000
DIS         3.088250
RAD        20.000000
TAX       387.000000
PTRATIO    2.800000
B          20.847500
LSTAT      10.005000
dtype: float64
```

IQR for each column

Trouver les valeurs aberrantes

- Une valeur False signifie que le point de données est valide, alors que True indique une valeur aberrante.

```
print(boston_df_o1 < (Q1 - 1.5 * IQR)) |(boston_df_o1 > (Q3 + 1.5 * IQR))
```

4	False	False	False	False	False	False	False	False	False	False	False	False	False
5	False	False	False	False	False	False	False	False	False	False	False	False	False
6	False	False	False	False	False	False	False	False	False	False	False	False	False
7	False	False	False	False	False	False	False	False	False	False	False	False	False
8	False	False	False	False	False	False	False	False	False	False	False	False	False
9	False	False	False	False	False	False	False	False	False	False	False	False	False
10	False	False	False	False	False	False	False	False	False	False	False	False	False
11	False	False	False	False	False	False	False	False	False	False	False	False	False
12	False	False	False	False	False	False	False	False	False	False	False	False	False
13	False	False	False	False	False	False	False	False	False	False	False	False	False
14	False	False	False	False	False	False	False	False	False	False	False	False	False
15	False	False	False	False	False	False	False	False	False	False	False	False	False
16	False	False	False	False	False	False	False	False	False	False	False	False	False
17	False	False	False	False	False	False	False	False	False	False	False	False	False
18	False	False	False	False	False	False	False	False	False	False	True	False	False
19	False	False	False	False	False	False	False	False	False	False	False	False	False
20	False	False	False	False	False	False	False	False	False	False	False	False	False
21	False	False	False	False	False	False	False	False	False	False	False	False	False

Detecting outlier with IQR

Trouver les valeurs aberrantes : centiles

- Une autre méthode pour détecter les valeurs aberrantes : les centiles.
 - Un centile (percentile) est une mesure statistique qui indique la valeur sous laquelle se trouve un pourcentage donné des observations d'un groupe.
- Un pourcentage des valeurs du haut ou du bas peut être jugé aberrant.
- Une erreur courante est d'utiliser les centiles selon l'étendue des données : p. ex. si vos données vont de 0 à 100, les 5 % supérieurs ne sont pas les valeurs entre 96 et 100. Les 5 % supérieurs sont les valeurs au-delà du 95^e centile des données.

Traiter les valeurs aberrantes

- Un dilemme : supprimer ou plafonner (drop or cap)
- Correction

```
#Capping the outlier rows with Percentiles
upper_lim = data['column'].quantile(.95)
lower_lim = data['column'].quantile(.05)

data.loc[(df[column] > upper_lim),column] = upper_lim
data.loc[(df[column] < lower_lim),column] = lower_lim
```

- Suppression

```
boston_df_o = boston_df_o[(z < 3).all(axis=1)]
```

- Score Z :
- Score IQR :

```
boston_df_out = boston_df_o1[~((boston_df_o1 < (Q1 - 1.5 * IQR)) |  
(boston_df_o1 > (Q3 + 1.5 * IQR))).any(axis=1)]
```

```
boston_df_out.shape
```

Regroupement

- Données ordonnées (tidy data), où chaque ligne est une instance et chaque colonne une caractéristique.

Tidy datasets are easy to manipulate, model and visualise, and have a specific structure: each variable is a column, each observation is a row, and each type of observational unit is a table.

— Hadley Wickham

- Les jeux de données de transactions sont rarement ordonnés -> le regroupement (group by) est utilisé.
- Le point clé des opérations de regroupement est de choisir les fonctions d'agrégation des caractéristiques.

Regroupement

- Agrégation des colonnes catégorielles :
- Fréquence la plus élevée : l'opération max pour les colonnes catégorielles

```
data.groupby('id').agg(lambda x: x.value_counts().index[0])
```

- Tableau croisé dynamique (pivot table) : une bonne option pour aller au-delà des colonnes binaires et combiner plusieurs caractéristiques en caractéristiques agrégées, plus informatives.

User	City	Visit Days
1	Roma	1
2	Madrid	2
1	Madrid	1
3	Istanbul	1
2	Istanbul	4
1	Istanbul	3
1	Roma	3



User	Istanbul	Madrid	Roma
1	3	1	4
2	4	2	0
3	1	0	0

Pivot table example: Sum of Visit Days grouped by Users

- Appliquer l'encodage à chaud (one-hot encoding)

Regroupement

- Les colonnes numériques sont surtout regroupées avec :
- Somme
- Moyenne

```
#sum_cols: List of columns to sum
#mean_cols: List of columns to average

grouped = data.groupby('column_to_group')

sums = grouped[sum_cols].sum().add_suffix('_sum')
avgs = grouped[mean_cols].mean().add_suffix('_avg')

new_df = pd.concat([sums, avgs], axis=1)
```

Plus d'ingénierie des caractéristiques...

- Données numériques
 - Réduction de dimension (dimensionality reduction) : SVD et ACP (apprentissage non supervisé, semaine 7)
 - Regroupement (clustering) : ID de groupe ou distance au centre comme caractéristique
 - Apprentissage non supervisé
 - Sélection de caractéristiques
- Données textuelles
 - Par exemple, représentations par sac de mots (bag-of-words)
- Données d'images :
 - Filtres
 - Convolutions
- Données relationnelles (graphes) :
 - Représentations des nœuds.

Génération de jeux de données équilibrés



Tactiques contre le déséquilibre des classes



- Voici les principales :

Corriger d'abord les données

- Collecter plus de données des classes minoritaires !!!
 - Rééchantillonner le jeu de données.
 - Générer des échantillons synthétiques (augmentation de données).
- Changer de mesure de performance.
 - Utiliser une fonction de perte qui tient compte des probabilités des classes.

Rééchantillonner un jeu de données


- Quand faire du sur- ou du sous-échantillonnage (over/undersampling) ?




- Avec beaucoup de données

- Avec peu de données

Exemple simple de sous-échantillonnage




- Jeu de données original
- 90 % classe 0 en bleu
- 10 % classe 1 en orange



- Classe majoritaire sous-échantillonnée.

Exemple de sous-échantillonnage par liens de Tomek



- Les liens de Tomek (Tomek links) éliminent les points de la classe majoritaire proches de la classe minoritaire. La frontière entre les classes devient plus nette.

Exemples de cas de déséquilibre des données

- Données tabulaires :
 - Finance : transactions frauduleuses
 - Marketing : lien cliqué dans une page web publicitaire
 - Médical : détection du cancer
 - Courriel : pourriel (spam)
- Données d'images :
 - Circulation : Lamborghini Aventador sur l'autoroute
 - Industrie : circuit intégré défectueux
 - Sécurité : enfant perdu dans la foule d'un centre commercial

Avantages de l'augmentation de données

- Améliore la performance des modèles
 - Ajoute des données d'entraînement
 - Réduit le déséquilibre des classes
 - Réduit le surapprentissage (overfitting) des modèles
 - Améliore la généralisation des modèles
- Réduit les coûts de collecte et d'étiquetage des données
 - Les bases de données (BD) coûtent cher à construire
 - Les entreprises ne partagent pas leurs BD
 - Les modèles passent, les BD restent




Augmentation de données de type image

Changements géométriques


- Translation
- Rotation aléatoire
- Retournement vertical et horizontal
- Recadrage
- Zoom

Changements d'intensité

- Changement des couleurs
- Changement du contraste
- Ajout de bruit
- Effacement aléatoire de zones



Exemples de méthodes classiques (2)



Méthodes basées sur les réseaux de neurones

- Réseaux antagonistes génératifs (GAN) (2014) (Goodfellow *et al.*, 2020)
- Transfert de style neuronal (NST) (2015) (Gatys *et al.*, 2016)
- Augmentation texte-vers-image par diffusion (2023) (Trabucco *et al.*, 2024)




photo → Monet

- [Zhu et al. 2017]

Réseaux antagonistes génératifs (GAN)

- Un réseau de neurones apprend à créer de nouveaux exemples qui ressemblent aux données d'entraînement.
- Le réseau générateur peut ensuite servir à créer de nouvelles images réalistes !



Exemples d'images synthétiques générées avec des GAN (1)




Exemples d'images synthétiques générées avec des GAN



Transfert de style neuronal

- Un réseau de neurones extrait les éléments de style d'une image de référence et les applique à l'image à modifier.
- Cela permet de générer plusieurs versions de l'image de départ avec différentes images de style.




Exemples d'images générées par transfert de style neuronal (1)




- Image
- Originale

Exemples d'images générées par transfert de style neuronal (2)



Exemples d'images générées par diffusion conditionnée sur du texte



- Trabucco et al. 2023 Effective Data Augmentation With Diffusion Models

Augmentation de données tabulaires


- Chaque entrée d'un tableau est un point dans un espace à D dimensions
- Il faut générer de nouveaux points tout en respectant les limites en D dimensions du tableau.
- Ne pas générer un âge de -5.

	age (n)	job (c)	marital (c)	education (c)	balance (n)	housing (c)
0	30	unemployed	married	primary	1787	no
1	33	services	married	secondary	4789	yes
2	35	management	single	tertiary	1350	yes
3	30	management	married	tertiary	1476	yes
4	59	blue-collar	married	secondary	0	yes
5	35	management	single	tertiary	747	no

- Entrées
- Espace à 6 dimensions

Méthodes classiques


- SMOTE génère de nouveaux éléments de la classe défavorisée en générant des points dans le voisinage des points existants.



- ADASYN modifie aléatoirement la position des nouveaux points SMOTE.

Méthodes classiques

- SMOTE génère de nouveaux éléments de la classe défavorisée en générant des points dans le voisinage des points existants.



- ADASYN modifie aléatoirement la position des nouveaux points SMOTE.
- Méthodes basées sur les réseaux de neurones
 - Tabular GAN utilise des GAN pour générer des valeurs synthétiques qui respectent les contraintes sur les plages de valeurs du tableau.
 - TabularLLM utilise un réseau de neurones pour générer des valeurs synthétiques qui respectent les contraintes sur les plages de valeurs du tableau()

Règle d'or




- Rien ne vaut l'ajout de vraies données !

Dérive des données : une situation courante (common)


- Une entreprise a collecté des données au cours des 6 derniers mois
- Ce que vous décidez de faire :
 - Prendre les 5 premiers mois pour l'entraînement et la validation
 - Prendre le dernier mois comme données de test
- Le modèle performe très bien sur les ensembles d'entraînement et de validation
- Le modèle ne performe pas bien sur l'ensemble de test
- Q : Que se passe-t-il ???
- Réponse : l'ensemble de test ne vient pas de la même distribution.
- Inspiré de : <https://www.youtube.com/watch?v=c5ClgEhAhK0&t=1s>

Validation antagoniste, illustration

- Pas de dérive¹



- Dérive



¹Source : <https://www.youtube.com/watch?v=c5ClgEhAhK0>

Validation antagoniste

- En rouge : ensemble de test
- En bleu : ensemble d'entraînement
- Idée : étiquette 1 pour l'entraînement et 0 pour le test (validation antagoniste, adversarial validation).
- Si un classifieur distingue les deux ensembles $\Rightarrow$ les deux distributions sont différentes $\Rightarrow$ dérive des données.
- Sinon, pas de dérive des données
 - Temps $\Rightarrow$

- Caractéristiques ~~~~~ cible

[illegible]

Validation antagoniste

[illegible]

- Cibles : 0 1 0 1 0 1 0 101

[illegible]

- Cible : 1011100011 ...

- Les résultats doivent être comparés à un mélange aléatoire (hypothèse nulle)
- Le classifieur devrait moins bien distinguer un mélange aléatoire.
- Plus de tests statistiques la semaine prochaine.

Dérive des données, que faire ?

- Si c'est une dérive constante : (difficile)
 - Réentraîner le modèle sur les données récentes en continu.
 - S'il n'y a pas assez de données : entraîner et tester sur des données mélangées.
- Si c'est une dérive survenue à un moment précis
 - Exemple : la COVID.
 - Identifier la date (avec le test précédent)
 - Entraîner seulement après le changement.

Conclusion

- Ce cours a couvert :
 - La normalisation
 - Le traitement des valeurs aberrantes.
 - L'équilibrage des données
 - L'augmentation de données
 - La dérive des données.

Références utilisées pour construire ce cours

- <https://towardsdatascience.com/feature-engineering-for-machine-learning-3a5e293a5114>
- <https://towardsdatascience.com/ways-to-detect-and-remove-the-outliers-404d16608dba>
- <https://www.slideshare.net/0xdata/feature-engineering-83511751>
- https://ift6758.github.io/lectures/feature_engineering.pdf
- <https://towardsdatascience.com/target-encoding-and-bayesian-target-encoding-5c6a6c58ae8c>

Leon Gatys, Alexander Ecker, and Matthias Bethge. A neural algorithm of artistic style. *J. Vis.*, 16(12):326, September 2016.

Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial networks. volume 63, page 139–144, New York, NY, USA, October 2020. Association for Computing Machinery.

Brandon Trabucco, Kyle Doherty, Max Gurinas, and Ruslan Salakhutdinov. Effective data augmentation with diffusion models. 2024:14590–14612, 2024.