

Introduction à la science des données

Cours 1 : bienvenue en science des données et en apprentissage automatique
(IFT6758)

Glen Berseth

Université de Montréal et Institut Mila-Québec IA

September 2, 2026



Université 
de Montréal



Mila

CIFAR

Plan


Qu'est-ce que la science des données ?

La science des données requiert des compétences diversifiées

Les LLM sont des outils, les experts peuvent faire mieux avec des outils

La science des données n'est pas du pur apprentissage automatique (IFT6390)

- Le pur apprentissage automatique est comme la physique pure
- On se demande : quelle est la grande théorie unifiée de l'univers ?
 - L'algorithme converge-t-il vers un bon point fixe ?
- La science des données est comme l'ingénierie
- On se demande : comment construire un robot qui ressemble au robot Einstein
 - Mettre en place un système permettant de reproduire ce succès de manière fiable ?




Une définition possible de la science des données

- « La science des données est l'application de techniques computationnelles et statistiques pour aborder ou mieux comprendre un problème du monde réel »
- Source : Le cours de Zico Kolter sur la science des données


Comment obtenir de la valeur à partir des données ?

- Commencer par les données
- Quelles données sont disponibles, en faut-il davantage, prétraitement des données
- Analyser les données
- Quel algorithme/modèle, comment savoir s'il fonctionne, comment l'améliorer
- Faire passer le système à l'échelle (MLOps)
 - Comment utiliser le matériel, distribuer les expériences, versionner (git), éviter les erreurs




Exemple : problème de la voix-à-texte

- Pourquoi la voix-vers-texte ?
 - Pour créer un bon modèle que vous et d'autres pouvez utiliser, nous devons avoir et utiliser toutes les compétences nécessaires en science des données



Exemple : problème de la voix-à-texte


- Pourquoi la voix-vers-texte ?
 - Pour créer un bon modèle que vous et d'autres pouvez utiliser, nous devons avoir et utiliser toutes les compétences nécessaires en science des données



- Et pourquoi chaque étape

Exemple: Le problème voix-à-texte


- Qu'a dit le locuteur dans cet extrait audio ?
- Données :
 - Forme d'onde audio
 - Métadonnées sur le locuteur/l'accent
- Analyse :
 - Que devrions-nous prédire (predict) ?
 - Comment entraîner un modèle pour le prédire ?
 - Comment savoir si le modèle fonctionne ?




- Transcription (y) : « Bonjour, comment allez-vous ? »

Exemple: Le problème voix-à-texte

- Qu'a dit le locuteur dans cet extrait audio ?
- Données :
 - Forme d'onde audio
 - Métadonnées sur le locuteur/l'accent
- Analyse :
 - Que devrions-nous prédire (predict) ?
 - Comment entraîner un modèle pour le prédire ?
 - Comment savoir si le modèle fonctionne ?
- Échelle :
 - Des milliers d'heures d'audio à transcrire
 - Quel compute devrions-nous utiliser ?
 - Comment faciliter l'exécution de ce code dans le nuage ?




- Transcription (y) : « Bonjour, comment allez-vous ? »




Données : qu'est-ce qui est disponible, que devrait-on utiliser ?

- Forme d'onde audio (x)
 - Séquence brute d'échantillons audio, p. ex. 16 kHz
 - $[0.0021, -0.0034, 0.0012], \dots$
 - Convertie en mel-spectrogramme (trames x bandes mel)
 - $[f_1, f_2, f_3], \dots$ (discretization)
 - Transforme l'audio en image, réutilisant les architectures standard
 - Est-ce suffisant ?



Données : qu'est-ce qui est disponible, que devrait-on utiliser ?


- Forme d'onde audio (x)
 - Séquence brute d'échantillons audio, p. ex. 16 kHz
 - [0.0021, -0.0034, 0.0012], ...
 - Convertie en mel-spectrogramme (trames x bandes mel)
 - [f_1, f_2, f_3], ... (discretization)
 - Transforme l'audio en image, réutilisant les architectures standard
 - Est-ce suffisant ?
- Rétroaction (feedback) (y)
 - Transcription de référence (vérité terrain)
- Est-ce suffisant ?
 - On veut prédire exactement les mots dits.
 - Ajouter accent, langue, ponctuation, etc.



- Transcription (y) : « Bonjour, comment allez-vous ? »

Analyse : entraîner un modèle, quel type de prédire/output?

- Quel est le type de l'entrée ? (x)
 - Séquence de trames de mel-spectrogramme
 - $[f_1, f_2, f_3], \dots$
 - Plus des métadonnées sur le locuteur/l'accent, parfois
 - $[\text{accent}, \text{fr-CA}], \dots$
 - Sortie y : séquence de jetons de texte (tokens)
- Rétroaction (y)
 - Transcription de référence (vérité terrain)
 - Prédiction séquence-à-séquence




speaker metadata


speaker_id: spk_0342
accent: fr-CA
age: 34
gender: F

Analyse : entraîner un modèle, quel type de prédire/output?

- Quel est le type de l'entrée ? (x)
 - Séquence de trames de mel-spectrogramme
 - $[f_1, f_2, f_3], \dots$
 - Plus des métadonnées sur le locuteur/l'accent, parfois
 - $[\text{accent}, \text{fr-CA}], \dots$
 - Sortie y : séquence de jetons de texte (tokens)
- Rétroaction (y)
 - Transcription de référence (vérité terrain)
 - Prédiction séquence-à-séquence
- Méthodes possibles
 - Classification, régression
 - Séquence-à-séquence (encodeur-décodeur / encoder-decoder)
 - Laquelle choisir ?




speaker metadata	
speaker_id:	spk_0342
accent:	fr-CA
age:	34
gender:	F



Analyse : quel algorithme de classification fonctionne le mieux ?

- Quel type de modèle/architecture ?
- Machine à vecteurs de support (SVM)
 - Théoriquement solide
 - Ne passe pas bien à l'échelle
- Modèle linéaire
 - La transcription est-elle linéaire par rapport à l'onde brute ?
 - Non
- Réseau de neurones
 - Parfois instable à entraîner
 - Prend beaucoup de temps à entraîner
- CNN + Transformer (Whisper)
 - Encodeur-décodeur, passe bien à l'échelle : ce que nous allons affiner (fine-tuner)




Sous-apprentissage / surapprentissage : le modèle s'ajuste-t-il bien aux données ?

- Sous-apprentissage (underfitting)
 - Les modèles linéaires représentent peu
- Surapprentissage (overfitting)
 - Le modèle a appris des cas particuliers
 - Absents de la vraie distribution
- Ajustement approprié?
 - Réserver de l'audio pour les tests (validation)
 - Validation croisée (cross-validation)
- Obtenir un meilleur ajustement
 - Régularisation (p. ex. dropout LoRA)
 - Rasoir d'Ockham : le plus simple gagne




Complexité du modèle : et comment la mesurer

- Arbres de décision
 - Arbres simples
- Réseaux profonds
 - Nombre de paramètres
 - Nombre de couches
- Adaptateurs LoRA (Hu *et al.*, 2022)
 - Le rang r contrôle le nombre de nouveaux paramètres ajoutés
 - $r=16$ garde le modèle de base majoritairement gelé (frozen)




Prétraitement et réglage du modèle (Validation)

- Le modèle est-il assez performant ?
 - On peut souvent faire mieux.
- Prétraiter les données
 - Comment diviser les données test/validation
 - Avons-nous assez de données à diviser ?
- Réglage du modèle :
 - Tous les modèles ont des hyperparamètres
 - Taux d'apprentissage (learning rate), taille de lot (batch size), rang/alpha de LoRA (rank/alpha)
 - Essayer différentes hyperparamter valeurs





Visualisation des données : bien présenter les résultats

- Comment montrer que le modèle fonctionne
- Exploration :
 - Y a-t-il d'autres tendances dans les données ?
 - Comment les trouver ?
- Présentation :
 - Meilleure façon de présenter l'exploration ?
 - On veut une visualisation compacte avec peu de bruit




Visualisation des données : bien présenter les résultats

- Comment montrer que le modèle fonctionne
- Exploration :
 - Y a-t-il d'autres tendances dans les données ?
 - Comment les trouver ?
- Présentation :
 - Meilleure façon de présenter l'exploration ?
 - On veut une visualisation compacte avec peu de bruit
- Visualisations avancées :
 - Multimodale (p. ex. spectrogrammes + cartes d'attention)
 - Visualisations interactives
 - Pièges de la visualisation





Prétraitement et augmentation des données

- Comment préparer les données pour faciliter le travail du modèle
- Prétraitement :
 - Données aberrantes en entrée, résultats aberrants en sortie (Garbage in, garbage out)
 - Filtrer les extraits audio trop longs/courts
 - Rééchantillonner tout l'audio au taux attendu par le modèle (16 kHz)




Prétraitement et augmentation des données

- Comment préparer les données pour faciliter le travail du modèle
- Prétraitement :
 - Données aberrantes en entrée, résultats aberrants en sortie (Garbage in, garbage out)
 - Filtrer les extraits audio trop longs/courts
 - Rééchantillonner tout l'audio au taux attendu par le modèle (16 kHz)
- Augmentation :
 - Ajouter du bruit de fond, des perturbations de vitesse/hauteur
 - D'autres méthodes ????







Ingénierie des caractéristiques/features : choisir les meilleures

- Toutes les caractéristiques ne se valent pas, utilisons les meilleures
 - Rappel du problème de transcription





Ingénierie des caractéristiques/features : choisir les meilleures

- Toutes les caractéristiques ne se valent pas, utilisons les meilleures
 - Rappel du problème de transcription
- Qu'est-ce qu'une caractéristique :
 - X = trames de mel-spectrogramme $[f_1, f_2, f_3]$
 - Les dernières secondes d'audio fonctionnent peut-être le mieux
- Sélection :
 - Réduire la longueur de l'entrée
 - Modèle plus petit/distillé, si possible





Test d'hypothèse : ayez confiance en votre modèle

- Quelle confiance avons-nous dans nos résultats ?
- Test d'hypothèse
 - Test statistique contre l'hypothèse nulle
- Méthodes
 - Simulation directe
 - Permutation
 - Amorçage (bootstrap)
 - Validation croisée




Test d'hypothèse : ayez confiance en votre modèle

- Quelle confiance avons-nous dans nos résultats ?
- Test d'hypothèse
 - Test statistique contre l'hypothèse nulle
- Méthodes
 - Simulation directe
 - Permutation
 - Amorçage (bootstrap)
 - Validation croisée
- Exemple : le Whisper affiné est-il vraiment meilleur ?
 - WER de base vs affiné, mêmes extraits
 - Amorçage sur les différences de WER
 - L'IC exclut 0 $\Rightarrow$ amélioration réelle



Virtualisation : rendez votre code reproductible/portable

- Nous devons déployer notre code sur les serveurs de l'entreprise
 - Comment faciliter cela ?
- Machines virtuelles (VM) :
 - Simuler un tout nouveau système d'exploitation par-dessus un existant
 - Copier cette configuration d'un ordinateur à l'autre
- Docker :
 - Un écosystème de VM légères
 - Facile à partager avec d'autres et à déployer
- Utile pour le réglage des hyperparamètres
 - Répliquer votre code sur plusieurs GPU, partager l'adaptateur LoRA via



	Entraînement (à partir de zéro)	Affinage (LoRA)
Données	~680k h d'audio	~quelques 100 h (fleurs fr)
Paramètres entraînaibles	~1,5G (modèle complet)	~0,4M (adaptateurs)
Matériel	Grappe de GPU (cluster)	1 GPU
Temps	semaines	heures


MLOps : suivi des expériences et outils de niveau production

- Combien de modèles différents allons-nous essayer et entraîner ? 100 ? 10 000 ?
 - Un bon scientifique tient un journal de toutes ses expériences
 - Noter POURQUOI chaque expérience a été menée, etc.
 - Après deux semaines, les gens oublient tous les détails des travaux précédents.



MLOps : suivi des expériences et outils de niveau production

- Combien de modèles différents allons-nous essayer et entraîner ? 100 ? 10 000 ?
 - Un bon scientifique tient un journal de toutes ses expériences
 - Noter POURQUOI chaque expérience a été menée, etc.
 - Après deux semaines, les gens oublient tous les détails des travaux précédents.
- Suivi des expériences :
 - Suivre les expériences en cours (Accelerate, W&B, comet.ml)
 - Faire plus d'exploration et d'analyse
 - Reproduire une expérience ?????



Apprentissage non supervisé

- Dans de nombreux cas, nous n'avons pas d'étiquettes y pour nos données. Que pouvons-nous faire ?

Apprentissage non supervisé

- Dans de nombreux cas, nous n'avons pas d'étiquettes y pour nos données. Que pouvons-nous faire ?
- L'apprentissage non-supervisé cherche la structure dans les données elles-mêmes, sans cible de vérité terrain à prédire
 - Regrouper des exemples similaires (regroupement / clustering)
 - Apprendre une représentation compacte des données (p. ex. un auto-encodeur)
 - Les motifs découverts de cette façon peuvent ensuite être réutilisés pour aider une tâche supervisée en aval

Apprentissage non supervisé

- Dans de nombreux cas, nous n'avons pas d'étiquettes y pour nos données. Que pouvons-nous faire ?
- L'apprentissage non-supervisé cherche la structure dans les données elles-mêmes, sans cible de vérité terrain à prédire
 - Regrouper des exemples similaires (regroupement / clustering)
 - Apprendre une représentation compacte des données (p. ex. un auto-encodeur)
 - Les motifs découverts de cette façon peuvent ensuite être réutilisés pour aider une tâche supervisée en aval
- Exemple : Whisper a été pré-entraîné de cette façon avant qu'on ne l'affine
 - Pré-entraîné sur 680 000 heures de paires audio-texte faiblement étiquetées
 - « Faiblement étiqueté » signifie que les transcriptions n'ont pas été soigneusement vérifiées par des humains, elles ont été extraites d'Internet (p. ex. sous-titres de vidéos), donc elles sont bruitées mais abondantes
 - Cela donne au modèle des motifs vocaux généraux avant qu'on ne l'affine sur un petit jeu de données proprement étiqueté


Apprentissage non supervisé : regroupement (clustering)

- Que peut-on faire quand on n'a pas les étiquettes y ?
 - Hypothèse : points de même étiquette devraient être similaires
 - Regroupement : regrouper les points « similaires »
 - Complexité : comment définir « similaire » ? (distance, caractéristiques)



Apprentissage non supervisé : regroupement (clustering)

- Que peut-on faire quand on n'a pas les étiquettes y ?
 - Hypothèse : points de même étiquette devraient être similaires
 - Regroupement : regrouper les points « similaires »
 - Complexité : comment définir « similaire » ? (distance, caractéristiques)
- Exemple : nettoyer le jeu de données d'affinage de Whisper
 - Regrouper les extraits par caractéristiques (plongements/embeddings, RSB/SNR, durée)
 - Petits regroupements/aberrants = souvent audio corrompu ou mal étiqueté
 - Repérer et retirer les mauvais extraits



Biais algorithmique

- Les prédictions sont-elles équitables ?
 - Les données sont-elles équitables?
 - Représentent-elles la vraie relation causale :
 - (A) température $\rightarrow$ altitude, ou
 - (B) altitude $\rightarrow$ température

Biais algorithmique

- Les prédictions sont-elles équitables ?
 - Les données sont-elles équitables?
 - Représentent-elles la vraie relation causale :
 - (A) température $\rightarrow$ altitude, ou
 - (B) altitude $\rightarrow$ température
- Biais :
 - Les données sont collectées par des personnes
 - Certains groupes apparaissent plus souvent
 - Accents, dialectes ou langues sous-représentés

Biais algorithmique

- Les prédictions sont-elles équitables ?
 - Les données sont-elles équitables?
 - Représentent-elles la vraie relation causale :
 - (A) température $\rightarrow$ altitude, ou
 - (B) altitude $\rightarrow$ température
- Biais :
 - Les données sont collectées par des personnes
 - Certains groupes apparaissent plus souvent
 - Accents, dialectes ou langues sous-représentés
- Équité :
 - Comprendre les effets de ces problèmes
 - Rendre modèle et données plus équitables
 - Éviter d'amplifier les biais historiques



Matériel et apprentissage distribué

- Quel matériel devrions-nous acheter pour exécuter notre algorithme ?
 - Il faut le justifier auprès du patron
- Matériel :
 - GPU nécessaire pour le traitement audio
 - Combien de requêtes par minute ?
 - LoRA + précision mixte (fp16) permet d'affiner sur un seul GPU
 - La précision matérielle du GPU mène à des résultats différents. (fp32 ou fp16 ou fp8) (Li *et al.*, 2024; Khatri *et al.*, 2026)



Matériel et apprentissage distribué

- Quel matériel devrions-nous acheter pour exécuter notre algorithme ?
 - Il faut le justifier auprès du patron
- Matériel :
 - GPU nécessaire pour le traitement audio
 - Combien de requêtes par minute ?
 - LoRA + précision mixte (fp16) permet d'affiner sur un seul GPU
 - La précision matérielle du GPU mène à des résultats différents. (fp32 ou fp16 ou fp8) (Li *et al.*, 2024; Khatri *et al.*, 2026)
- Distribuer :
 - Quel service en nuage (cloud) utiliser ?
 - Cela dépend des hypothèses du modèle




Données sous forme de graphes


- Spécificités des graphes
 - Tâches standard
 - Représentations
 - Matrice d'adjacence, matrice laplacienne
- Plongements de nœuds (node embeddings)
 - Par similarité de nœuds
 - Marches aléatoires



Social networks



Economic networks



Biomedical networks



Information networks:
Web & citations



Internet



Networks of neurons




Données sous forme de graphes

- Spécificités des graphes

- Tâches standard
- Représentations
- Matrice d'adjacence, matrice laplacienne

- Plongements de nœuds (node embeddings)

- Par similarité de nœuds
- Marches aléatoires




- Exemple : réseau social

- Informations sur les nœuds : localisation, âge, etc.
- Informations sur les liens : amis, « j'aime »

Les grands modèles de langage (LLM)


- Spécificités des LLM (semaine 8)
 - Comment créer un LLM [Li et al. \(2024\)](#); [Khatri et al. \(2026\)](#)
 - Tokenisation (tokenization), une forme d'ingénierie des caractéristiques
 - Affinage supervisé (SFT)
- Apprentissage par renforcement (semaine 9)
 - Apprentissage par renforcement à partir de rétroaction humaine (RLHF/RLVR)
 - Utilisation de récompenses vérifiées
- Modèles vision-langage (semaine 10)
 - Tokenisation de plusieurs types de données
 - Entraînement



Aller plus en profondeur

- D'ici la fin de ce cours, vous comprendrez le pourquoi et le comment de la construction de tels systèmes, solide et professionnelle.


La science des données requiert des compétences diversifiées



- Ligue pour la justice algorithmique (Algorithmic Justice League)



Retour sur ce qu'est la science des données



- Source : <https://www.datasciencecourse.org/slides/intro.pdf>

Première étape : page web du cours

- Page statique du cours :
 - Section française : <https://fracturedplane.notion.site/Cours-de-Science-des-Donnees-IFT6758B-2026-3c1214857276818499f7e8eee49dc68a?pvs=74>
 - Section anglaise : <https://fracturedplane.notion.site/Data-Science-Course-IFT6758B-2026-3ae21485727681a38001f0d8c572d69a>
- Page des prérequis :
 - Prérequis
 - Comprendre Python, l'algèbre linéaire, les statistiques
- Calendrier du cours
 - Section française : <https://fracturedplane.notion.site/Cours-de-Science-des-Donnees-IFT6758B-2026-3c1214857276818499f7e8eee49dc68a?pvs=74>
 - Section anglaise : <https://fracturedplane.notion.site/Data-Science-Course-IFT6758B-2026-3ae21485727681a38001f0d8c572d69a>

Deuxième étape : Piazza

- Discussions et questions sur Piazza : courriel déjà envoyé.
- Nous n'utiliserons pas StudiUM !
- Assurez-vous d'être inscrit sur Piazza ! Sinon, remplissez [ce formulaire]
- Assurez-vous de consulter Piazza fréquemment.
 - et de vérifier votre courriel @umontreal.ca !

Troisième étape : sondage

- Remplissez le sondage [lien ici](#)
- Très important !
 - Cela nous aidera à orienter le cours en fonction de votre parcours.
 - Organiser les équipes de projet
- Je vous laisserai plus de temps pendant la pause pour remplir le formulaire !

Logistique du cours : Gradescope

- Les quiz se font sur Gradescope.
- Des devoirs de programmation seront fournis mais non notés. Cependant, ils pourront apparaître aux examens écrits.
- Quiz 0 ! (pour s'entraîner à soumettre des réponses)

Logistique du cours : évaluation

- Projet final (3 jalons) (35 %)
- Participation en classe (5%)
- Devoirs de programmation (Gradescope) – (5 %)
 - Exemples présents aux examens
- Examen intra + Examen final (examens écrits)
 - Intra : la semaine après la semaine de relâche (25 %)
 - Final en décembre (30 %)

Le projet final

- Brisons la glace !



Le projet final

- Données publiques de la LNH.
- Récupération des données à partir d'une API.
- Visualisation des données.
- Notions de base en apprentissage automatique.
- Défi : domaine non standard
-> données du monde réel
- Objectif : pipeline proche du milieu de production (nauge)



Pourquoi ce cours ?

- La science des données évolue rapidement !
- Ce cours présente à tous les participants les méthodes les plus avancées
- Ce cours est créé pour aider les gens à trouver un emploi ! Réussir ses entretiens.
 - On obtient ce qu'on investit dans ses études

Réflexions sur les modèles de texte génératifs

- Combien d'entre vous ont utilisé ChatGPT/Gemini/Claude/Qwen/etc. ?
- Dans quel but les utilisez-vous? Qui utilise quoi?
- Fonctionnent-ils toujours?
 - Exemples de leurs échecs...

Réflexions sur les modèles de texte génératifs

- Combien d'entre vous ont utilisé ChatGPT/Gemini/Claude/Qwen/etc. ?
- Dans quel but les utilisez-vous? Qui utilise quoi?
- Fonctionnent-ils toujours?
 - Exemples de leurs échecs...
- LLMs changer
 - Les modèles sont mis à jour(updated), et leurs performances changent
 - Usage restreint au travail. Impossible de les utiliser pour des projets sensibles/privé
 - L'usage sera restreint et CHER
- La vérité : beaucoup d'entreprises veulent utiliser l'IA, sans savoir comment.
 - Ils ont besoin d'experts qui comprennent comment intégrer l'IA dans leurs systèmes de façon **FORT/FIABLE**.

Les LLM sont des outils, les experts peuvent faire mieux avec des outils

Exemple : un pinceau

- Dans une main inexpérimentée (sans connaissance), un pinceau ne fait que mélanger toutes les couleurs en une couleur terne et sale.



Figure: peinture ennuyeuse

Les LLM sont des outils, les experts peuvent faire mieux avec des outils

Exemple : un pinceau

- Dans une main inexpérimentée (sans connaissance), un pinceau ne fait que mélanger toutes les couleurs en une couleur terne et sale.

Novice + paintbrush: every color blends to the same mud



Figure: peinture ennuyeuse

- Dans la main d'un expert, le même outil produit des chefs-d'œuvre.



- Vincent van Gogh, *La Nuit étoilée* (1889)



- Léonard de Vinci, *La Joconde* (v. 1503)

L'IA est utilisée partout

- Les LLM produisent plus, mais pas mieux. Nous devons donc être meilleurs.
- Cependant, l'IA peut être utilisée correctement.
- Le CERN l'utilise pour aider à traiter les données, améliorer le code, etc.
- Le gouvernement canadien l'utilise pour le traitement des données.
- De nombreuses entreprises améliorent ces outils
 - Ils fonctionnent tous mieux avec des connaissances du domaine.

Règles d'utilisation des modèles de texte génératifs (p. ex. ChatGPT)

- Vous devez décrire comment vous avez vérifié que le contenu généré est correct et correspond à ce que vous vouliez.

Règles d'utilisation des modèles de texte génératifs (p. ex. ChatGPT)

- Vous devez décrire comment vous avez vérifié que le contenu généré est correct et correspond à ce que vous vouliez.
- Identifiez clairement où et comment l'IA générative a été utilisée.

Règles d'utilisation des modèles de texte génératifs (p. ex. ChatGPT)

- Vous devez décrire comment vous avez vérifié que le contenu généré est correct et correspond à ce que vous vouliez.
- Identifiez clairement où et comment l'IA générative a été utilisée.
- Vous devez ajouter une annexe détaillée qui énumère toutes vos invites (prompts) et réponses.
 - Comment vous avez utilisé l'IA générative,
 - Les risques pour la véracité, l'exactitude et la qualité de votre travail,
 - Les mesures concrètes que vous avez prises pour atténuer ces risques, et
 - La valeur que vous avez vous-même ajoutée au contenu généré par l'IA, par exemple lorsque vous avez dû intervenir pour corriger ou orienter l'IA générative.

Règles d'utilisation des modèles de texte génératifs (p. ex. ChatGPT)

- Vous devez décrire comment vous avez vérifié que le contenu généré est correct et correspond à ce que vous vouliez.
- Identifiez clairement où et comment l'IA générative a été utilisée.
- Vous devez ajouter une annexe détaillée qui énumère toutes vos invites (prompts) et réponses.
 - Comment vous avez utilisé l'IA générative,
 - Les risques pour la véracité, l'exactitude et la qualité de votre travail,
 - Les mesures concrètes que vous avez prises pour atténuer ces risques, et
 - La valeur que vous avez vous-même ajoutée au contenu généré par l'IA, par exemple lorsque vous avez dû intervenir pour corriger ou orienter l'IA générative.
- Des questions ?



Sondage: LLMs utiliser

Sondage

- Dans quelles circonstances est-il judicieux d'utiliser des modèles linguistiques dans notre travail ?
 - (A) : Lorsque nous ne savons pas trop comment procéder.
 - (B) : Lorsque nous avons une idée de la manière de mener à bien la tâche, mais que nous n'en sommes pas tout à fait sûrs.
 - (C) : Nous savons assez bien comment mener à bien la tâche. Nous avons simplement besoin d'un outil pour nous aider à automatiser le processus.
 - (D) : Pour les tâches que nous avons déjà effectuées à de nombreuses reprises, mais qui constituent ici un cas particulier, présentant une légère différence par rapport à l'une des fois précédentes où nous l'avons réalisée.

Ressources utiles

- Livres : Statistical Learning, Python Handbook, Introduction to Data Science
- Cours en ligne : freeCodeCamp , Harvard CS109
- La revue de science des données de Harvard (Harvard Data Science Review)



Ressources

- Certains contenus proviennent de (<https://ucbrise.github.io/cs294-ai-sys-sp22/>,
- <https://fullstackdeeplearning.com/spring2021/>,
- <https://stanford-cs329s.github.io/>).

- Edward J Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuezhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations*, 2022.
- Devvrit Khatri, Lovish Madaan, Rishabh Tiwari, Rachit Bansal, Venkata Sai Surya Subramanyam Duvvuri, Manzil Zaheer, Inderjit Dhillon, David Brandfonbrener, and Rishabh Agarwal. The art of scaling reinforcement learning compute for llms. In *International Conference on Learning Representations*, volume 2026, pages 72438–72467, 2026.
- Rui Li, Deji Fu, Chunyu Shi, Zhilan Huang, and Gang Lu. Efficient llms training and inference: An introduction. *IEEE Access*, 13:32944–32970, 2024.