

# Apprentissage pour la science des données

## Cours 4 : Complexité, diagnostic des courbes d'entraînement, interprétabilité et métriques de performance

Glen Berseth

Université de Montréal et Institut québécois d'intelligence artificielle (Mila)

September 14, 2026



Université  de Montréal



Mila

**CIFAR**

# Plan

Complexité d'un modèle en apprentissage automatique (AA)

Complexité des modèles linéaires

Temps d'entraînement et d'inférence

Interprétabilité

Diagnostic des courbes d'entraînement

Courbes d'entraînement typiques des modèles « en santé »

Classification

Métriques de classification basées sur l'aire sous la courbe

Un dernier exemple

# Complexité d'un modèle en apprentissage automatique (AA)

- Capacité à comprendre de plus en plus d'information des données, jusqu'à ce qu'il en soit complètement « saturé ».
- Principaux facteurs affectant la complexité d'un modèle
  - Nombre de paramètres à entraîner
  - Structure/architecture
- Un petit réseau de neurones (RN) profond est souvent plus performant qu'un RN peu profond mais très large.



## Situations courantes lors de l'entraînement d'un modèle en AA

- Il est possible d'améliorer sa performance en augmentant les données d'entraînement.

## Situations courantes lors de l'entraînement d'un modèle en AA


- Il est possible d'améliorer sa performance en augmentant les données d'entraînement.
- Capacité dépassée; ajouter des données n'améliore plus rien...

## Situations courantes lors de l'entraînement d'un modèle en AA

- Il est possible d'améliorer sa performance en augmentant les données d'entraînement.
- Capacité dépassée; ajouter des données n'améliore plus rien...
- La performance maximale dépend de model complexité.

# Situations courantes lors de l'entraînement d'un modèle en AA

- Il est possible d'améliorer sa performance en augmentant les données d'entraînement.
- Capacité dépassée; ajouter des données n'améliore plus rien...
- La performance maximale dépend de model complexité.
- Pour de meilleures performances, augmenter la complexité du modèle ou en changer.



# Complexité des modèles linéaires

- Un modèle de base peut être rendu plus complexe en ajoutant de nouvelles combinaisons de characteristics:
  - Modèle de base :
  - Interactions ajoutées :
  - Non-linéarités ajoutées :
  - Attributs x ajoutés :
- Les paramètres  $\theta$  des modèles linéaires sont faciles à estimer avec la méthode des moindres carrés (least squares).
- Le nombre d'interactions possibles augmente en  $D^2$  où  $D$  est la dimensionnalité de  $x$ .

$$\hat{y} = \theta_0 + \theta_1 x^1 + \theta_2 x^2$$

$$\hat{y} = \theta_0 + \theta_1 x^1 + \theta_2 x^2 + \theta_3 x^1 x^2$$

$$\hat{y} = \theta_0 + \theta_1 x^1 + \theta_2 x^2 + \theta_3 x^1 x^2 + \theta_4 (x^1)^2 + \theta_5 (x^2)^2$$

$$\hat{y} = \theta_0 + \theta_1 x^1 + \theta_2 x^2 + \theta_3 x^3 + \dots$$

# Complexité et arbres de décision

- Un arbre de décision gère implicitement les interactions entre les attributs  $x$  sans avoir à les spécifier comme dans un modèle multilinéaire.
- Rendre les arbres de décision plus complexes
  - Forêt aléatoire (random forest)
  - Gradient Boosted Trees
  - Boosted Forests
  - XGBoost
- Beaucoup de problèmes réels se prêtent naturellement à une analyse basée sur les arbres de décision.

## Exemple : modéliser les profits d'une station de ski



- Il faut prendre en compte plusieurs attributs  $x$ 
  - Bulletin météo
  - Jour de la semaine
  - Congé ?
  - Chute de neige importante
- Chaque skieur utilise un arbre de décision avec ces attributs pour décider s'il vient skier ou non.
- Les profits dépendront donc des décisions d'un grand nombre d'arbres de décision.



- La foule décide comme une forêt aléatoire !

# Stratégies pour contrôler la complexité d'un arbre de décision

- Réduction de la complexité
  - Limiter sa profondeur
- Augmentation de la complexité
  - Passer à une forêt aléatoire



## Ajouter des couches à un réseau de neurones n'est pas toujours la solution

- Améliore la performance d'un réseau de neurones jusqu'à un certain point.

## Ajouter des couches à un réseau de neurones n'est pas toujours la solution



- Améliore la performance d'un réseau de neurones jusqu'à un certain point.
- La performance peut diminuer si trop de couches sont ajoutées (problème de rétropropagation (backpropagation) du gradient).

## Ajouter des couches à un réseau de neurones n'est pas toujours la solution

- Améliore la performance d'un réseau de neurones jusqu'à un certain point.
- La performance peut diminuer si trop de couches sont ajoutées (problème de rétropropagation (backpropagation) du gradient).
- Particulièrement vrai pour l'architecture classique (simple) des RN convolutifs.

# Ajouter des couches à un réseau de neurones n'est pas toujours la solution

- Améliore la performance d'un réseau de neurones jusqu'à un certain point.
- La performance peut diminuer si trop de couches sont ajoutées (problème de rétropropagation (backpropagation) du gradient).
- Particulièrement vrai pour l'architecture classique (simple) des RN convolutifs.
- L'erreur de classification finit par augmenter avec le nombre de couches...



- Architecture classique d'un RN convolutif



# Changer de famille de modèles est encore plus efficace

- Les performances finissent par plafonner pour une famille de structures donnée.

## Changer de famille de modèles est encore plus efficace


- Les performances finissent par plafonner pour une famille de structures donnée.
- Il est nécessaire de tester différentes structures de RN.

# Changer de famille de modèles est encore plus efficace

- Les performances finissent par plafonner pour une famille de structures donnée.
- Il est nécessaire de tester différentes structures de RN.
- Trop ajuster un modèle préféré diminue (decreases) le retour sur performance.

# Changer de famille de modèles est encore plus efficace

- Les performances finissent par plafonner pour une famille de structures donnée.
- Il est nécessaire de tester différentes structures de RN.
- Trop ajuster un modèle préféré diminue (decreases) le retour sur performance.
- Il est important de connaître la littérature et les ressources disponibles.



# L'importance du logiciel libre (Open Source)

- Il est rare de commencer à coder un ResNet complexe à partir de zéro.

# L'importance du logiciel libre (Open Source)

- Il est rare de commence coder un ResNet complexe à partir de zéro.
- Le code source de la majorité des modèles d'AA est publié sur un site de partage après la publication des articles scientifiques associés!

# L'importance du logiciel libre (Open Source)

- Il est rare de commence coder un ResNet complexe à partir de zéro.
- Le code source de la majorité des modèles d'AA est publié sur un site de partage après la publication des articles scientifiques associés!
- Les paramètres de RN déjà entraînés peuvent être téléchargés !

# L'importance du logiciel libre (Open Source)

- Il est rare de commence coder un ResNet complexe à partir de zéro.
- Le code source de la majorité des modèles d'AA est publié sur un site de partage après la publication des articles scientifiques associés!
- Les paramètres de RN déjà entraînés peuvent être téléchargés !
- Un nouveau RN peut être adapté à son problème et à ses données grâce à l'apprentissage par transfert (transfer learning).

# L'importance du logiciel libre (Open Source)

- Il est rare de commence coder un ResNet complexe à partir de zéro.
- Le code source de la majorité des modèles d'AA est publié sur un site de partage après la publication des articles scientifiques associés!
- Les paramètres de RN déjà entraînés peuvent être téléchargés !
- Un nouveau RN peut être adapté à son problème et à ses données grâce à l'apprentissage par transfert (transfer learning).
- Plusieurs services d'hébergement web et de gestion de développement logiciel existent.

## statech/resnet

keras-style API to ResNets (ResNet-50, ResNet-101, and ResNet-152)



Ax 1

Contributor

58

Used by

22

Stars

20

Forks




## Temps d'inférence/latence : temps requis pour faire une prédiction.

- Modèle de classification simple :  $k$  plus proches voisins (nearest neighbours)
  - Temps d'entraînement nul !
  - Calcul des distances aux  $N$  données d'entraînement à chaque fois...
  - Temps d'inférence proportionnel à  $K$


## Temps d'inférence/latence : temps requis pour faire une prédiction.

- Modèle de classification simple : k plus proches voisins (nearest neighbours)
  - Temps d'entraînement nul !
  - Calcul des distances aux N données d'entraînement à chaque fois...
  - Temps d'inférence proportionnel à K
  - Temps en secondes si K est grand
  - Peu pratique en temps réel...




# Modèle de classification complexe : réseau de neurones

- Temps d'entraînement long (heures, jours)...
- Peut être réduit grâce à l'apprentissage par transfert
- Temps d'inférence constant (quelques ms à une seconde)
- Généralement utilisé en temps réel !



# Modèle de classification complexe : réseau de neurones

- Temps d'entraînement long (heures, jours)...
- Peut être réduit grâce à l'apprentissage par transfert
- Temps d'inférence constant (quelques ms à une seconde)
- Généralement utilisé en temps réel !



## Machine Learning Time Complexity

DataInterview.com

n: data size  
p: Number of features  
T: Number of trees

l: Number of iterations  
m: Number of components  
h: Number of hidden units  
k: number of clusters

| ML Algorithms          | Training Time                                 | Inference Time                              |
|------------------------|-----------------------------------------------|---------------------------------------------|
| Linear Regression      | $O(np^2 + p^3)$                               | $O(p)$                                      |
| Logistic Regression    | $O(np^2 + p^3)$                               | $O(p)$                                      |
| Naive Bayes            | $O(np)$                                       | $O(p)$                                      |
| Decision Tree          | Avg: $O(T \cdot n \log n)$<br>Worst: $O(n^2)$ | Avg: $O(T \cdot n \log n)$<br>Worst: $O(n)$ |
| Random Forest          | $O(T \cdot n \log n)$                         | $O(T \cdot \log n)$                         |
| Gradient Boosted Trees | $O(T \cdot n \log n)$                         | $O(T \cdot \log n)$                         |
| Principal Component    | $O(np^2 + p^3)$                               | $O(pm)$                                     |
| K-Nearest Neighbor     | $O(1)$                                        | $O(np)$                                     |
| K-Means                | $O(l \cdot k \cdot n \cdot p)$                | $O(k \cdot p)$                              |
| Dense Neural Networks  | $O(l \cdot n \cdot p \cdot h)$                | $O(p \cdot h)$                              |

# Conclusion


- Deux moments principaux d'« utilisation » des modèles :
- Entraînement :
  - Important lors du développement des modèles
- Inférence :
  - Important lors de l'utilisation du modèle

# Conclusion

- Deux moments principaux d'« utilisation » des modèles :
- Entraînement :
  - Important lors du développement des modèles
- Inférence :
  - Important lors de l'utilisation du modèle
- Les deux peuvent être réduits (demande plus de programmation et de ressources) en utilisant :
  - La parallélisation (entraînement distribué)
  - Une grappe (cluster) de calcul.
  - Un matériel plus efficace (GPU vs CPU)
  - Plus de détails dans des cours dédiés.


# Choisir un modèle d'apprentissage automatique

- L'IA offre de nombreux modèles pour analyser des données.
- Certains sont précis, mais incompréhensibles.
- D'autres sont simples, mais imprécis (fort biais).
- Chacun représente une approximation de la réalité.
- Lequel choisir ?



# L'importance d'expliquer les résultats des prédictions


- En général, plus la complexité d'un modèle augmente, plus son interprétabilité diminue.



- Complexité
- Exemples concrets :
  - Prêt bancaire refusé
  - Détection du cancer
  - Demande refusée
  - Etc.

# Exemple de demande de carte de crédit

- Comment un banquier pourrait-il expliquer sa décision à un client ?
- Simple à expliquer



- Trop complexe à expliquer
- Que faire d'une précision (accuracy) de 95 % pour le modèle complexe, sans intervalle de confiance, et qui ne peut être expliquée ?

# L'interprétabilité peut aider à détecter des biais

- Exemple de biais de sélection

## L'interprétabilité peut aider à détecter des biais

- Exemple de biais de sélection
- Les CV de 100 femmes et 1000 hommes ont été analysés.

## L'interprétabilité peut aider à détecter des biais

- Exemple de biais de sélection
- Les CV de 100 femmes et 1000 hommes ont été analysés.
- Il y a plus de chances de trouver des candidatures exceptionnelles parmi les CV des hommes, 10x plus nombreux.

## L'interprétabilité peut aider à détecter des biais

- Exemple de biais de sélection
- Les CV de 100 femmes et 1000 hommes ont été analysés.
- Il y a plus de chances de trouver des candidatures exceptionnelles parmi les CV des hommes, 10x plus nombreux.
- Un modèle entraîné sur ces données pourrait déterminer que le sexe des candidats est un attribut principal de performance !

## L'interprétabilité peut aider à détecter des biais

- Exemple de biais de sélection
- Les CV de 100 femmes et 1000 hommes ont été analysés.
- Il y a plus de chances de trouver des candidatures exceptionnelles parmi les CV des hommes, 10x plus nombreux.
- Un modèle entraîné sur ces données pourrait déterminer que le sexe des candidats est un attribut principal de performance !
- Remplaçons le sexe par l'origine ethnique, et celle-ci deviendra un nouvel attribut principal pour les mêmes raisons...


## L'interprétabilité peut aider à détecter des biais

- Exemple de biais de sélection
- Les CV de 100 femmes et 1000 hommes ont été analysés.
- Il y a plus de chances de trouver des candidatures exceptionnelles parmi les CV des hommes, 10x plus nombreux.
- Un modèle entraîné sur ces données pourrait déterminer que le sexe des candidats est un attribut principal de performance !
- Remplaçons le sexe par l'origine ethnique, et celle-ci deviendra un nouvel attribut principal pour les mêmes raisons...
- Plus de détails dans le cours sur les biais algorithmiques/données.



# L'interprétabilité peut aider à détecter des biais


- Exemple de biais de mesure
- Un système d'analyse d'images médicales est entraîné à détecter des cancers dans des images de type IRM.
- Problème :
  - Les cas positifs sont confirmés avec la machine B.
  - Les cas négatifs proviennent tous de la machine A.
- Le taux de détection du cancer sera biaisé par la machine utilisée pour obtenir l'image.




- Tomodensitomètre
- IRM

# Interprétabilité des résultats : modèles simples

- Il est facile d'expliquer les décisions prises par des modèles simples tels que :
- Régression linéaire



- Arbre de décision



# Exemple de régression linéaire



- Modèle linéaire général :
  - De plus grandes valeurs  $|\theta_i|$  correspondent à des attributs (normalisés)  $x^i$  plus importants.
  - Quand  $\theta_i > 0$ , il y a une corrélation positive entre l'attribut et la réponse  $y$ .
  - Une variation  $\Delta x^i$  produit une variation de la réponse  $\Delta y = \theta_i \Delta x^i$  quand les autres attributs  $x^j$  restent inchangés.

Modèle linéaire simple :  $y = \theta_0 + \theta_1 x$

Ajouter plus d'attributs donne  $y = \theta_0 + \theta_1 x^1 + \dots + \theta_D x^D$ .

# Exemple d'un arbre de décision

- Arbre de decision ajusté aux données morphométriques (en cm) de deux types de sauterelles (grasshoppers et katydid en anglais)
- Seuls quelques attributs X permettent de différencier les deux types d'insectes.




- Classification d'une nouvelle sauterelle.

## Interprétabilité des résultats : réseaux de neurones

- Pour faire des prédictions avec un réseau de neurones, les données d'entrée passent par de nombreuses couches effectuant des produits matriciels suivis de transformations non linéaires.
- Difficile de suivre le flux des données d'une couche à l'autre.
- Une seule prédiction peut impliquer des **millions** d'opérations mathématiques selon l'architecture du réseau de neurones.





# Exemple d'un réseau de neurones profond de complexité modeste




- Le réseau de neurones convolutif AlexNet contient
- Huit couches cachées
- Une fonction d'activation non linéaire (ReLU, Leaky ReLU, etc.)
- 62 378 344 paramètres !

# L'interprétabilité des réseaux de neurones est un domaine de recherche actif




- Il faut un expert pour comprendre un résultat et ses implications.
- OBJECTIF : un système expert de nouvelle génération expliquera ses décisions.

# Différences entre modèles interprétables et explicables




- Un modèle interprétable est facile à comprendre pour un humain
- Un modèle explicable ne peut pas être compris exactement de manière simple, mais il existe des stratégies pour analyser les facteurs qui influencent ses prédictions.
- Sa structure est complexe et le nombre de paramètres est élevé.

# Différences entre modèles interprétables et explicables




- Un modèle interprétable est facile à comprendre pour un humain
- Sa structure est simple et le nombre de paramètres est faible.

# Différences entre modèles interprétables et explicables



- Un modèle interprétable est facile à comprendre pour un humain
  - Sa structure est simple et le nombre de paramètres est faible.
- 
- Un modèle explicable ne peut pas être compris exactement de manière simple, mais il existe des stratégies pour analyser les facteurs qui influencent ses prédictions.

# Différences entre modèles interprétables et explicables




- Un modèle interprétable est facile à comprendre pour un humain
  - Sa structure est simple et le nombre de paramètres est faible.
- 
- Un modèle explicable ne peut pas être compris exactement de manière simple, mais il existe des stratégies pour analyser les facteurs qui influencent ses prédictions.
  - Sa structure est complexe et le nombre de paramètres est élevé.

# Quels sont les facteurs importants d'un modèle ?

- Les modèles interprétables identifient souvent des facteurs importants
  - Régression linéaire
  - Régression logistique
  - Arbres de décision
- Il existe des méthodes pour expliquer les facteurs localement importants, c.-à-d. pour une donnée particulière
  - LIME (Ribeiro *et al.*, 2016)
  - SHAP (Lundberg and Lee, 2017)
  - DeepLIFT (Shrikumar *et al.*, 2017)


# Exemple d'application de LIME pour les images



**Figure 4:** Explaining an image classification prediction made by Google's Inception network, highlighting positive pixels. The top 3 classes predicted are "Electric Guitar" ( $p = 0.32$ ), "Acoustic guitar" ( $p = 0.24$ ) and "Labrador" ( $p = 0.21$ )

- Pour l'image ci-dessus, LIME fait ceci


# Exemple d'application de LIME pour les images



**Figure 4:** Explaining an image classification prediction made by Google's Inception network, highlighting positive pixels. The top 3 classes predicted are "Electric Guitar" ( $p = 0.32$ ), "Acoustic guitar" ( $p = 0.24$ ) and "Labrador" ( $p = 0.21$ )

- Pour l'image ci-dessus, LIME fait ceci
- Détermine les trois classes les plus probables associées à l'image.


# Exemple d'application de LIME pour les images



**Figure 4:** Explaining an image classification prediction made by Google's Inception network, highlighting positive pixels. The top 3 classes predicted are "Electric Guitar" ( $p = 0.32$ ), "Acoustic guitar" ( $p = 0.24$ ) and "Labrador" ( $p = 0.21$ )

- Pour l'image ci-dessus, LIME fait ceci
- Détermine les trois classes les plus probables associées à l'image.
- Identifie, dans une couche donnée, les attributs x importants (c.-à-d. les neurones)

# Exemple d'application de LIME pour les images




**Figure 4:** Explaining an image classification prediction made by Google's Inception network, highlighting positive pixels. The top 3 classes predicted are "Electric Guitar" ( $p = 0.32$ ), "Acoustic guitar" ( $p = 0.24$ ) and "Labrador" ( $p = 0.21$ )

- Pour l'image ci-dessus, LIME fait ceci
- Détermine les trois classes les plus probables associées à l'image.
- Identifie, dans une couche donnée, les attributs  $x$  importants (c.-à-d. les neurones)
- Masque les zones de l'image où ces attributs ont un effet négligeable.

# L'importance d'expliquer un modèle

- Si vous ne pouvez pas expliquer une chose simplement, c'est que vous ne la comprenez pas assez bien.



- C'est vrai en relativité, en mathématiques, en génomique, en biochimie, et aussi en apprentissage automatique.

# Diagnostic des courbes d'entraînement



- Le stéthoscope de l'AA : la courbe de la fonction de perte

## Qu'est-ce qui est préférable pour un classifieur fraîchement entraîné ?

- Ces résultats basés sur deux figures sont difficiles à interpréter !
- Cas A
  - 99 % de précision (accuracy) d'entraînement
  - 80 % de précision de validation
- Cas B
  - 85 % de précision d'entraînement
  - 80 % de précision de validation
- Cas C
  - 30 % de précision d'entraînement
  - 25 % de précision de validation



## Qu'est-ce qui est préférable pour un classifieur fraîchement entraîné ?

- Ces résultats basés sur deux figures sont difficiles à interpréter !
- Cas A
  - 99 % de précision (accuracy) d'entraînement
  - 80 % de précision de validation
- Cas B
  - 85 % de précision d'entraînement
  - 80 % de précision de validation
- Cas C
  - 30 % de précision d'entraînement
  - 25 % de précision de validation



- Surapprentissage (overfitting)



- Optimal




- Sous-apprentissage (underfitting)



# Le stéthoscope de l'AA


- Pour un médecin, l'évolution de la température d'un patient est souvent plus utile que sa température actuelle.



- Il ne suffit pas de se satisfaire de la performance finale d'un modèle pour décider s'il est bien entraîné ; il faut aussi regarder ses différentes « tracer de température » :
  - L'évolution de la fonction de perte
  - L'évolution de la métrique de performance


## Courbe d'apprentissage :

- Tracé de la performance d'apprentissage en fonction du temps.




- Seuls les algorithmes qui apprennent de manière incrémentale ont une telle tracer.

## Courbes d'entraînement typiques des modèles « en santé »




# Évolution générale d'une fonction de perte




- Un entraînement typique comporte trois phases :

# Évolution générale d'une fonction de perte




- Un entraînement typique comporte trois phases :
- Sous-apprentissage : le modèle est peu performant sur les deux ensembles de données, mais s'améliore lentement.

# Évolution générale d'une fonction de perte




- Un entraînement typique comporte trois phases :
- Sous-apprentissage : le modèle est peu performant sur les deux ensembles de données, mais s'améliore lentement.
- Meilleur compromis (tradeoff) entre mémorisation et compréhension des données.

# Évolution générale d'une fonction de perte



- Un entraînement typique comporte trois phases :
- Sous-apprentissage : le modèle est peu performant sur les deux ensembles de données, mais s'améliore lentement.
- Meilleur compromis (tradeoff) entre mémorisation et compréhension des données.
- Surapprentissage : le modèle mémorise les données d'entraînement, mais ne peut plus correctement prédire les données de validation.


# Exemple d'une tracé de fonction de perte pour un entraînement normal



- Où commence le surapprentissage ?


# Évolution générale d'une métrique de performance

- L'entraînement devrait être arrêté quand le meilleur compromis entre mémorisation et compréhension des données est atteint.
- C'est la méthode de l'arrêt prématuré (early stopping).



# Différents symptômes et leurs solutions


- Entraînement trop court




- Les courbes d'entraînement et de validation ont un comportement similaire et une performance médiocre.

# Différents symptômes et leurs solutions

- Entraînement trop court




- Les courbes d'entraînement et de validation ont un comportement similaire et une performance médiocre.




# Différents symptômes et leurs solutions

- Entraînement trop court



- Les courbes d'entraînement et de validation ont un comportement similaire et une performance médiocre.
  - Solution : entraîner plus longtemps !



# Taux d'apprentissage convergent du réseau

- Dans l'algorithme de descente de gradient, les paramètres  $\theta$  d'un modèle sont mis à jour selon

$$\theta = \theta - \eta^* \nabla_{\theta} J(\theta)$$


- où  $\eta$  est le taux d'apprentissage (learning rate) et  $J(\theta)$  est la fonction de perte.
- Le taux d'apprentissage est l'un des hyperparamètres les plus importants lors de l'entraînement d'un modèle.

# Taux d'apprentissage convergent du réseau


- Dans l'algorithme de descente de gradient, les paramètres  $\theta$  d'un modèle sont mis à jour selon

$$\theta = \theta - \eta^* \nabla_{\theta} J(\theta)$$

- où  $\eta$  est le taux d'apprentissage (learning rate) et  $J(\theta)$  est la fonction de perte.
- Le taux d'apprentissage est l'un des hyperparamètres les plus importants lors de l'entraînement d'un modèle.




# Ensemble d'entraînement trop petit



- Itérations

- Ensemble d'entraînement trop petit :
- Pas assez varié en termes de données.
- Le modèle entraîné reconnaît peu de données de l'ensemble de validation ; il ne peut pas faire de bonnes prédictions


# Ensemble d'entraînement trop petit



- Itérations


- Ensemble d'entraînement trop petit :
- Pas assez varié en termes de données.
- Le modèle entraîné reconnaît peu de données de l'ensemble de validation ; il ne peut pas faire de bonnes prédictions
- Solutions :
- Augmenter le nombre de données
- Uniformiser les deux ensembles
- Mélanger les données d'entraînement pour éviter les erreurs périodiques.

## Ensembles d'entraînement et de validation trop différents




- Le modèle entraîné reconnaît peu de données de l'ensemble de validation ;

## Ensembles d'entraînement et de validation trop différents




- Le modèle entraîné reconnaît peu de données de l'ensemble de validation ;
- Il ne peut pas faire de bonnes prédictions.

## Ensembles d'entraînement et de validation trop différents




- Le modèle entraîné reconnaît peu de données de l'ensemble de validation ;
- Il ne peut pas faire de bonnes prédictions.
- Exemple : l'ensemble d'entraînement contient des données anciennes et l'ensemble de validation des données récentes.

# Ensembles d'entraînement et de validation trop différents



- Le modèle entraîné reconnaît peu de données de l'ensemble de validation ;
- Il ne peut pas faire de bonnes prédictions.
- Exemple : l'ensemble d'entraînement contient des données anciennes et l'ensemble de validation des données récentes.
- Solutions :
  - Uniformiser les ensembles de données avant de les séparer en ensembles d'entraînement et de validation.


## Ensemble de validation trop petit



- Les statistiques basées sur un ensemble de validation trop petit sont bruitées.
- Les deux ensembles peuvent être stratifiés différemment.

- Époques


# Ensemble de validation trop petit



- Époques

- Les statistiques basées sur un ensemble de validation trop petit sont bruitées.
- Les deux ensembles peuvent être stratifiés différemment.
- Solutions :
  - Augmenter le nombre de données
  - Uniformiser les deux ensembles


# Ensemble de validation trop facile



- Époques

- Parfois, l'ensemble de validation contient les données les plus fréquentes.
- Elles sont faciles à traiter pour le modèle et peu d'erreurs sont observées.
- La performance en validation est meilleure qu'en entraînement !


# Ensemble de validation trop facile



- Époques


- Parfois, l'ensemble de validation contient les données les plus fréquentes.
- Elles sont faciles à traiter pour le modèle et peu d'erreurs sont observées.
- La performance en validation est meilleure qu'en entraînement !
- Solutions :
  - Augmenter le nombre de données
  - Uniformiser les deux ensembles

# Courbe de perte ou courbe de métrique de performance pour savoir quand arrêter ?



- Fonction de perte :
  - Ne capture pas toujours ce qui est le plus important.
  - Fonction dérivable qui se comporte de manière « similaire » à la métrique.
  - Sert uniquement à l'optimisation.

# Courbe de perte ou courbe de métrique de performance pour savoir quand arrêter ?



- Fonction de perte :
  - Ne capture pas toujours ce qui est le plus important.
  - Fonction dérivable qui se comporte de manière « similaire » à la métrique.
  - Sert uniquement à l'optimisation.
- Métrique de performance :
  - Définit le mieux la performance du modèle.
  - Dépend de l'usage prévu du modèle.

# Métriques de performance

- Qu'est-ce qu'une métrique de performance ?
- Une façon de quantifier la performance d'un modèle d'apprentissage automatique.

# Métriques de performance

- Qu'est-ce qu'une métrique de performance ?
- Une façon de quantifier la performance d'un modèle d'apprentissage automatique.
- Remarque : fonction de perte (loss function)  $\neq$  métrique de performance
  - La fonction de perte est utilisée pendant l'entraînement.
  - La métrique de performance est utilisée à la fin pour évaluer le modèle final.

# Différentes métriques

- Régression
  - $R^2$
  - $R^2$  ajusté
  - MAE
  - MSE
  - RMSE
  - ...
- Classification
  - Exactitude (accuracy)
  - Précision
  - Sensibilité
  - Spécificité
  - ROC/AUC
  - ...

# Différentes métriques

- Régression
  - $R^2$
  - $R^2$  ajusté
  - MAE
  - MSE
  - RMSE
  - ...
- Classification
  - Exactitude (accuracy)
  - Précision
  - Sensibilité
  - Spécificité
  - ROC/AUC
  - ...




# Propriétés des métriques

- Les métriques sont souvent de meilleures évaluations pour comparer des modèles
  - Une fonction/valeur qui fournisse des valeurs plus compréhensibles est souhaitée
  - Comparaison entre jeux de données
  - Comparaison entre modèles
- Le MSE n'est pas idéal pour cela
  - Les valeurs sont très sensibles aux jeux de données

# Erreur quadratique moyenne (MSE)

- MSE pour Mean Squared Error.
- Il s'agit de la variance des erreurs du modèle
- Elle est sensible aux grands différence entre les prédictions du modèle et les cibles.

$$MSE = \frac{1}{N} \sum_{i=1}^N \left( \underbrace{y_i - \hat{y}_i}_{\text{Erreur résiduelle}} \right)^2$$



## Racine de l'erreur quadratique moyenne (RMSE)


- RMSE pour Root Mean Squared Error.
- C'est l'écart-type des erreurs du modèle.
- Elle est sensible aux grands différence entre les prédictions du modèle et les cibles.

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N \left( \underbrace{y_i - \hat{y}_i}_{\text{Erreur résiduelle}} \right)^2}$$

# Erreur absolue moyenne (MAE)

- MAE pour Mean Absolute Error.
- Elle est robuste aux grands différence entre les prédictions du modèle et les observations.
- Raison : la valeur absolue de l'erreur résiduelle a moins d'effet sur le MAE que le carré de l'erreur sur le MSE et le RMSE.

$$MAE = \frac{1}{N} \sum_{i=1}^N \left| \underbrace{y_i - \hat{y}_i}_{\text{Erreur résiduelle}} \right|$$



# Coefficient de détermination R carré ( $R^2$ )


- Méthode de calcul :

Si  $\bar{y}$  est la moyenne des données observées :

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{\sum_{i=1}^N (\hat{y}_i - y_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}$$

- Quand  $SSE = 0$ , les données sont bien expliquées
- Quand  $SSE = SST$ , les données ne sont pas bien expliquées



- Exemple pour un modèle linéaire

## Coefficient de détermination R carré ( $R^2$ )

- Il quantifie la proximité des données au modèle ajusté.
- Plus la valeur de  $R^2$  est grande, s'approchant de 1, plus le modèle explique la variabilité des données.

$$R^2 = 1 - \frac{\text{Variance expliquée}}{\text{Variance totale}}$$


- [https://en.wikipedia.org/wiki/Coefficient\\_of\\_determination](https://en.wikipedia.org/wiki/Coefficient_of_determination)

# Exemples



$$R \in [-1, 1]$$

$$R^2 \in [0, 1]$$



- où  $R$  est le coefficient de corrélation entre deux ensembles de données.
- Plus le  $R^2$  est grand, meilleure est la correspondance entre
- Les prédictions d'un modèle et les observations




$$R^2 = 0.990$$



$$R^2 = 0.494$$



$$R^2 = 0.022$$



## R carré ajusté

- La métrique  $R^2$  a tendance à surestimer la qualité de la régression linéaire.
- Le  $R^2$  ajusté pénalise l'ajout d'attributs x supplémentaires qui n'améliorent pas un modèle.

## R carré ajusté

- La métrique  $R^2$  a tendance à surestimer la qualité de la régression linéaire.
- Le  $R^2$  ajusté pénalise l'ajout d'attributs x supplémentaires qui n'améliorent pas un modèle.

$$R^2 = 1 - \frac{SSE}{SST}$$



$$R^2_{\text{ajusté}} = 1 - \left( \frac{N-1}{N-p} \right) \frac{SSE}{SST}$$

$$R^2_{\text{ajusté}} \leq R^2$$

- N : nombre de données
- p : nombre de paramètres d'un modèle

## Quelle métrique choisir ?

- En général, le  $R^2$  et une mesure d'erreur, par ex. le RMSE.
- Le  $R^2$  exprime le pourcentage de la variance des données expliqué par un modèle.
- Le RMSE donne l'écart-type des erreurs de prédiction du modèle.

# Classification

- Le choix de la métrique dépend de l'usage prévu
- Exemple de matrice de confusion pour des sujets atteints de la Covid-19
- Il est supposé que 80 % des sujets à tester ont la maladie.
- Les chiffres sont ramenés à une population de 100 individus.

100 people at risk of covid-19  
Pre-test probability 80%



80 people have covid-19

20 people do not have covid-19

They are tested for covid-19  
using the RT-PCR test:



57 people have a test result suggesting that  
they have covid-19 (test positive)

43 people have a test result suggesting that  
they do not have covid-19 (test negative)

But who actually has covid-19?



## Diagnosis

56 people who test  
positive have covid-19  
("true positive")

1 person who tests positive  
does not have covid-19  
("false positive")

24 people who test  
negative have covid-19  
("false negative")

19 people who test negative  
do not have covid-19  
("true negative")

## Consequences

Appropriately told to  
self-isolate

Told they need to self-isolate  
when they would be safe to  
go out

Told they do not need to  
self-isolate and so go out and  
infect more people

Told they do not need to  
self-isolate and are safe to go  
out without infecting more  
people

# Matrice de confusion

- Matrice de confusion : Explication des erreurs lors d'une classification binaire.
- La matrice n'est pas une métrique ; elle aide à calculer plusieurs métriques.




- Nombre de bonnes classifications :  $VP + VN$
- Nombre d'erreurs :  $FN + FP$

|                          | Prédit positif ( $\hat{Y} = 1$ ) | Prédit négatif ( $\hat{Y} = 0$ ) |
|--------------------------|----------------------------------|----------------------------------|
| Réel positif ( $Y = 1$ ) | Vrais positifs (VP)              | Faux négatifs (FN)               |
| Réel négatif ( $Y = 0$ ) | Faux positifs (FP)               | Vrais négatifs (VN)              |

# Le choix de la métrique dépend de l'usage prévu

- Exemple de matrice de confusion pour des sujets atteints de la Covid-19
- Il est supposé que 80% des sujets à tester ont la maladie.
- Les chiffres (figures) sont ramenés à une population de 100 individus.



|              |                     | Classe prédite                   |                                  |
|--------------|---------------------|----------------------------------|----------------------------------|
|              |                     | Positif ( $\hat{Y} = 1$ )        | Négatif ( $\hat{Y} = 0$ )        |
| Vraie classe | Positif ( $Y = 1$ ) | Vrais positifs (VP)<br><b>56</b> | Faux négatifs (FN)<br><b>24</b>  |
|              | Négatif ( $Y = 0$ ) | Faux positifs (FP)<br><b>1</b>   | Vrais négatifs (VN)<br><b>19</b> |

- Matrice de confusion correspondante

# Exactitude (Accuracy)

- C'est la métrique la plus intuitive.
- Elle indique la fraction de prédictions correctes, parmi toutes les prédictions faites.
- Exemple : sur les 100 personnes testées, 75 ont reçu un diagnostic correct.

|              |                     | Classe prédite                   |                                  |
|--------------|---------------------|----------------------------------|----------------------------------|
|              |                     | Positif ( $\hat{Y} = 1$ )        | Négatif ( $\hat{Y} = 0$ )        |
| Vraie classe | Positif ( $Y = 1$ ) | Vrais positifs (VP)<br><b>56</b> | Faux négatifs (FN)<br><b>24</b>  |
|              | Négatif ( $Y = 0$ ) | Faux positifs (FP)<br><b>1</b>   | Vrais négatifs (VN)<br><b>19</b> |

{

$$\begin{aligned}\text{Exactitude} &= \frac{\text{Nombre de bonnes classifications}}{\text{Nombre total d'exemples}} \\ &= \frac{56 + 19}{56 + 19 + 1 + 24} \\ &= 75\%\end{aligned}$$

}

## Exactitude (Accuracy)

- Pour certaines maladies rares, une exactitude d'environ 95 % est parfois observée.

## Exactitude (Accuracy)

- Pour certaines maladies rares, une exactitude d'environ 95 % est parfois observée.
- Est-ce vraiment une bonne performance de détection ?

# Exactitude (Accuracy)

- Pour certaines maladies rares, une exactitude d'environ 95 % est parfois observée.
- Est-ce vraiment une bonne performance de détection ?
- Dans le cas de données déséquilibrées, l'exactitude n'est pas une métrique utile.



# Exactitude (Accuracy)

- Pour certaines maladies rares, une exactitude d'environ 95 % est parfois observée.
- Est-ce vraiment une bonne performance de détection ?
- Dans le cas de données déséquilibrées, l'exactitude n'est pas une métrique utile.
- Exemple pour une maladie rare :



# Exactitude (Accuracy)

- Pour certaines maladies rares, une exactitude d'environ 95 % est parfois observée.
- Est-ce vraiment une bonne performance de détection ?
- Dans le cas de données déséquilibrées, l'exactitude n'est pas une

métrique utile.



- Exemple pour une maladie rare :
- 1000 sujets testés : 950 en santé et 50 malades

# Exactitude (Accuracy)

- Pour certaines maladies rares, une exactitude d'environ 95 % est parfois observée.
- Est-ce vraiment une bonne performance de détection ?
- Dans le cas de données déséquilibrées, l'exactitude n'est pas une

métrique utile.



- Exemple pour une maladie rare :
- 1000 sujets testés : 950 en santé et 50 malades
- Un test bidon, qui indique toujours un sujet en santé, a raison 950 fois sur 1000, soit 95 % d'exactitude !

## Rappel (Recall)

- Rappel (ou sensibilité) : probabilité d'une prédiction positive pour un cas positif.
- En médecine, cela correspond à la probabilité d'identifier les patients malades.
- Exemple : 80 personnes atteintes de la Covid-19 ont été testées et 56 ont reçu un diagnostic positif.

|              |                     | Classe prédite                   |                                  |
|--------------|---------------------|----------------------------------|----------------------------------|
|              |                     | Positif ( $\hat{Y} = 1$ )        | Négatif ( $\hat{Y} = 0$ )        |
| Vraie classe | Positif ( $Y = 1$ ) | Vrais positifs (VP)<br><b>56</b> | Faux négatifs (FN)<br><b>24</b>  |
|              | Négatif ( $Y = 0$ ) | Faux positifs (FP)<br><b>1</b>   | Vrais négatifs (VN)<br><b>19</b> |

$$\begin{aligned}\text{Rappel} &= \frac{VP}{VP + FN} \\ &= \frac{56}{56 + 24} \\ &= 70\%\end{aligned}$$

# Précision (Precision)

- Précision : probabilité d'une prédiction positive parmi les points prédits positifs.
- En médecine, cela correspond à la probabilité que les patients diagnostiqués malades le soient réellement.
- Exemple : 57 personnes ont reçu un diagnostic positif pour la Covid-19 alors que seules 56 l'avaient réellement.

|              |                     | Classe prédite                   |                                  |
|--------------|---------------------|----------------------------------|----------------------------------|
|              |                     | Positif ( $\hat{Y} = 1$ )        | Négatif ( $\hat{Y} = 0$ )        |
| Vraie classe | Positif ( $Y = 1$ ) | Vrais positifs (VP)<br><b>56</b> | Faux négatifs (FN)<br><b>24</b>  |
|              | Négatif ( $Y = 0$ ) | Faux positifs (FP)<br><b>1</b>   | Vrais négatifs (VN)<br><b>19</b> |

$$\begin{aligned}\text{Précision} &= \frac{VP}{VP + FP} \\ &= \frac{56}{56 + 1} \\ &= 98\%\end{aligned}$$

## Précision ou rappel ; lequel choisir ?

- Cela dépend des besoins de l'utilisateur :

## Précision ou rappel ; lequel choisir ?

- Cela dépend des besoins de l'utilisateur :
- Minimiser les faux positifs  $\Rightarrow$  Précision

## Précision ou rappel ; lequel choisir ?

- Cela dépend des besoins de l'utilisateur :
- Minimiser les faux positifs  $\Rightarrow$  Précision
- Exemple : circuits intégrés faussement identifiés comme défectueux sur une

chaîne d'assemblage.



# Précision ou rappel ; lequel choisir ?

- Cela dépend des besoins de l'utilisateur :
- Minimiser les faux positifs  $\Rightarrow$  Précision
- Exemple : circuits intégrés faussement identifiés comme défectueux sur une



chaîne d'assemblage.

- Minimiser les faux négatifs  $\Rightarrow$  Rappel

# Précision ou rappel ; lequel choisir ?

- Cela dépend des besoins de l'utilisateur :
- Minimiser les faux positifs  $\Rightarrow$  Précision
- Exemple : circuits intégrés faussement identifiés comme défectueux sur une

chaîne d'assemblage.



- Minimiser les faux négatifs  $\Rightarrow$  Rappel



- Exemple : patients atteints de cancers non détectés.

# Spécificité

- Spécificité : probabilité d'une prédiction négative pour un cas négatif.
- En médecine, cela correspond à la probabilité de ne pas identifier des patients non malades comme malades.
- Exemple : 20 personnes sans Covid-19 ont été testées et 19 ont reçu un diagnostic négatif.

|              |                     | Classe prédite                   |                                  |
|--------------|---------------------|----------------------------------|----------------------------------|
|              |                     | Positif ( $\hat{Y} = 1$ )        | Négatif ( $\hat{Y} = 0$ )        |
| Vraie classe | Positif ( $Y = 1$ ) | Vrais positifs (VP)<br><b>56</b> | Faux négatifs (FN)<br><b>24</b>  |
|              | Négatif ( $Y = 0$ ) | Faux positifs (FP)<br><b>1</b>   | Vrais négatifs (VN)<br><b>19</b> |

$$\begin{aligned}\text{Spécificité} &= \frac{VN}{VN + FP} \\ &= \frac{19}{19 + 1} \\ &= 95\%\end{aligned}$$

# Résumé des principales métriques d'intérêt

## condition positive (P)

the number of real positive cases in the data

## condition negative (N)

the number of real negative cases in the data

## true positive (TP)

A test result that correctly indicates the presence of a condition or characteristic

## true negative (TN)

A test result that correctly indicates the absence of a condition or characteristic

## false positive (FP)

A test result which wrongly indicates that a particular condition or attribute is present

## false negative (FN)

A test result which wrongly indicates that a particular condition or attribute is absent

## sensitivity, recall, hit rate, or true positive rate (TPR)

$$\text{TPR} = \frac{\text{TP}}{P} = \frac{\text{TP}}{\text{TP} + \text{FN}} = 1 - \text{FNR}$$

## specificity, selectivity or true negative rate (TNR)

$$\text{TNR} = \frac{\text{TN}}{N} = \frac{\text{TN}}{\text{TN} + \text{FP}} = 1 - \text{FPR}$$

## precision or positive predictive value (PPV)

$$\text{PPV} = \frac{\text{TP}}{\text{TP} + \text{FP}} = 1 - \text{FDR}$$

## negative predictive value (NPV)

$$\text{NPV} = \frac{\text{TN}}{\text{TN} + \text{FN}} = 1 - \text{FOR}$$

## miss rate or false negative rate (FNR)

$$\text{FNR} = \frac{\text{FN}}{P} = \frac{\text{FN}}{\text{FN} + \text{TP}} = 1 - \text{TPR}$$

## fall-out or false positive rate (FPR)

$$\text{FPR} = \frac{\text{FP}}{N} = \frac{\text{FP}}{\text{FP} + \text{TN}} = 1 - \text{TNR}$$

## false discovery rate (FDR)

$$\text{FDR} = \frac{\text{FP}}{\text{FP} + \text{TP}} = 1 - \text{PPV}$$

## false omission rate (FOR)

$$\text{FOR} = \frac{\text{FN}}{\text{FN} + \text{TN}} = 1 - \text{NPV}$$

## Métriques de classification basées sur l'aire sous la courbe


- Avec un modèle donnant la probabilité d'appartenance à une classe d'intérêt, le seuil peut être ajusté pour classifier les données.
- Chaque seuil mène à une matrice de confusion.

## Métriques de classification basées sur l'aire sous la courbe

- Avec un modèle donnant la probabilité d'appartenance à une classe d'intérêt, le seuil peut être ajusté pour classer les données.
- Chaque seuil mène à une matrice de confusion.
- Pour chacun, des métriques sont calculées.

# Métriques de classification basées sur l'aire sous la courbe

- Avec un modèle donnant la probabilité d'appartenance à une classe d'intérêt, le seuil peut être ajusté pour classifier les données.
- Chaque seuil mène à une matrice de confusion.
- Pour chacun, des métriques sont calculées.



- L'effet de chaque seuil peut être visualisé à l'aide de graphiques affichant les métriques.
- L'aire sous la courbe (AUC) est une nouvelle métrique !
- Seuil de probabilité

# La courbe ROC

- ROC : Receiver Operating Characteristic

# La courbe ROC


- ROC : Receiver Operating Characteristic
- L'AUC représente la probabilité qu'un positif contre un négatif soit décidé correctement.

# La courbe ROC

- ROC : Receiver Operating Characteristic
- L'AUC représente la probabilité qu'un positif contre un négatif soit décidé correctement.
- Le classifieur avec la plus grande aire sous la courbe est le meilleur.


# La courbe ROC

- ROC : Receiver Operating Characteristic
- L'AUC représente la probabilité qu'un positif contre un négatif soit décidé correctement.
- Le classifieur avec la plus grande aire sous la courbe est le meilleur.
- Cette métrique est la plus utilisée en cas de déséquilibre des classes.




# Un dernier exemple

- Exemple d'une matrice de confusion pour des sujets atteints du cancer du sein
- Le test a une sensibilité et une spécificité d'environ 90 % (source : 3Blue1Brown)



# Exemple d'une matrice de confusion pour des sujets atteints du cancer du sein


- Le test a une sensibilité et une spécificité d'environ  $\sim 90\%$



- Question :
- Une femme de 50 ans sans symptômes participe à un test de routine et obtient un résultat positif, quelle est la probabilité qu'elle ait un cancer du sein ?
- 100 %, 90 %, 50 %, 10 %, 0 %

# Exemple d'une matrice de confusion pour des sujets atteints du cancer du sein

- Le test a une sensibilité et une spécificité d'environ  $\sim 90\%$




- Question :
- Une femme de 50 ans sans symptômes participe à un test de routine et obtient un résultat positif, quelle est la probabilité qu'elle ait un cancer du sein ?
- 100 %, 90 %, 50 %, 10 %, 0 %

Réponse : - 10 %

## Exemple d'une matrice de confusion pour des sujets atteints du cancer du sein

$$P(A \text{ le cancer} \mid \text{test positif}) \approx \frac{9}{9 + 89} \approx \frac{1}{11}$$

- Le test a une sensibilité et une spécificité d'environ 90 %



# Conclusion

- Un test détermine si vous êtes positif ou non.

# Conclusion

- Un test détermine si vous êtes positif ou non.
- Un test détermine la probabilité d'être positif

# Conclusion

- Un test détermine si vous êtes positif ou non.
- Un test détermine la probabilité d'être positif
- Un test met à jour la probabilité d'être positif

## Quiz/Sondage

- (A) précision, (B) rappel, (C) spécificité, ou (D) exactitude
- Cas d'usage : imaginez développer un service de courriel où il est essentiel de minimiser le nombre de courriels légitimes marqués à tort comme pourriel.

## Quiz/Sondage

- (A) précision, (B) rappel, (C) spécificité, ou (D) exactitude
- Cas d'usage : imaginez développer un service de courriel où il est essentiel de minimiser le nombre de courriels légitimes marqués à tort comme pourriel.
- Cas d'usage : considérez un modèle d'apprentissage automatique conçu pour dépister des patients pour une maladie mortelle mais traitable, comme un type spécifique de cancer.

## Quiz/Sondage

- (A) précision, (B) rappel, (C) spécificité, ou (D) exactitude
- Cas d'usage : imaginez développer un service de courriel où il est essentiel de minimiser le nombre de courriels légitimes marqués à tort comme pourriel.
- Cas d'usage : considérez un modèle d'apprentissage automatique conçu pour dépister des patients pour une maladie mortelle mais traitable, comme un type spécifique de cancer.
- Cas d'usage : une institution financière veut construire un modèle pour détecter les transactions frauduleuses par carte de crédit et les bloquer en temps réel. L'objectif est de prévenir la fraude sans incommoder un grand nombre de clients légitimes.

## Quiz/Sondage

- (A) précision, (B) rappel, (C) spécificité, ou (D) exactitude
- Cas d'usage : imaginez développer un service de courriel où il est essentiel de minimiser le nombre de courriels légitimes marqués à tort comme pourriel.
- Cas d'usage : considérez un modèle d'apprentissage automatique conçu pour dépister des patients pour une maladie mortelle mais traitable, comme un type spécifique de cancer.
- Cas d'usage : une institution financière veut construire un modèle pour détecter les transactions frauduleuses par carte de crédit et les bloquer en temps réel. L'objectif est de prévenir la fraude sans incommoder un grand nombre de clients légitimes.
- Cas d'usage : une entreprise de commerce électronique développe un système pour classifier automatiquement les images de ses produits dans de larges catégories bien représentées, telles que « vêtements », « électronique », « articles pour la maison » et « livres ».

## Quiz/Sondage

- Pourquoi le  $R^2$  est-il plus facile à utiliser que le RMSE pour évaluer un modèle de régression ?
- (A) le  $R^2$  est toujours positif, (B) le  $R^2$  est plus rapide à calculer, (C) le  $R^2$  exprime un pourcentage, ou (D) il est plus précis que l'écart-type des erreurs du modèle

Plus de détails sur cet exemple et sur les tests statistiques dans les prochains cours.

Scott M Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, 2017.

Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. "Why should I trust you?": Explaining the predictions of any classifier. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 1135–1144, 2016.

Avanti Shrikumar, Peyton Greenside, and Anshul Kundaje. Learning important features through propagating activation differences. In *International Conference on Machine Learning*, pages 3145–3153, 2017.