

Apprentissage pour la science des données

Cours 7 : Traitement et augmentation des données

Glen Berseth

Université de Montréal et Institut québécois d'intelligence artificielle (Mila)

September 23, 2026



Université
de Montréal



Mila

CIFAR

Plan


Qu'est-ce qu'une caractéristique (feature) ?

Motivations de l'ingénierie des caractéristiques (feature engineering)

Nettoyage des données

Transformation des données

Qu'est-ce qu'une caractéristique (feature) ?




1

- Entrée : x
- Numérique
- Caractéristiques extraites (extracted features): $\varphi(x)$

¹source: <https://learnopencv.com/histogram-of-oriented-gradients/>

Motivations de l'ingénierie des caractéristiques (feature engineering)




- Rendre les données séparables
- Impossible de les séparer avec un classifieur linéaire
 - Utiliser un modèle plus complexe ou une autre option ?


²Source: <https://www.slideshare.net/0xdata/feature-engineering-83511751>

Un exemple simple



- Changement de coordonnées



Cartesian coordinates




Polar coordinates



3

³Source: <https://www.slideshare.net/0xdata/feature-engineering-83511751>

Similaire à l'ingénierie des invites (prompt engineering)




- Mais, de façon plus formelle

⁴Source: <https://kripeshadwani.com/what-is-prompt-engineering/>

Quelques citations

- « Trouver de bonnes caractéristiques est difficile, cela prend du temps et requiert une expertise de spécialiste. L'*apprentissage automatique appliqué* n'est essentiellement rien d'autre que de l'ingénierie des caractéristiques. » Andrew Ng
- « Une bonne préparation des données et une bonne ingénierie des caractéristiques sont indispensables à de meilleures prédictions. » Marios Michailidis (KazAnova), Grand Maître Kaggle, Kaggle n° 3, ancien n° 1

Cycle de l'ingénierie des caractéristiques




5

- Pas d'ingénierie des caractéristiques
 - Collecte des données
 - Création de la variable cible
 - Suppression des doublons (duplicates)
 - Correction des classes mal étiquetées (labels)


⁵Source: <https://www.slideshare.net/0xdata/feature-engineering-83511751>

Cycle de l'ingénierie des caractéristiques



- Comment ?
 - Connaissance approfondie du domaine
 - Expérience préalable
 - Analyse exploratoire des données (EDA)
 - Rétroaction (feedback) du modèle d'apprentissage automatique

Cycle de l'ingénierie des caractéristiques



- Comment?
 - Validation croisée (cross-validation)
 - Mesure des métriques
 - Éviter la fuite de données (leakage)

L'ingénierie des caractéristiques est difficile

- Des transformations de caractéristiques puissantes (comme l'encodage de la cible (target encoding)) peuvent introduire une fuite de données si elles sont mal appliquées
- Nécessite généralement une connaissance du domaine sur la façon dont les caractéristiques interagissent (interact) entre elles
- Prend du temps ; nécessite de mener des milliers d'expériences


L'ingénierie des caractéristiques est difficile

- Des transformations de caractéristiques puissantes (comme l'encodage de la cible (target encoding)) peuvent introduire une fuite de données si elles sont mal appliquées
- Nécessite généralement une connaissance du domaine sur la façon dont les caractéristiques interagissent (interact) entre elles
- Prend du temps ; nécessite de mener des milliers d'expériences
- Pourquoi l'ingénierie des caractéristiques est importante
 - Extraire de nouvelles caractéristiques de grande valeur, retirer les caractéristiques non pertinentes ou bruitées
 - Des modèles plus simples avec de meilleurs résultats
 - Objectif : trouver une transformation globale qui rend les données plus faciles à comprendre.

Nettoyage des données



La préparation des données occupe une bonne partie du temps d'un scientifique des données.



What data scientists spend the most time doing

- Building training sets: 3%
- Cleaning and organizing data: 60%
- Collecting data sets: 19%
- Mining data for patterns: 9%
- Refining algorithms: 4%
- Other: 5%

- $60 + 19 + 3 = 82\%$!


- source:

<https://www.forbes.com/sites/gilpress/2016/03/23/data-preparation-most-time-consuming-least-enjoyable-data-science-task-survey-says/?sh=40ad122b6f63>

Traitement des données manquantes (missing)

- Problème fréquent: bases de données avec des données manquantes.
- Imputation des données (remplacement des données manquantes)
 - Mettre des valeurs génériques (0, Nan)
 - Utilise les distributions des variables x présentes pour prédire les variables x manquantes.
 - Ne fonctionne pas pour cibler y .

- Données connues
- Données manquantes à prédire



Exemple d'une base de données avec des données manquantes


	Caractéristiques (X)					Réponse (Y)
	Surface	Nombre chambres	Quartier résidentiel	...	Nombre écoles	Prix
Maison 1	x_1^1	x_2^1	x_3^1	...	x_{10}^1	250 000
Maison 2	x_1^2	x_2^2	?	...	?	300 000
Maison 3	?	x_2^3	x_3^3	...	x_{10}^3	325 000
...	...	...	...	...	...	...
Maison 100	x_1^{100}	x_2^{100}	x_3^{100}	...	x_{10}^{100}	475 000

- Si nous supprimons les trois colonnes problématiques, nous perdons 30 % des données!
- Besoin de conserver les données


Méthodes d'imputation

- Imputation par la moyenne :
 - Remplacer par la valeur moyenne
- Régression :
 - Entraîner un modèle pour prédire les données manquantes
- Regroupement (clustering):
 - Regrouper les points de données pour trouver des étiquettes de classe
- Substitution :
 - Remplacer par une nouvelle valeur non observée dans les données

- Données connues
- Données manquantes à prédire




Transformation des données




Transformation de la cible

- Transformation de la variable réponse
- À utiliser quand la variable présente une distribution asymétrique, afin de rapprocher les résidus d'une « distribution normale » (courbe en cloche)
- Principalement utile pour les tâches de régression : peut améliorer l'ajustement du modèle
- par exemple, $\log(x)$, $\log(x+1)$, $\sqrt{x}$, $\sqrt{x+1}$, etc.
- Rappel : **de nombreuses méthodes d'entraînement en apprentissage automatique supposent que les données sont gaussiennes, etc.**

Exemple : données immobilières d'Ames



6



⁶Source:

https://scikit-learn.org/stable/auto_examples/compose/plot_transformed_target.html

Transformations des caractéristiques

- Même idée.
- Transformation logarithmique (ou transformation log) :
- Cela aide à traiter les données asymétriques ; après la transformation, la distribution devient plus proche d'une distribution normale.
- Dans la plupart des cas, l'ordre de grandeur des données change au sein de leur plage de valeurs.
- Cela réduit aussi l'effet des valeurs aberrantes, grâce à la normalisation des écarts de grandeur.

Transformations

- Les données que vous soumettez à la transformation logarithmique doivent uniquement comporter des valeurs **positives**, sinon vous obtiendrez une erreur. Vous pouvez également **ajouter 1** à vos données avant de les transformer.
- Cela garantit que le résultat de la transformation est positif.

#Log Transform Example

```
data = pd.DataFrame({'value':[2,45, -23, 85, 28, 2, 35, -12]}))
```

```
data['log+1'] = (data['value']+1).transform(np.log)
```

#Negative Values Handling

#Note that the values are different

```
data['log'] = (data['value']-data['value'].min()+1)  
.transform(np.log)
```

	value	log(x+1)	log(x-min(x)+1)
0	2	1.09861	3.25810
1	45	3.82864	4.23411
2	-23	nan	0.00000
3	85	4.45435	4.69135
4	28	3.36730	3.95124
5	2	1.09861	3.25810
6	35	3.58352	4.07754
7	-12	nan	2.48491

Codage des caractéristiques

- Transformer des caractéristiques catégoriques en caractéristiques numériques afin de fournir une information plus précise
- Aide à capturer explicitement les relations non linéaires et les interactions entre les valeurs des caractéristiques
- La plupart des outils d'apprentissage automatique acceptent uniquement des nombres en entrée., p. ex. xgboost, gbm, glmnet, libsvm, liblinear, etc.

Conversion des valeurs catégoriques en valeurs numériques

- Les variables catégoriques contiennent des catégories qui ne sont pas comparables.
 - P. ex. : Couleur = [Rouge, Vert, Bleu]
- Ces variables sont converties en variables binaires factices. (Encodage à chaud (one-hot encoding))
 - Conserve toute l'information de la variable catégorique.
 - Adapté aux modèles linéaires en apprentissage automatique.



- Augmente la dimensionnalité des variables à traiter (process).
- Peut introduire de l'information redondante.



Chaque catégorie peut être transformée en k variables binaires factices (variables factices)




Figure: alt text

- Exemple : la couleur bleue est codée comme [0, 0, 1]

Chaque catégorie peut être transformée en k variables binaires factices (variables factices)




Figure: alt text

- Exemple : la couleur bleue est codée comme [0, 0, 1]
- Représentation utilisée dans
 - Les méthodes basées sur les arbres de décision
 - Les méthodes de régression linéaire utilisant la sélection de variables

Conversion des valeurs ordinales en valeurs numériques

- Les variables ordinales contiennent des catégories dont l'ordre est important :
 - P. ex. : `note_finale = [A, B, C, D, E]` avec $A > B > C > D > E$
- Elles sont converties en valeurs entières (encodage ordinal)
 - `note_finale = [0, 1, 2, 3, 4]` avec $A = 4, B = 3, \dots$
- Représentation utilisée dans :
 - Les méthodes basées sur les arbres de décision
 - Les méthodes de régression linéaire si
 - Il y a beaucoup de catégories
 - Les valeurs numériques implicites des catégories sont distribuées linéairement

Encodage par fréquence


- Encodage des niveaux catégoriques des caractéristiques en valeurs comprises entre 0 et 1, selon leur fréquence relative

A	0.44 (4 out of 9)
B	0.33 (3 out of 9)
C	0.22 (2 out of 9)

Feature	Encoded Feature
A	0.44
A	0.44
A	0.44
A	0.44
B	0.33
B	0.33
B	0.33
C	0.22
C	0.22

Groupeement (binning)

- Le groupeement peut être appliqué aux données catégoriques comme aux données numériques :
- Exemple



Binning illustration of numerical data

#Numerical Binning Example

Value	Bin
0-30	-> Low
31-70	-> Mid
71-100	-> High

#Categorical Binning Example

Value	Bin
Spain	-> Europe
Italy	-> Europe
Chile	-> South America
Brazil	-> South America

Groupement (binning)

- La principale motivation du groupement est de rendre le modèle plus robuste et d'éviter le surapprentissage (overfitting), ce qui a toutefois un coût en performance.
- Le compromis (tradeoff) entre performance et surapprentissage est un point clé du processus de regroupement.
- Groupement numérique : le groupement peut être redondant en raison de son effet sur la performance du modèle.
- Regroupement catégorique : les étiquettes (labels) à faible fréquence nuisent probablement à la robustesse des modèles statistiques. Donc, l'attribution d'une catégorie générale à ces valeurs moins fréquentes aide à préserver la robustesse du modèle.

Encodage de la moyenne de la cible

- Il est préférable de calculer la moyenne pondérée (weighted) entre la moyenne globale de l'ensemble d'entraînement et la moyenne du niveau :

$$\lambda(n) * \text{moyenne}(\text{niveau}) + (1 - \lambda(n)) * \text{moyenne}(\text{ensemble de données})$$

- Les poids sont basés sur la fréquence des niveaux, c.-à-d. que si une catégorie apparaît seulement quelques fois dans l'ensemble de données, sa valeur codée sera proche de la moyenne globale plutôt que de la moyenne de ce niveau.
- n : nombre d'exemples dans la catégorie

Encodage de la moyenne de la cible

- Plutôt que d'encoder les variables catégoriques et d'augmenter le nombre de caractéristiques, chaque niveau peut être encodé comme la moyenne de la réponse.

A	0.75 (3 out of 4)
B	0.66 (2 out of 3)
C	1.00 (2 out of 2)


Feature	Outcome	MeanEncode
A	1	0.75
A	0	0.75
A	1	0.75
A	1	0.75
B	1	0.66
B	1	0.66
B	0	0.66
C	1	1.00
C	1	1.00

- Idée : donner l'information pertinente directement au modèle ! Problème : peut mener au surapprentissage !!!
- Rappel: Nous avons besoin un number pour entrainement, pas A, B, C

Fonction de lissage λ de l'encodage de la moyenne de la cible

$$\frac{1}{1 + \exp\left(\frac{-(x-k)}{f}\right)}$$

x = frequency
k = inflection
point
f = steepness



Lissage de l'encodage de la moyenne de la cible

$$\lambda = \frac{1}{1 + \exp(-\frac{(x-2)}{0.25})}$$

	x	level	dataset	λ	
A	4	0.75	0.77	0.99	$0.99*0.75 + 0.01*0.77 = 0.7502$
B	3	0.66	0.77	0.98	$0.98*0.66 + 0.02*0.77 = 0.6622$
C	2	1.00	0.77	0.5	$0.5*1.0 + 0.5*0.77 = 0.885$

$$\lambda = \frac{1}{1 + \exp(-\frac{(x-3)}{0.25})}$$


	x	level	dataset	λ	
A	4	0.75	0.77	0.98	$0.98*0.75 + 0.01*0.77 = 0.7427$
B	3	0.66	0.77	0.5	$0.5*0.66 + 0.5*0.77 = 0.715$
C	2	1.00	0.77	0.017	$0.017*1.0 + 0.983*0.77 = 0.773$

Feature	Outcome
A	1
A	0
A	1
A	1
B	1
B	1
B	0
C	1
C	1

Encodage de la moyenne de la cible : schéma leave-one-out

- Pour éviter le surapprentissage, le schéma leave-one-out peut être utilisé


Feature	Outcome
A	1
A	0
A	1
A	1
B	1
B	1
B	0
C	1
C	1



LOOencode
0.66

Encodage de la moyenne de la cible : schéma leave-one-out

- Pour éviter le surapprentissage, le schéma leave-one-out peut être utilisé

Feature	Outcome		LOOencode
A	1		0.66
A	0		1.00
A	1		
A	1		
B	1		
B	1		
B	0		
C	1		
C	1		

Encodage de la moyenne de la cible : schéma leave-one-out

- Pour éviter le surapprentissage, le schéma leave-one-out peut être utilisé

Feature	Outcome		LOOencode
A	1		0.66
A	0		1.00
A	1		0.66
B	1		
B	1		
B	0		
C	1		
C	1		

Encodage de la moyenne de la cible : schéma leave-one-out

- Pour éviter le surapprentissage, le schéma leave-one-out peut être utilisé

Feature	Outcome		LOOencode
A	1		0.66
A	0		1.00
A	1		0.66
A	1		0.66
B	1		
B	1		
B	0		
C	1		
C	1		

Encodage de la moyenne de la cible : schéma leave-one-out

- Pour éviter le surapprentissage, le schéma leave-one-out peut être utilisé

Feature	Outcome	LOOencode
A	1	0.66
A	0	1.00
A	1	0.66
A	1	0.66
B	1	0.50
B	1	0.50
B	0	1.00
C	1	1.00
C	1	1.00



Encodage de la moyenne de la cible

- Quand l'utiliser ?

Encodage de la moyenne de la cible

- Quand l'utiliser ?
- Caractéristiques à forte cardinalité :

Encodage de la moyenne de la cible

- Quand l'utiliser ?
- Caractéristiques à forte cardinalité :
- Les caractéristiques comportant un grand nombre de catégories peuvent être difficiles à encoder : un encodage « one-hot » générerait trop d'alternatives

Encodage de la moyenne de la cible

- Quand l'utiliser ?
- Caractéristiques à forte cardinalité :
- Les caractéristiques comportant un grand nombre de catégories peuvent être difficiles à encoder : un encodage « one-hot » générerait trop d'alternatives
- Un encodage « target » attribue des valeurs numériques aux catégories en s'appuyant sur la propriété la plus importante de l'entité : sa relation avec la cible.

Encodage de la moyenne de la cible

- Quand l'utiliser ?
- Caractéristiques à forte cardinalité :
- Les caractéristiques comportant un grand nombre de catégories peuvent être difficiles à encoder : un encodage « one-hot » générerait trop d'alternatives
- Un encodage « target » attribue des valeurs numériques aux catégories en s'appuyant sur la propriété la plus importante de l'entité : sa relation avec la cible.
- Caractéristiques orientées domaine :

Encodage de la moyenne de la cible

- Quand l'utiliser ?
- Caractéristiques à forte cardinalité :
- Les caractéristiques comportant un grand nombre de catégories peuvent être difficiles à encoder : un encodage « one-hot » générerait trop d'alternatives
- Un encodage « target » attribue des valeurs numériques aux catégories en s'appuyant sur la propriété la plus importante de l'entité : sa relation avec la cible.
- Caractéristiques orientées domaine :
- L'expérience vous amène peut-être à penser qu'une caractéristique catégorielle devrait être importante même si elle donne de mauvais résultats avec une métrique. L'encodage par cible peut aider à révéler la véritable valeur informative d'une

Quiz/Sondage

- Pourquoi faut-il encoder les catégories ordinales comme A, B, C ?
- (A) pour économiser de la mémoire, (B) parce que des valeurs numériques sont nécessaires, (C) parce qu'elles sont plus interprétables pour les humains, ou (D) elles sont plus rapides

- Pourquoi convertir les variables catégoriques comme Couleur = [Rouge, Vert, Bleu] en variables binaires factices (one-hot) ?
- (A) pour réduire le nombre de caractéristiques, (B) pour éliminer l'information redondante, (C) parce que les modèles exigent des valeurs numériques et que les catégories ne sont pas comparables, ou (D) pour rendre les données plus lisibles pour les humains