Apprentissage pour la science des données

Cours 9 : Tests d'hypothèse

Glen Berseth

Université de Montréal et Institut québécois d'intelligence artificielle (Mila)

October 7, 2026



Plan

Comment comparer deux distributions de façon juste ?

Test t

Et s'il y a plusieurs groupes ?

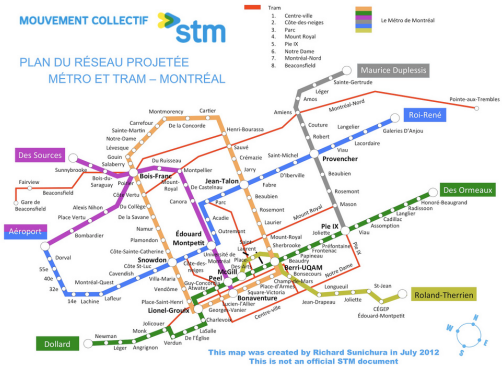
Analyse post hoc

Et les données catégorielles ?

Comment comparer deux distributions de façon juste ?

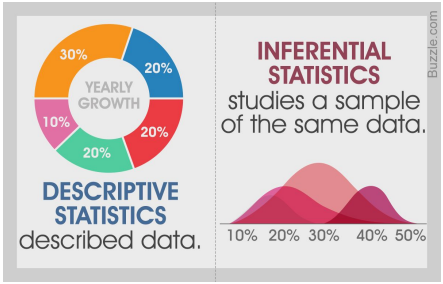
- Problème : je veux savoir comment arriver en classe à l'heure
- Mes choix : prendre l'autobus ou prendre le métro
- Quelle méthode a le plus de chances d'arriver à l'heure ?

- Jusqu'ici, j'ai recueilli 30 échantillons
  - 20 positifs pour le métro
  - 10 positifs pour l'autobus
- Dois-je prendre l'autobus ?
  - À quel point suis-je sûr ?



Statistique inférentielle

- Il y a rarement assez d'information pour être sûr qu'une chose est vraie
- Statistique inférentielle (inferential statistics) : collecter des données, puis en déduire quelque chose sur la vraie distribution échantillonnée (sampled).



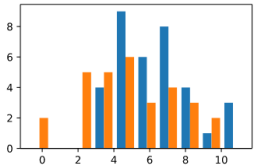
Qu'est-ce qu'une hypothèse ?

- Le objectife est de savoir si une affirmation est vraie ou non.

Qu'est-ce qu'une hypothèse ?

- Le objectife est de savoir si une affirmation est vraie ou non.

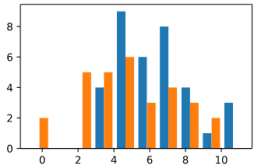
- Considérons la question « La section A arrive-t-elle en classe plus vite que la section B ? »
  - Mais un élève n'a pas accès à l'horaire de tout le monde.
  - Vous pouvez interroger 20% des élèves au hasard (at random)
  - Temps moyen de la classe A : 4,85
  - Temps moyen de la classe B : 6,25



Qu'est-ce qu'une hypothèse ?

- Le objectife est de savoir si une affirmation est vraie ou non.

- Considérons la question « La section A arrive-t-elle en classe plus vite que la section B ? »
  - Mais un élève n'a pas accès à l'horaire de tout le monde.
  - Vous pouvez interroger 20% des élèves au hasard (at random)
  - Temps moyen de la classe A : 4,85
  - Temps moyen de la classe B : 6,25
  - La classe A semble plus rapide.
    - Mais vous n'avez pas interrogé tous les élèves.
  - Test d'hypothèse (hypothesis testing) : vérifier, avec la statistique inférentielle, la probabilité que ce résultat soit dû au hasard.



Types d'hypothèses

- **Hypothèse nulle** (null hypothesis, H_0) : rien n'a été trouvé.
- **Hypothèse alternative** (alternative hypothesis, H_1) : l'autre option étudiée, pour voir si elle est vraie.
- Dans l'exemple de comparaison des classes :
  - L'hypothèse nulle : pas assez d'information pour conclure quoi que ce soit
  - L'hypothèse alternative : assez d'information pour dire qu'une chose est possible (avec une certaine confiance).

Types d'hypothèses

- **Hypothèse nulle** (null hypothesis, H_0) : rien n'a été trouvé.
- **Hypothèse alternative** (alternative hypothesis, H_1) : l'autre option étudiée, pour voir si elle est vraie.
- Dans l'exemple de comparaison des classes :
  - L'hypothèse nulle : pas assez d'information pour conclure quoi que ce soit
  - L'hypothèse alternative : assez d'information pour dire qu'une chose est possible (avec une certaine confiance).
- Formuler l'hypothèse pour poser une question
  - H_0 — Il n'y a pas de différence entre les moyennes des classes A et B.
  - H_1 — Il y a une différence entre les moyennes des classes A et B.

Test t

- Considérons une situation avec:
- Deux distributions de distribution normale,
- ... de même variance.
- Nous voulons conclure que les deux distributions ont des moyennes différentes.
- Rappel : la vraie distribution génératrice est inconnue.
- Fonctionnement du test t (t-test)
  - L'échantillonnage est un processus aléatoire
  - Quelle est la probabilité d'obtenir le même résultat à nouveau ?

Analyse du test t

$$t = \frac{\overbrace{\bar{x}_1 - \bar{x}_2}^{\text{signal}}}{\underbrace{s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}_{\text{bruit}}}$$

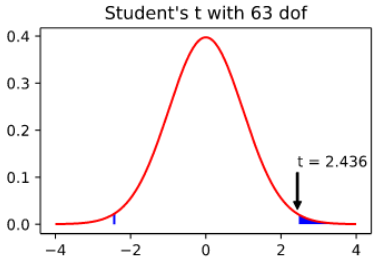
$$\frac{\text{différence des moyennes}}{\text{variance totale des deux groupes}} = \frac{\text{signal}}{\text{bruit}}$$

Où :

- $\bar{x}_1, \bar{x}_2$ – moyennes des échantillons du 1er et du 2e groupe;
- n_1, n_2 – taille d'échantillon du 1er et du 2e groupe;
- $s_p = \sqrt{\frac{(n_1-1)s_1^2+(n_2-1)s_2^2}{n_1+n_2-2}}$ – l'« *écart-type combiné* » (pooled standard deviation)
- s_1, s_2 = écart-type du 1er et du 2e groupe.

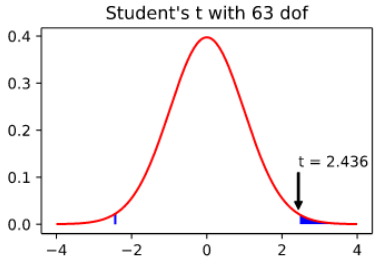
Analyse du test t

- Les classes A/B donnent t-stat $= 2.436$
- 0,00885 = aire sous la courbe à droite de 2,436.
- 0,00885 est seulement à droite. Au total, il y a $2 \times 0.00885 = 0.0177 = 1.77\%$ de probabilité d'être à plus de 2,436 de zéro.



Analyse du test t

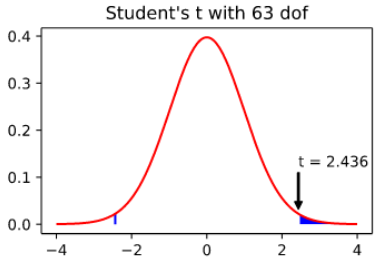
- Les classes A/B donnent t-stat $= 2.436$
- 0,00885 = aire sous la courbe à droite de 2,436.
- 0,00885 est seulement à droite. Au total, il y a $2 \times 0.00885 = 0.0177 = 1.77\%$ de probabilité d'être à plus de 2,436 de zéro.



- Ce qui signifie, la probabilité d'obtenir ces échantillons à partir de populations (normales, de même variance) de moyennes identiques est 0,0177.

Analyse du test t

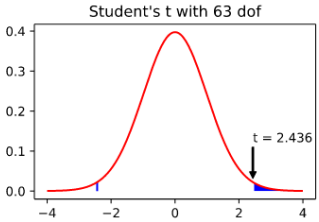
- Les classes A/B donnent t-stat $= 2.436$
- 0,00885 = aire sous la courbe à droite de 2,436.
- 0,00885 est seulement à droite. Au total, il y a $2 \times 0.00885 = 0.0177 = 1.77\%$ de probabilité d'être à plus de 2,436 de zéro.



- Ce qui signifie, la probabilité d'obtenir ces échantillons à partir de populations (normales, de même variance) de moyennes identiques est 0,0177.
- Conclusion : il est très peu probable que H_0 soit vraie.

Tester la normalité

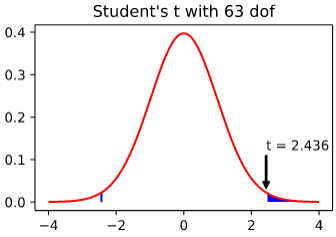
- Les hypothèses du test t ne sont peut-être pas vraies
- Encore une fois : la vraie distribution est **inconnue**



- Que faire ? La même chose que tous les jours
  - Utiliser un test de normalité (p. ex. Shapiro–Wilk) et demander « Les données semblent-elles gaussiennes ? »
  - C'est un test à l'envers
  - Le but est $p > 0.05$

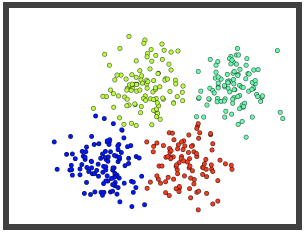
Tester si les variances sont égales

- **Rappel : la vraie distribution est inconnue**
- Avec les données disponibles, quelle est la probabilité que les variances soient le meme ?
  - Dit homoscédastique (homoscedastic)
- Le test de **Levene** suppose que les deux échantillons ont la même variance.
  - Avec un petit p, cette hypothèse est rejetée (rejected)
- Il existe une version du test t qui ne suppose pas l'égalité des variances.
  - **Test t de Welch** (Welch's t-test)



Et s'il y a plusieurs groupes ?

- Les tests t sont conçus pour deux distributions
- Et s'il y a trois ensembles d'échantillons, et que la question est de savoir si l'un d'eux est différent ? P. ex., y a-t-il une différence de taille entre autobus, vélo et marche ?

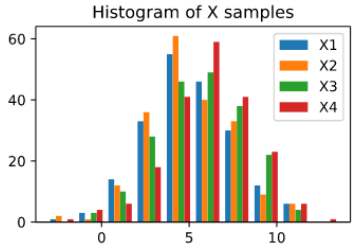


  - Une option : faire un test t pour autobus vs métro, autobus vs vélo, métro vs vélo. Voir s'il y a des différences avec $p < 0.05$.
    - Mais rappelez-vous ce que $p < 0.05$ signifie : 5 % de probabilité de rejeter l'hypothèse nulle à tort, **par pur hasard**.
    - Avec trois tests t, la probabilité d'aucun rejet incorrect de H_0 est : $0.95^3 = 0.86$
  - Le p effectif vraiment 0,14 : moins de confiance dans les résultats.

ANOVA (ANalyse de la VAriance)

- Un test pour savoir si les moyennes de certains groupes diffèrent. Semblable à un test t, mais pour >2 groupes.

- Présupposés :
  - Observations indépendantes et de même loi (iid).
  - Les groupes suivent une loi normale.
  - Les groupes ont la même variance.

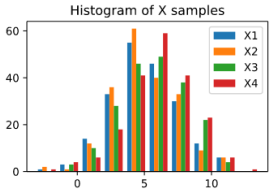


- Certaines moyennes sont-elles différentes ?
  - Difficile à dire
- Bien, mais insatisfaisant. Certains groupes ont des moyennes différentes, mais le test ne dit pas lesquels.

ANOVA (analyse de la variance)

- Un test : savoir si les moyennes de certains groupes diffèrent. Semblable à un test t, mais pour groupes > 2.

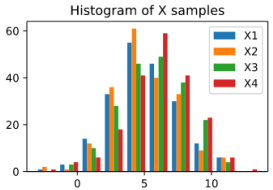
- Certaines moyennes sont-elles différentes ?
- Difficile à dire... le test dit oui!
- Bien, mais insatisfaisant.



ANOVA (analyse de la variance)

- Un test : savoir si les moyennes de certains groupes diffèrent. Semblable à un test t, mais pour groupes > 2.

- Certaines moyennes sont-elles différentes ?
- Difficile à dire… le test dit oui!
- Bien, mais insatisfaisant.



- Nous savons que certains groupes ont des moyennes différentes, mais lesquels ?

```
from scipy import stats
anova = stats.f_oneway(x1, x2, x3, x4)
print(anova)
print(anova.pvalue)
```

```
F_onewayResult(statistic=6.301848031347299, pvalue=0.0003159232
0.0003159232567907352
```

Analyse post hoc

- Un test pour savoir si les moyennes de certains groupes diffèrent. Très semblable à un test t, mais pour >2 groupes.
- Si l'ANOVA est significative, vous pouvez ensuite faire une analyse post hoc (post hoc analysis) : des comparaisons par paires entre chaque variable.
- Elle doit être faite correctement, pour éviter de faire beaucoup de tests séparés et de lire des valeurs p (p-values) invalides.
- Le test le plus souvent suggéré dans ce cas est le test HSD de Tukey (Honest Significant Difference).

Test HSD de Tukey (Honest Significant Difference)

- Indique si les moyennes des différents groupes sont semblables (similar).
- Il y a 4 groupes x_1, x_2, x_3, x_4

Multiple Comparison of Means - Tukey HSD, FWER=0.05

group1	group2	meandiff	p-adj	lower	upper	reject
x1	x2	-0.0202	0.9	-0.6538	0.6135	False
x1	x3	0.4763	0.2143	-0.1574	1.1099	False
x1	x4	0.8956	0.0017	0.262	1.5293	True
x2	x3	0.4965	0.1824	-0.1372	1.1301	False
x2	x4	0.9158	0.0012	0.2822	1.5494	True
x3	x4	0.4194	0.3224	-0.2143	1.053	False

Manipuler les valeurs p

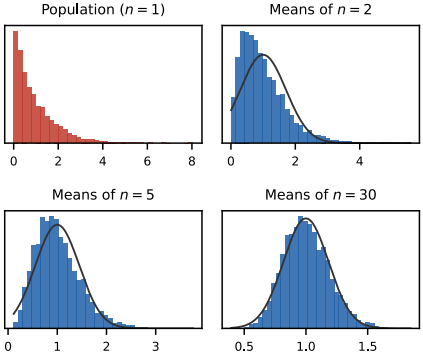
- **Il ne faut pas se tromper (decive) soi-même (ou les autres) avec la statistique.**
  - Gardez en tête ce qu'est vraiment une valeur p.
- Imaginez une enquête sur la forme physique selon le lieu. L'enquête recueille plusieurs variables : taille, poids, ville de résidence.
- Mauvaise pratique n° 1 : recueillir des données jusqu'à ce que l'ANOVA du poids par ville atteigne $p < 0.05$.
- Si vous concevez l'expérience pour obtenir la conclusion voulue, vous n'obtiendrez pas des résultats vrai.

Manipuler les valeurs p

- N'essayez pas des tests jusqu'à ce qu'un d'eux fonctionne (p-hacking)...
- ANOVA du poids par ville : $p < 0.05$.
- ANOVA de la taille par ville : $p < 0.05$
- Test t du poids, Vancouver vs Toronto : $p < 0.05$
- Test t du poids, Vancouver vs Calgary : $p < 0.05$
- À chaque test, il y a 5 % de chance de rejeter l'hypothèse nulle **par hasard**.
- Le test HSD de Tukey (Honest Significant Difference) en tient compte!

Théorème central limite

- Théorème central limite (central limit theorem) : prenons une distribution de moyenne μ et de variance σ. Tirer n valeurs de X, nommées S_i. Continuer ainsi pour générer S_1. Répéter pour S_2, S_3.
- Les moyennes des échantillons, S_k, tendent vers une loi normale si n est assez grand.



Quelques conseils

- Ces tests fonctionnent bien avec assez de données
- Les données devraient suivre une loi normale
- $>$40 points, c'est correct a commencer

Et les données catégorielles ?

- Et si les données ont encore moins de structure et sont catégorielles ?
- **Test du khi-deux** (chi-squared test)
  - Fonctionne sur des totaux par catégorie comme ceux-ci (avec > 5 observations par catégorie).
  - Hypothèse nulle : les catégories sont indépendantes, c.-à-d. les proportions sont les mêmes peu importe la catégorie.

$$\chi^2 = \sum \frac{(O - E)^2}{E}$$

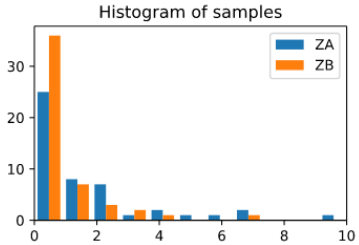
- O = les fréquences observées,
- E = les fréquences attendues,
- $\sum$ = la « somme de »

Test U de Mann–Whitney

- Et si aucune hypothèse ne peut être faite sur la distribution des données ?
- Test U de **Mann–Whitney**
  - C'est un test non paramétrique (non-parametric test)
  - Permet de décider si les échantillons d'un groupe sont plus grands/petits que ceux d'un autre
- Hypothèses :
  - Les observations sont indépendantes.
  - Les valeurs sont ordinales : elles peuvent être triées.

Test U de Mann–Whitney

- H_0 : si x, y sont tirés de X, Y, est-ce que $P(x < y) = \frac{1}{2}$?
- H_1 : $P(x < y) \neq \frac{1}{2}$?
  - Les valeurs d'un groupe tendent à être plus hautes que l'autre
- Mann-Whitney ignore la taille des différences : seul l'ordre compte.
- Corollaire : pour comparer la vitesse d'un code, faire trois exécutions de chaque; si les trois sont plus rapides/lentes, Mann-Whitney donne un résultat significatif avec $p = 0.04$.



Quiz/Sondage

- Nous voulons comparer deux groupes, mais les données ne sont clairement pas gaussiennes. Quel test faut-il utiliser ?
- (A) t-test de Student, (B) t-test de Welch, (C) test de Mann–Whitney ou (D) ANOVA

Quiz/Sondage

- Comment vérifier que les données suivent une loi normale avant un t-test ?
- (A) le test de Levene, (B) un test de Shapiro–Wilk, (C) un test du chi carré d'indépendance, ou (D) le test HSD de Tukey

Références

- https://ggbaker.ca/data-science/slide-content/stats-tests.html#/title-2
- https://towardsdatascience.com/t-test-and-hypothesis-testing-explained-simply-1cff6358633e
- https://ggbaker.ca/data-science/slide-content/inferential.html#/title-6