# Apprentissage pour la science des données

## Cours 10 : Tests d'hypothèse pratiques et plan d'expérience

Glen Berseth

Université de Montréal et Institut québécois d'intelligence artificielle (Mila)

October 6, 2026



# Plan

Introduction : inférence

Amorçage : la tour de tortues de Yertle

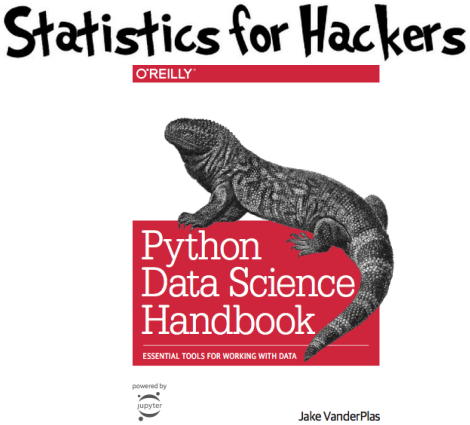
Validation croisée

Résumé : quatre recettes de statistiques pour hackers

# Introduction : inférence

- Méta-algorithmes : évaluer les processus utilisés pour apprendre des données
- Science : comment passer du fini au général ?
- « Il est facile de mal interpréter avec les statistiques, mais difficile de dire la vérité sans elles. »

# Remerciements






# « Pourquoi ne pas simplement . . . »

< Une alternative populaire . . . >

```
from statsmodels.stats.weightstats import ttest_ind
t, p, dof = ttest_ind(group1, group2,
                      alternative='larger',
                      usevar='unequal')
print(p)   # 0.186
```

# « Pourquoi ne pas simplement . . . »

< Une alternative populaire . . . >

```
from statsmodels.stats.weightstats import ttest_ind
t, p, dof = ttest_ind(group1, group2,
                      alternative='larger',
                      usevar='unequal')
print(p)   # 0.186
```

. . . Mais à quelle *question* ce test répond-il ?

# Prenons du recul...

Le sens profond est dans la *distribution d'échantillonnage* (sampling distribution) :
Théorème central limite (central limit theorem) :

$$X_1, \ldots, X_n \text{ i.i.d.}, \quad \mathbb{E}[X_i] = \mu, \quad \mathbb{E}[(X_i - \mu)^2] = \sigma^2$$

$$\frac{\sum_{i=1}^{n} X_i - n\mu}{\sqrt{n}} \to \mathcal{N}(0, \sigma^2)$$

$$t = \underbrace{\frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}}$$

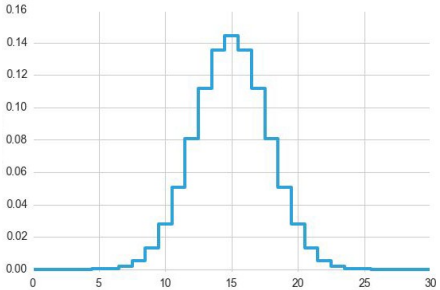
« Ressemblent » à des variables gaussiennes

# Prenons du recul...

Le sens profond se trouve dans la *distribution d'échantillonnage* :

$$p(t;\nu) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\,\Gamma\left(\frac{\nu}{2}\right)}\left(1+\frac{t^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

Même principe que l'exemple de la pièce :




0.8 %

# Utiliser plutôt une méthode d'échantillonnage

Le problème :
Contrairement au lancer de pièce, pas de *modèle génératif* (generative model) . . .

# Utiliser plutôt une méthode d'échantillonnage

Le problème :
Contrairement au lancer de pièce, pas de *modèle génératif* (generative model) . . .
Solution : la permutation (shuffling)

# Permutation

| $\star$ | | $\times$ | |
|---|---|---|---|
| 84 | 72 | 81 | 69 |
| 57 | 46 | 74 | 61 |
| 63 | 76 | 56 | 87 |
| 99 | 91 | 69 | 65 |
| | | 66 | 44 |
| | | 62 | 69 |

**Idée :**
Simuler la distribution en *permutant* les étiquettes à répétition et en calculant la statistique voulue.

**Motivation :**
Si les étiquettes n'ont vraiment aucune importance, les échanger ne devrait pas changer le résultat !

# Permutation

| $\star$ | | $\times$ | |
|---|---|---|---|
| 84 | 72 | 81 | 69 |
| 57 | 46 | 74 | 61 |
| 63 | 76 | 56 | 87 |
| 99 | 91 | 69 | 65 |
| | | 66 | 44 |
| | | 62 | 69 |

1. Permuter les étiquettes
2. Réorganiser
3. Calculer les moyennes

# Permutation

| ⋆ | | × | |
|---|---|---|---|
| 84 | 72 | 81 | 69 |
| 57 | 46 | 74 | 61 |
| 63 | 76 | 56 | 87 |
| 99 | 91 | 69 | 65 |
| | | 66 | 44 |
| | | 62 | 69 |

1. **Permuter les étiquettes**
2. Réorganiser
3. Calculer les moyennes

# Permutation

| $\star$ | | $\times$ | |
|---|---|---|---|
| 84 | 81 | 72 | 69 |
| 61 | 69 | 74 | 57 |
| 65 | 76 | 56 | 87 |
| 99 | 44 | 46 | 63 |
| | | 66 | 91 |
| | | 62 | 69 |

1. Permuter les étiquettes
2. **Réorganiser**
3. Calculer les moyennes

# Permutation

| $\star$ | | $\times$ | |
|---|---|---|---|
| 84 | 81 | 72 | 69 |
| 61 | 69 | 74 | 57 |
| 65 | 76 | 56 | 87 |
| 99 | 44 | 46 | 63 |
| | | 66 | 91 |
| | | 62 | 69 |

- $\star$ moyenne : 72.4
- $\times$ moyenne : 67.6
- Différence : 4.8

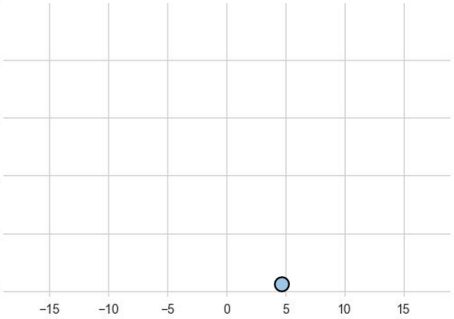
1. Permuter les étiquettes
2. Réorganiser
3. **Calculer les moyennes**

# Permutation

| ⋆ | | × | |
|---|---|---|---|
| 84 | 81 | 72 | 69 |
| 61 | 69 | 74 | 57 |
| 65 | 76 | 56 | 87 |
| 99 | 44 | 46 | 63 |
| | | 66 | 91 |
| | | 62 | 69 |

- ⋆ moyenne : 72.4
- × moyenne : 67.6
- Différence : 4.8

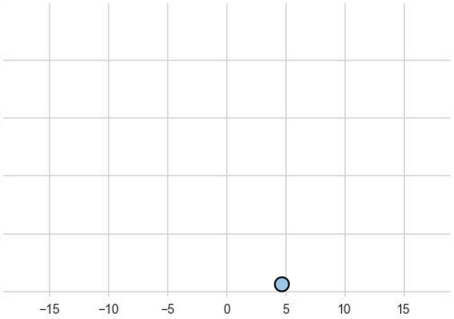
1. Permuter les étiquettes
2. Réorganiser
3. **Calculer les moyennes**



# Permutation

| ⋆ | | × | |
|---|---|---|---|
| 84 | 81 | 72 | 69 |
| 61 | 69 | 74 | 57 |
| 65 | 76 | 56 | 87 |
| 99 | 44 | 46 | 63 |
| | | 66 | 91 |
| | | 62 | 69 |

1. **Permuter les étiquettes**
2. Réorganiser
3. Calculer les moyennes

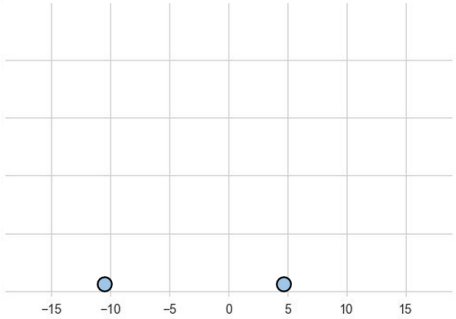


# Permutation

| ⋆ | | × | |
|---|---|---|---|
| 84 | 56 | 72 | 69 |
| 61 | 63 | 74 | 57 |
| 65 | 66 | 81 | 87 |
| 62 | 44 | 46 | 69 |
| | | 76 | 91 |
| | | 99 | 69 |

- ⋆ moyenne : 62.6
- × moyenne : 74.1
- Différence : -11.6

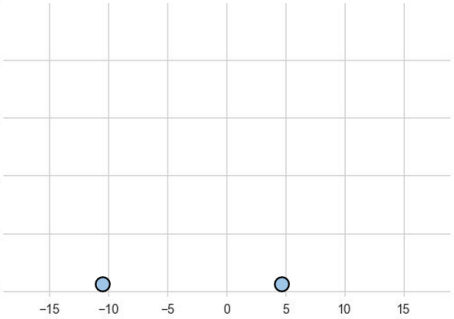
1. Permuter les étiquettes
2. Réorganiser
3. **Calculer les moyennes**



# Permutation

| ⋆ | | × | |
|---|---|---|---|
| 84 | 56 | 72 | 69 |
| 61 | 63 | 74 | 57 |
| 65 | 66 | 81 | 87 |
| 62 | 44 | 46 | 69 |
| | | 76 | 91 |
| | | 99 | 69 |

1. **Permuter les étiquettes**
2. Réorganiser
3. Calculer les moyennes

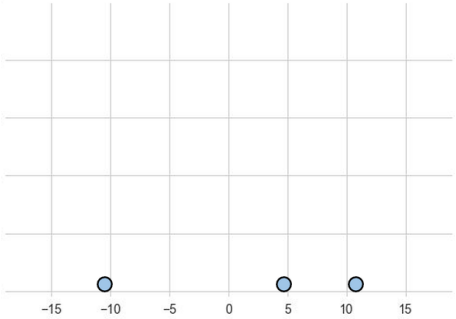


# Permutation

| ⋆ | | × | |
|---|---|---|---|
| 74 | 56 | 72 | 69 |
| 61 | 63 | 84 | 57 |
| 87 | 76 | 81 | 65 |
| 91 | 99 | 46 | 69 |
| | | 66 | 62 |
| | | 44 | 69 |

- ⋆ moyenne : 75.9
- × moyenne : 65.3
- Différence : 10.6

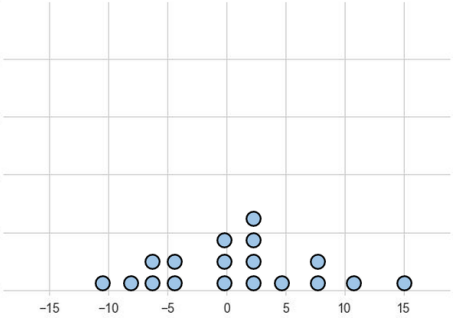
1. Permuter les étiquettes
2. Réorganiser
3. **Calculer les moyennes**



# Permutation

| $\star$ | | $\times$ | |
|---|---|---|---|
| 84 | 56 | 72 | 69 |
| 61 | 63 | 74 | 57 |
| 65 | 66 | 81 | 87 |
| 62 | 44 | 46 | 69 |
| | | 76 | 91 |
| | | 99 | 69 |

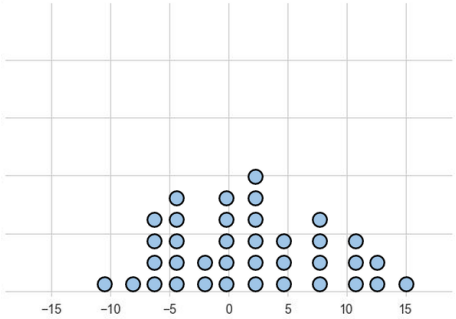
1. Permuter les étiquettes
2. Réorganiser
3. Calculer les moyennes



# Permutation

| ⋆ | | × | |
|---|---|---|---|
| 84 | 81 | 69 | 69 |
| 61 | 69 | 87 | 74 |
| 65 | 76 | 56 | 57 |
| 99 | 44 | 46 | 63 |
| | | 66 | 91 |
| | | 62 | 72 |

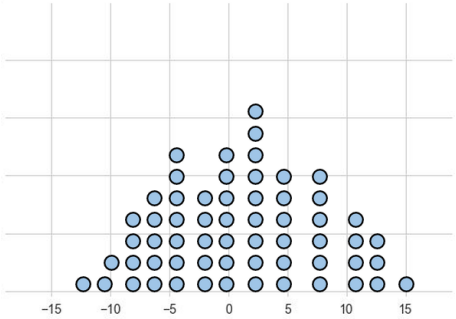
1. Permuter les étiquettes
2. Réorganiser
3. Calculer les moyennes



# Permutation

| ⋆ | | × | |
|---|---|---|---|
| 74 | 62 | 72 | 57 |
| 61 | 63 | 84 | 69 |
| 87 | 81 | 76 | 65 |
| 91 | 99 | 46 | 69 |
| | | 66 | 56 |
| | | 44 | 69 |

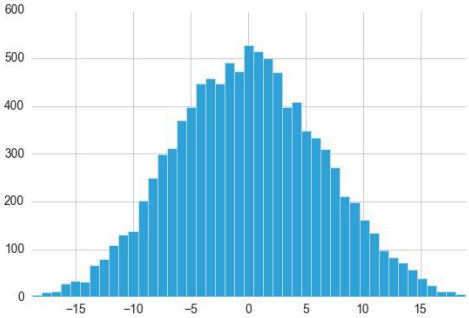
1. Permuter les étiquettes
2. Réorganiser
3. Calculer les moyennes



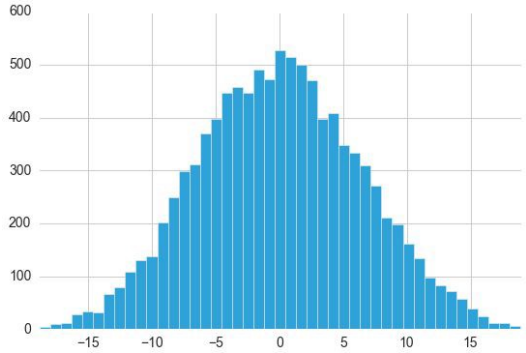
# Permutation

| ⋆ | | × | |
|---|---|---|---|
| 84 | 81 | 72 | 69 |
| 61 | 69 | 74 | 57 |
| 65 | 76 | 56 | 87 |
| 99 | 44 | 46 | 63 |
| | | 66 | 91 |
| | | 62 | 69 |

1. Permuter les étiquettes
2. Réorganiser
3. Calculer les moyennes



# Permutation




différence de score

16 %

$$\frac{N_{>6.6}}{N_{tot}} = \frac{1608}{10000} = 0.16$$

# « Une différence de 6.6 n'est pas significative à $p = 0.05$. »




*Ce jour-là, tous les Sneetches ont oublié les étoiles*
*Et s'ils en avaient une, ou non, sur le ventre.*

# Notes sur la permutation

- Mesurer la significativité statistique entre **deux** groupes.

# Notes sur la permutation

- Mesurer la significativité statistique entre **deux** groupes.
- Fonctionne lorsque l'*hypothèse nulle* (null hypothesis) suppose que les deux groupes sont équivalents.

# Notes sur la permutation

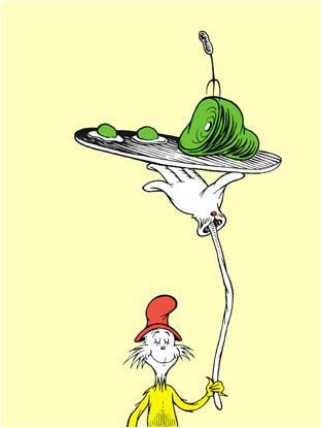
- Mesurer la significativité statistique entre **deux** groupes.
- Fonctionne lorsque l'*hypothèse nulle* (null hypothesis) suppose que les deux groupes sont équivalents.
- Comme toute méthode, la permutation ne fonctionne que si vos échantillons sont représentatifs – attention aux biais de sélection (selection bias) !

# Notes sur la permutation

- Mesurer la significativité statistique entre **deux** groupes.
- Fonctionne lorsque l'*hypothèse nulle* (null hypothesis) suppose que les deux groupes sont équivalents.
- Comme toute méthode, la permutation ne fonctionne que si vos échantillons sont représentatifs – attention aux biais de sélection (selection bias) !
- Demande de la prudence pour des essais non indépendants.
- Discussion dans *Resampling: The New Statistics* de Simon.

# Quatre recettes de statistiques pour hackers

1. Simulation directe ✓
2. Permutation ✓
3. Amorçage (bootstrap)
4. Validation croisée (cross-validation)



# Amorçage : la tour de tortues de Yertle

*Sur l'île lointaine de Sala-ma-Sond,*
*Yertle la tortue*
*était roi de l'étang. . .*



# Jusqu'à quelle hauteur Yertle peut-il empiler ses tortues ?

Observer 20 tours de tortues de Yertle . . .

| # de tortues | 48 | 24 | 32 | 61 | 51 | 12 | 32 | 18 | 19 | 24 |
|---|---|---|---|---|---|---|---|---|---|---|
| | 21 | 41 | 29 | 21 | 25 | 23 | 42 | 18 | 23 | 13 |

- Quel est le nombre moyen de tortues dans la pile de Yertle ?
- Quelle est l'incertitude sur cette estimation ?



# Méthode classique

Moyenne de l'échantillon :

$$\bar{x} = \frac{1}{N} \sum_{i=1}^{N} x_i = 28.9$$

Erreur type de la moyenne (standard error of the mean) :

$$\sigma_{\bar{x}} = \frac{1}{\sqrt{N}} \sqrt{\frac{1}{N-1} \sum_{i=1}^{N} (x_i - \bar{x})^2} = 3.0$$

# Quelles hypothèses se cachent derrière ces formules ?

L'échantillonnage peut-il être utilisé à la place ?

# Rééchantillonnage par amorçage

Problème :
Comme avant, il n'y a pas de *modèle génératif* . . .

# Rééchantillonnage par amorçage

Problème :
Comme avant, il n'y a pas de *modèle génératif* . . .
Solution : rééchantillonnage par amorçage (bootstrap resampling)

# Rééchantillonnage par amorçage

| | | | |
|---|---|---|---|
| 48 | 24 | 51 | 12 |
| 21 | 41 | 25 | 23 |
| 32 | 61 | 19 | 24 |
| 29 | 21 | 23 | 13 |
| 32 | 18 | 42 | 18 |

**Idée :**
Simuler la distribution en *tirant des échantillons avec remise.*

**Motivation :**
Les données estiment leur propre distribution – des échantillons aléatoires sont tirés de cette distribution.

# Rééchantillonnage par amorçage

| | | | |
|---|---|---|---|
| 48 | 24 | 51 | 12 |
| 21 | 41 | 25 | 23 |
| 32 | 61 | 19 | 24 |
| 29 | 21 | 23 | 13 |
| 32 | 18 | 42 | 18 |

**Idée :**
Simuler la distribution en *tirant des échantillons avec remise.*

**Motivation :**
Les données estiment leur propre distribution – des échantillons aléatoires sont tirés de cette distribution.

# Rééchantillonnage par amorçage

| | | | |
|---|---|---|---|
| 48 | 24 | 51 | 12 |
| **21** | 41 | 25 | 23 |
| 32 | 61 | 19 | 24 |
| 29 | 21 | 23 | 13 |
| 32 | 18 | 42 | 18 |

**Idée :**
Simuler la distribution en *tirant des échantillons avec remise.*

**Motivation :**
Les données estiment leur propre distribution – des échantillons aléatoires sont tirés de cette distribution.

| |
|---|
| **21** |

# Rééchantillonnage par amorçage

| | | | |
|---|---|---|---|
| 48 | 24 | 51 | 12 |
| 21 | 41 | 25 | 23 |
| 32 | 61 | **19** | 24 |
| 29 | 21 | 23 | 13 |
| 32 | 18 | 42 | 18 |

**Idée :**
Simuler la distribution en *tirant des échantillons avec remise.*

**Motivation :**
Les données estiment leur propre distribution – des échantillons aléatoires sont tirés de cette distribution.

| | |
|---|---|
| 21 | **19** |

# Rééchantillonnage par amorçage

| | | | |
|---|---|---|---|
| 48 | 24 | 51 | 12 |
| 21 | 41 | **25** | 23 |
| 32 | 61 | 19 | 24 |
| 29 | 21 | 23 | 13 |
| 32 | 18 | 42 | 18 |

**Idée :**
Simuler la distribution en *tirant des échantillons avec remise.*

**Motivation :**
Les données estiment leur propre distribution – des échantillons aléatoires sont tirés de cette distribution.

| | | |
|---|---|---|
| 21 | 19 | **25** |

# Rééchantillonnage par amorçage

| | | | |
|---|---|---|---|
| 48 | **24** | 51 | 12 |
| 21 | 41 | 25 | 23 |
| 32 | 61 | 19 | 24 |
| 29 | 21 | 23 | 13 |
| 32 | 18 | 42 | 18 |

**Idée :**
Simuler la distribution en *tirant des échantillons avec remise.*

**Motivation :**
Les données estiment leur propre distribution – des échantillons aléatoires sont tirés de cette distribution.

| | | | |
|---|---|---|---|
| 21 | 19 | 25 | **24** |

# Rééchantillonnage par amorçage

| | | | |
|---|---|---|---|
| 48 | 24 | 51 | 12 |
| 21 | 41 | 25 | 23 |
| 32 | 61 | 19 | 24 |
| 29 | 21 | **23** | 13 |
| 32 | 18 | 42 | 18 |

**Idée :**
Simuler la distribution en *tirant des échantillons avec remise.*

**Motivation :**
Les données estiment leur propre distribution – des échantillons aléatoires sont tirés de cette distribution.

| | | | | |
|---|---|---|---|---|
| 21 | 19 | 25 | 24 | **23** |

# Rééchantillonnage par amorçage

| | | | |
|---|---|---|---|
| 48 | 24 | 51 | 12 |
| 21 | 41 | 25 | 23 |
| 32 | 61 | **19** | 24 |
| 29 | 21 | 23 | 13 |
| 32 | 18 | 42 | 18 |

**Idée :**
Simuler la distribution en *tirant des échantillons avec remise.*

**Motivation :**
Les données estiment leur propre distribution – des échantillons aléatoires sont tirés de cette distribution.

| | | | | | |
|---|---|---|---|---|---|
| 21 | 19 | 25 | 24 | 23 | **19** |

# Rééchantillonnage par amorçage

| | | | |
|---|---|---|---|
| 48 | 24 | 51 | 12 |
| 21 | **41** | 25 | 23 |
| 32 | 61 | 19 | 24 |
| 29 | 21 | 23 | 13 |
| 32 | 18 | 42 | 18 |

**Idée :**
Simuler la distribution en *tirant des échantillons avec remise.*

**Motivation :**
Les données estiment leur propre distribution – des échantillons aléatoires sont tirés de cette distribution.

| | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| 21 | 19 | 25 | 24 | 23 | 19 | 41 | 23 | 41 | 18 |
| 61 | 12 | 42 | 42 | 42 | 19 | 18 | 61 | 29 | **41** |

# Rééchantillonnage par amorçage

| | | | |
|---|---|---|---|
| 48 | 24 | 51 | 12 |
| 21 | 41 | 25 | 23 |
| 32 | 61 | 19 | 24 |
| 29 | 21 | 23 | 13 |
| 32 | 18 | 42 | 18 |

**Idée :**
Simuler la distribution en *tirant des échantillons avec remise.*

**Motivation :**
Les données estiment leur propre distribution – des échantillons aléatoires sont tirés de cette distribution.

| | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| 21 | 19 | 25 | 24 | 23 | 19 | 41 | 23 | 41 | 18 |
| 61 | 12 | 42 | 42 | 42 | 19 | 18 | 61 | 29 | 41 |

$\rightarrow 31.05$

# Rééchantillonnage par amorçage

| | | | |
|---|---|---|---|
| 48 | 24 | 51 | 12 |
| 21 | 41 | 25 | 23 |
| 32 | 61 | 19 | 24 |
| 29 | 21 | 23 | 13 |
| 32 | 18 | 42 | 18 |

**Idée :**
Simuler la distribution en *tirant des échantillons avec remise.*

**Motivation :**
Les données estiment leur propre distribution – des échantillons aléatoires sont tirés de cette distribution.

| | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| 21 | 19 | 25 | 24 | 23 | 19 | 41 | 23 | 41 | 18 |
| 61 | 12 | 42 | 42 | 42 | 19 | 18 | 61 | 29 | 41 |

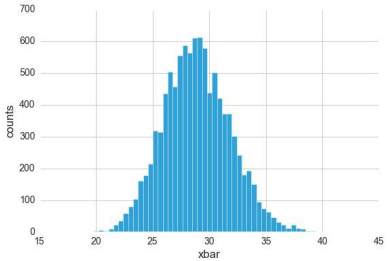
$\rightarrow$ 31.05

Répéter ceci plusieurs milliers de fois . . .

# L'amorçage retrouve l'estimation analytique !

```
for i in range(10000):
    sample = N[randint(20, size=20)]
    xbar[i] = mean(sample)
mean(xbar), std(xbar)
# (28.9, 2.9)
```

Hauteur $= 29 \pm 3$ tortues






# Notes sur l'amorçage

- Sert à estimer des statistiques de vos données (moyenne, écart-type, ...)

# Notes sur l'amorçage

- Sert à estimer des statistiques de vos données (moyenne, écart-type, ...)
- Bien étudié et repose sur des bases théoriques solides.

# Notes sur l'amorçage

- Sert à estimer des statistiques de vos données (moyenne, écart-type, ...)
- Bien étudié et repose sur des bases théoriques solides.
- L'amorçage **ne fonctionne** souvent **pas** bien pour les statistiques de rang (p. ex. la valeur maximale)

# Notes sur l'amorçage

- Sert à estimer des statistiques de vos données (moyenne, écart-type, ...)
- Bien étudié et repose sur des bases théoriques solides.
- L'amorçage **ne fonctionne** souvent **pas** bien pour les statistiques de rang (p. ex. la valeur maximale)
- Fonctionne mal avec très peu d'échantillons (règle empirique : $N > 20$)

# Notes sur l'amorçage

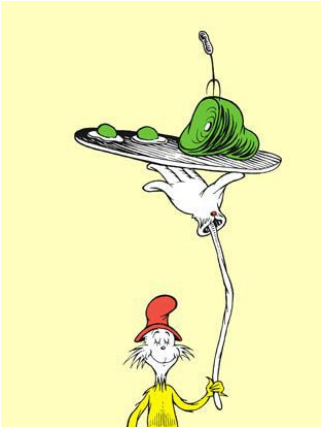
- Sert à estimer des statistiques de vos données (moyenne, écart-type, ...)
- Bien étudié et repose sur des bases théoriques solides.
- L'amorçage **ne fonctionne** souvent **pas** bien pour les statistiques de rang (p. ex. la valeur maximale)
- Fonctionne mal avec très peu d'échantillons (règle empirique : $N > 20$)
- Toujours : attention aux biais de sélection & aux données dépendantes !

# Notes sur l'amorçage

- Sert à estimer des statistiques de vos données (moyenne, écart-type, ...)
- Bien étudié et repose sur des bases théoriques solides.
- L'amorçage **ne fonctionne** souvent **pas** bien pour les statistiques de rang (p. ex. la valeur maximale)
- Fonctionne mal avec très peu d'échantillons (règle empirique : $N > 20$)
- Toujours : attention aux biais de sélection & aux données dépendantes !
- Plus de diapositives sur l'amorçage

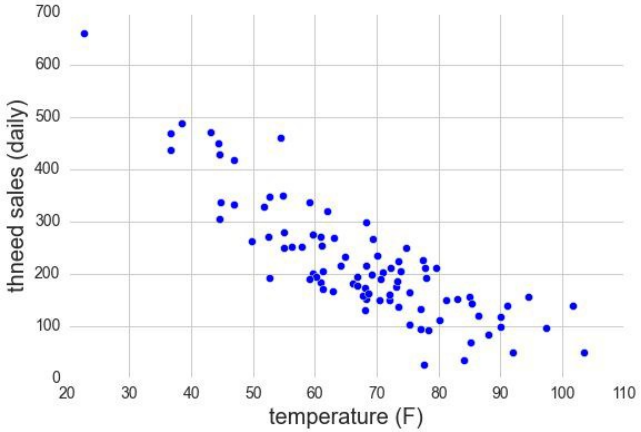
# Quatre recettes de statistiques pour hackers

1. Simulation directe ✓
2. Permutation ✓
3. Amorçage ✓
4. Validation croisée

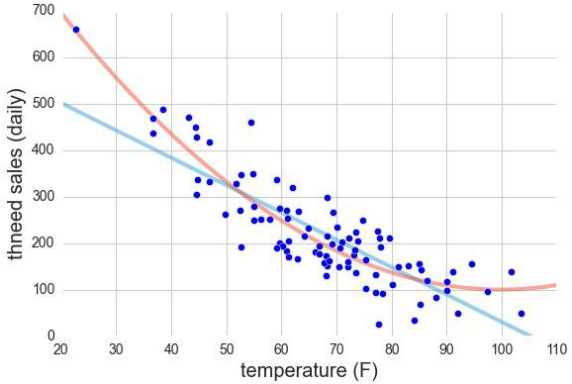


# Validation croisée

- Les ventes semblent suivre une tendance avec la température . . .



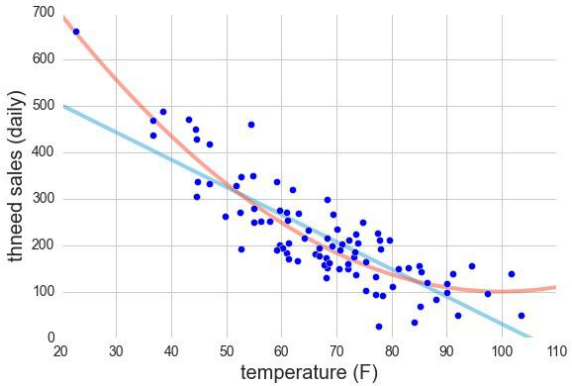
# Mais quel modèle s'ajuste le mieux ?




$y = a + bx$

$y = a + bx + cx^2$

# Mais quel modèle s'ajuste le mieux ?




$y = a + bx$

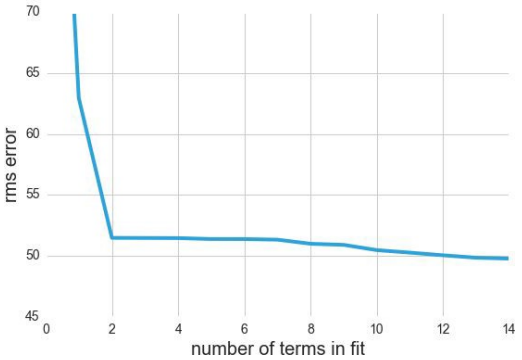
$y = a + bx + cx^2$

Les modèles peuvent-ils être jugés par l'erreur quadratique moyenne (root-mean-square error, RMS) ?

Erreur RMS = 63.0

Erreur RMS = 51.5

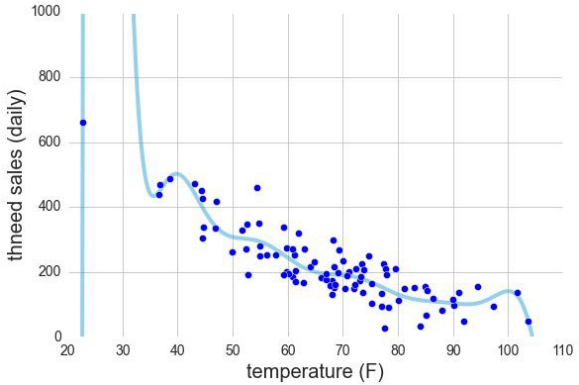
# En général, un modèle plus complexe a *toujours* une RMS plus faible




$$y = a + bx$$
$$y = a + bx + cx^2$$
$$y = a + bx + cx^2 + dx^3$$
$$y = a + bx + cx^2 + dx^3 + ex^4$$
$$y = a + \cdots$$

# L'erreur RMS ne dit pas tout

$$y = a + bx + cx^2 + dx^3 + ex^4 + fx^5 + \cdots + nx^{14}$$



# Pas d'inquiétude : les statistiques ont résolu ce problème



# Méthode classique

L'écart d'erreur quadratique moyenne suit une loi du khi-deux (chi-squared) :

$$p(x;\nu) = \frac{1}{2^{\nu/2}\,\Gamma\left(\frac{\nu}{2}\right)}\, x^{\frac{\nu}{2}-1} e^{-\frac{x}{2}}$$

# Méthode classique

L'écart d'erreur quadratique moyenne suit une loi du khi-deux (chi-squared) :

$$p(x;\nu) = \frac{1}{2^{\nu/2}\,\Gamma\left(\frac{\nu}{2}\right)}\, x^{\frac{\nu}{2}-1} e^{-\frac{x}{2}}$$

Les degrés de liberté (degrees of freedom) s'estiment facilement, car les modèles sont *imbriqués* (nested) . . .

$$\nu \approx \nu_2 - \nu_1, \qquad \nu_2 \approx (N - d_2), \qquad \nu_1 \approx (N - d_1)$$

# Méthode classique

L'écart d'erreur quadratique moyenne suit une loi du khi-deux (chi-squared) :

$$p(x;\nu) = \frac{1}{2^{\nu/2}\,\Gamma\left(\frac{\nu}{2}\right)}\, x^{\frac{\nu}{2}-1} e^{-\frac{x}{2}}$$

Les degrés de liberté (degrees of freedom) s'estiment facilement, car les modèles sont *imbriqués* (nested) . . .

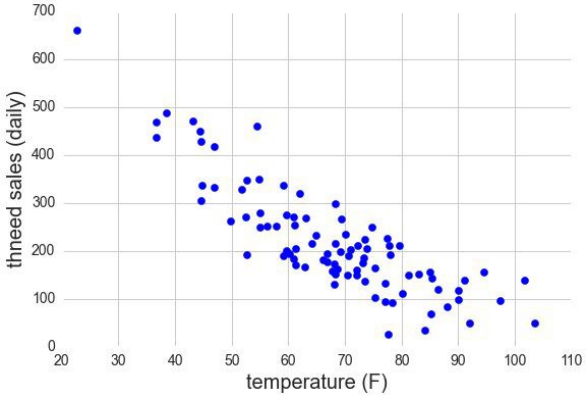
$$\nu \approx \nu_2 - \nu_1, \qquad \nu_2 \approx (N - d_2), \qquad \nu_1 \approx (N - d_1)$$

Remplacer par les valeurs numériques . . .

**Attendez... à quelle question cherchions-nous à répondre, déjà ?**

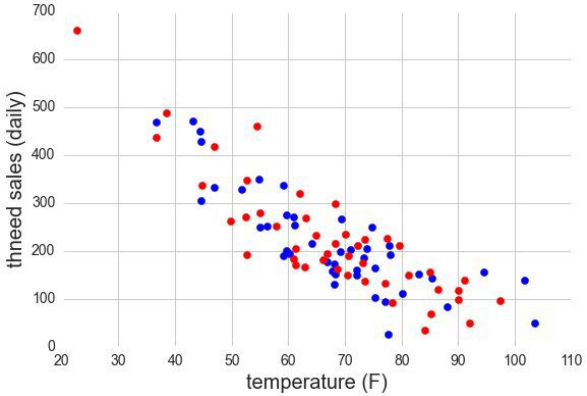
# Validation croisée

Une autre approche : la validation croisée



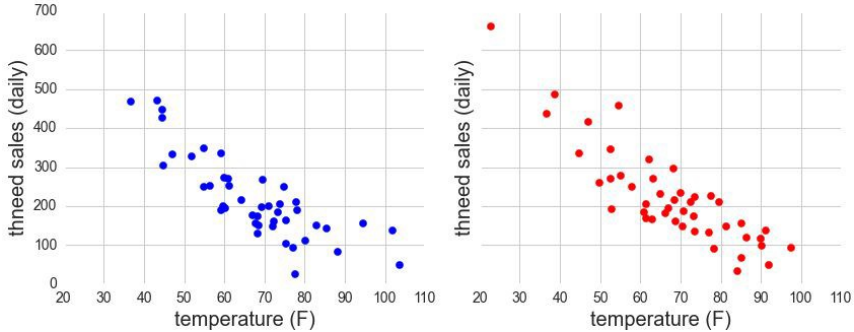
# Validation croisée

1. Diviser les données au hasard



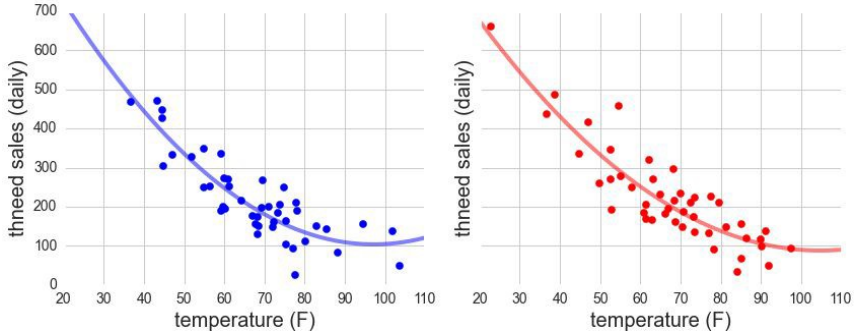
# Validation croisée

1. Diviser les données au hasard



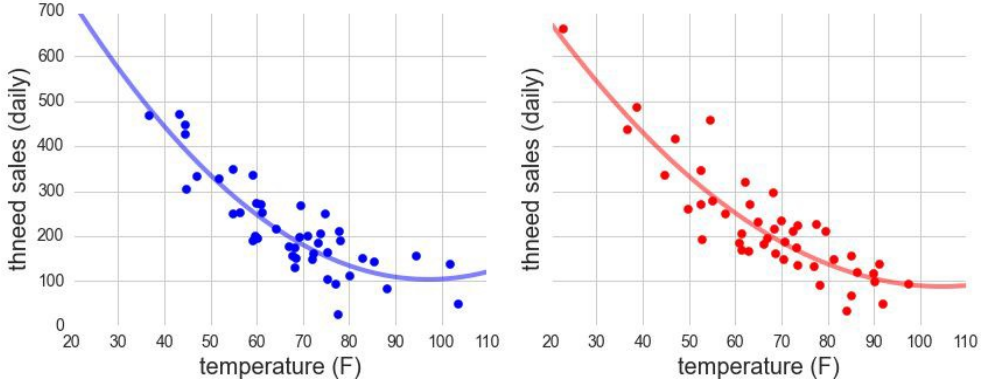
# Validation croisée

2. Trouver le meilleur modèle pour chaque sous-ensemble



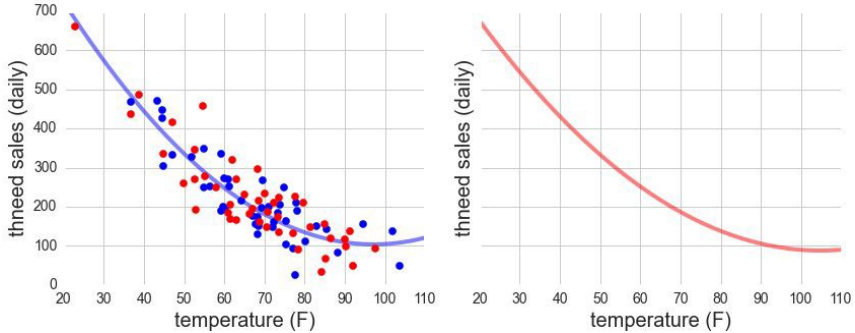
# Validation croisée

3. Comparer les modèles entre sous-ensembles



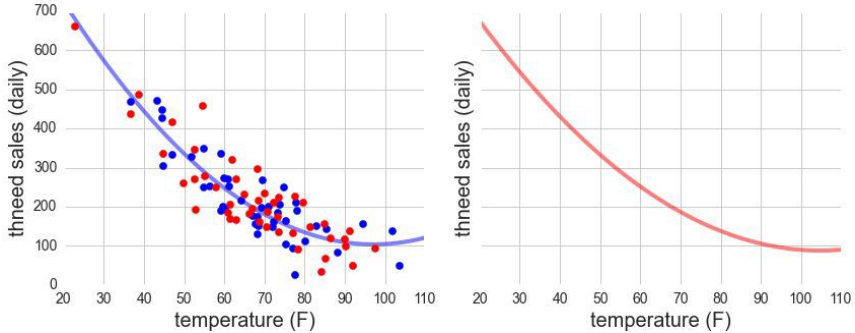
# Validation croisée

3. Comparer les modèles entre sous-ensembles



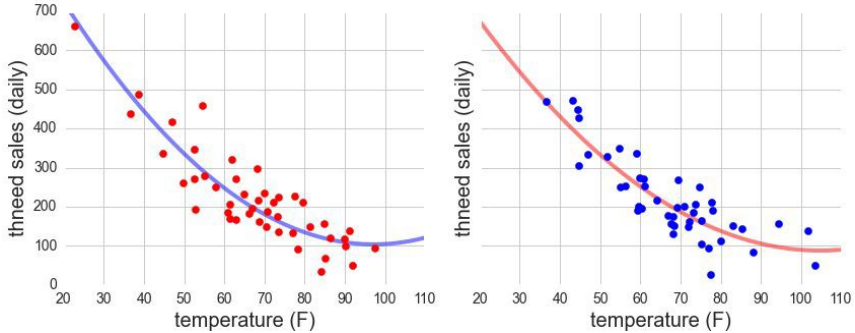
# Validation croisée

3. Comparer les modèles entre sous-ensembles



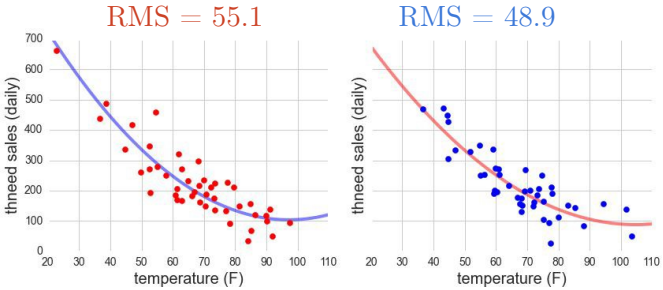
# Validation croisée

3. Comparer les modèles entre sous-ensembles



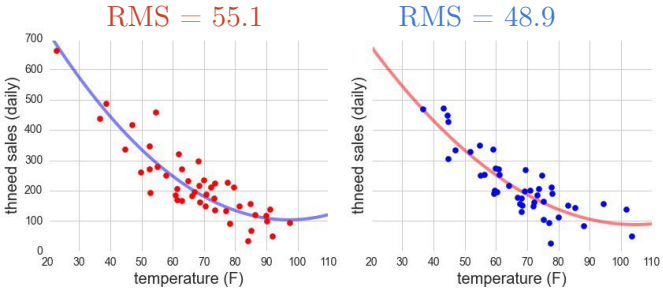
# Validation croisée

4. Calculer l'erreur RMS pour chacun




Estimation RMS = 52.1

4. Calculer l'erreur RMS pour chacun

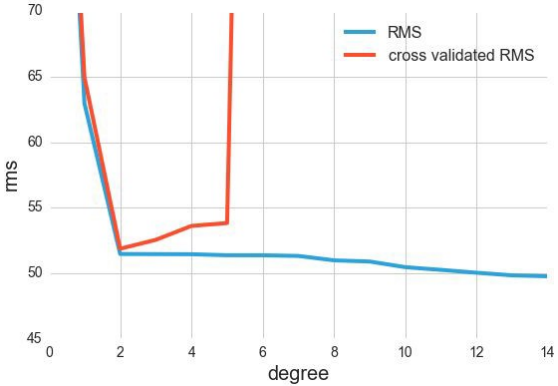



Estimation RMS = 52.1

# Répéter tant que vous avez de la patience . . .

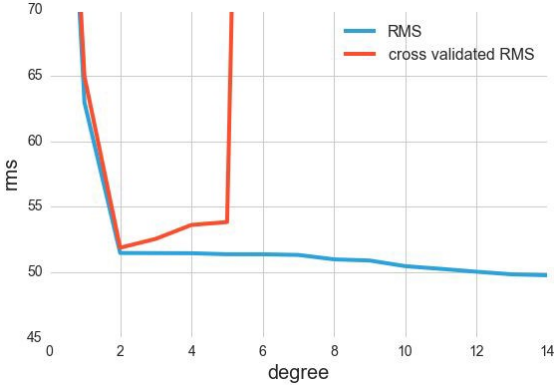
# Validation croisée

5. Comparer l'erreur RMS en validation croisée des modèles :



# Validation croisée

5. Comparer l'erreur RMS en validation croisée des modèles :




Le meilleur modèle minimise l'erreur en validation croisée.

# Notes sur la validation croisée

- Nous avons utilisé une **validation croisée à « 2 plis » (2-fold)** ; d'autres schémas existent et peuvent mieux fonctionner pour vos données (voir p. ex. la documentation de scikit-learn)

# Notes sur la validation croisée

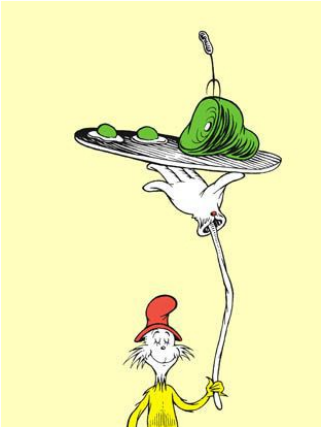
- Nous avons utilisé une **validation croisée à « 2 plis » (2-fold)** ; d'autres schémas existent et peuvent mieux fonctionner pour vos données (voir p. ex. la documentation de scikit-learn)
- La validation croisée est la méthode de référence pour évaluer les modèles en **apprentissage automatique**, car les statistiques des modèles sont souvent inconnues au sens classique.

# Notes sur la validation croisée

- Nous avons utilisé une **validation croisée à « 2 plis » (2-fold)** ; d'autres schémas existent et peuvent mieux fonctionner pour vos données (voir p. ex. la documentation de scikit-learn)
- La validation croisée est la méthode de référence pour évaluer les modèles en **apprentissage automatique**, car les statistiques des modèles sont souvent inconnues au sens classique.
- Encore une fois : attention au biais de sélection et à l'indépendance des données.

# Résumé : quatre recettes de statistiques pour hackers

1. Simulation directe ✓
2. Permutation ✓
3. Amorçage ✓
4. Validation croisée ✓

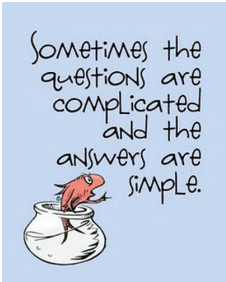


# Résumé

Les **méthodes d'échantillonnage** permettent d'utiliser des approches **computationnelles** intuitives à la place de règles statistiques souvent peu intuitives.
Si vous savez écrire une boucle for, vous savez faire de l'analyse statistique.

# Résumé

Les **méthodes d'échantillonnage** permettent d'utiliser des approches **computationnelles** intuitives à la place de règles statistiques souvent peu intuitives.
Si vous savez écrire une boucle for, vous savez faire de l'analyse statistique.




– Dr. Seuss (attr)

# Quiz/Sondage

**Pourquoi est-il possible d'utiliser des méthodes basées sur la simulation pour comparer des distributions ?**

- (A) parce que les données suivent toujours une loi gaussienne
- (B) grâce au théorème central limite
- (C) parce que les ordinateurs génèrent des nombres vraiment aléatoires
- (D) parce que la taille de l'échantillon est toujours assez grande pour éviter toute erreur

# Références utilisées pour ce cours

- Cours de science des données de Zico Kolter.
- https://speakerdeck.com/jakevdp/statistics-for-hackers
- https://www.huber.embl.de/msmb/Chap-Testing.html#multiple-testing
- Pour aller plus loin : livre ISLR, section 5, diapositives des années précédentes