Apprentissage pour la science des données

Cours 12 : Sélection de caractéristiques

Glen Berseth

Université de Montréal et Institut québécois d'intelligence artificielle (Mila)

October 14, 2026



Plan

Méthodes basées sur la similarité : technique de similarité

Méthodes basées sur la théorie de l'information

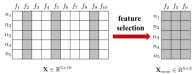
Méthodes parcimonieuses : qu'est-ce que la parcimonie ?

Méthodes statistiques

Sélection avec caractéristiques structurées : un cadre

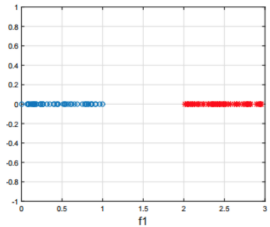
Qu'est-ce que la sélection de caractéristiques ?

- Une procédure en apprentissage automatique pour trouver un sous-ensemble de caractéristiques (features) qui donne un « meilleur » modèle pour un jeu de données
  - Éviter le surapprentissage (overfitting) et mieux généraliser
  - Réduire le stockage et le temps d'entraînement
  - Interprétabilité

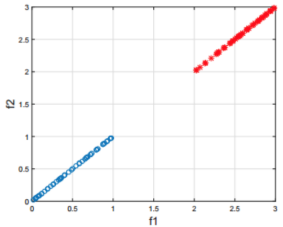


Caractéristiques pertinentes vs redondantes

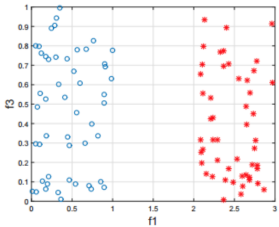
- La sélection de caractéristiques (feature selection) garde les caractéristiques pertinentes et retire celles qui sont redondantes ou non pertinentes
- Par exemple, pour une tâche de classification binaire (f_1 est **pertinente** ; f_2 est **redondante** étant donné f_1 ; f_3 est **non pertinente**)



(a) relevant feature f_1



(b) redundant feature f_2

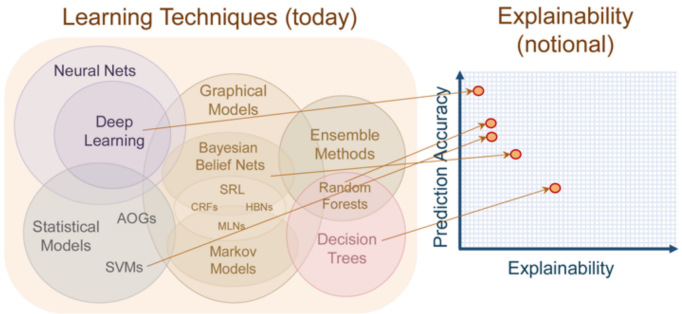


(c) irrelevant feature f_3

Extraction vs sélection de caractéristiques

- **Points communs**
  - Accélérer l'apprentissage
  - Réduire le stockage nécessaire
  - Améliorer la performance de l'apprentissage
  - Construire des modèles qui généralisent mieux
- **Différences**
  - L'extraction de caractéristiques (feature extraction) crée de nouvelles caractéristiques, la sélection choisit un sous-ensemble des originales
  - La sélection garde le sens physique et rend les modèles plus lisibles et interprétables

Interprétabilité des algorithmes d'apprentissage



http://nautil.us/issue/40/learning/is-artificial-intelligence-permanently-inscrutable

With feature selection, both the accuracy and interpretability of most learning algorithms can be enhanced !

Quand la sélection de caractéristiques est-elle importante ?

- Données bruitées
- Beaucoup de caractéristiques peu fréquentes
- Caractéristiques de plusieurs types (p. ex. multimodales)
- Trop de caractéristiques par rapport aux échantillons
- Modèle complexe
- Les échantillons réels diffèrent des échantillons d'entraînement et de test

Algorithmes de sélection de caractéristiques

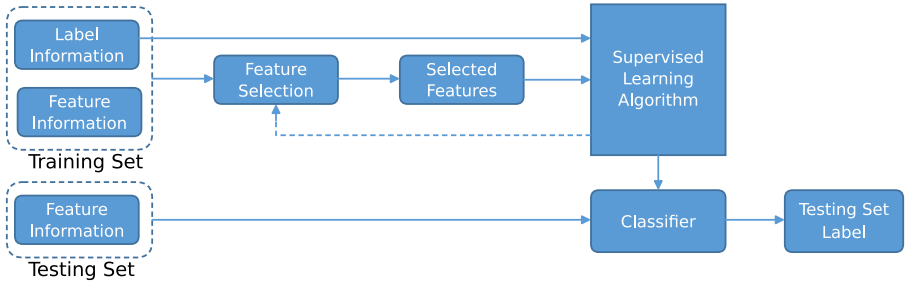
- Selon le **point de vue des étiquettes (labels)** (si l'information d'étiquette est utilisée pendant la sélection) :
  - Supervisée
  - Non supervisée
  - Semi-supervisée

Algorithmes de sélection de caractéristiques

- Selon le **point de vue des étiquettes (labels)** (si l'information d'étiquette est utilisée pendant la sélection) :
  - Supervisée
  - Non supervisée
  - Semi-supervisée
- Selon le **point de vue de la stratégie de sélection** (comment les caractéristiques sont choisies) :
  - Méthodes enveloppantes (wrapper methods)
  - Méthodes de filtrage (filter methods)
  - Méthodes intégrées (embedded methods)

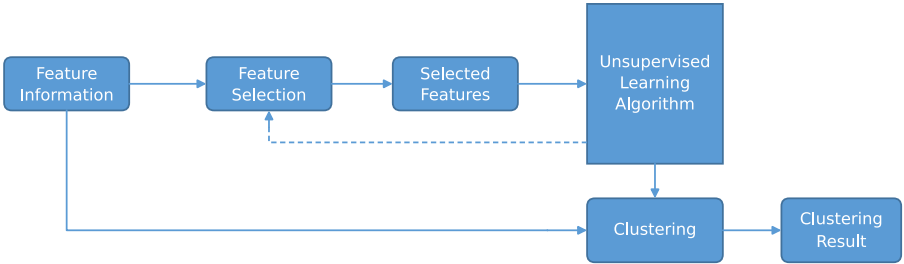
Sélection de caractéristiques supervisée

- La sélection supervisée sert souvent en classification ou en régression
- Trouver des caractéristiques discriminantes qui séparent les échantillons de classes différentes (classification) ou approximent les variables cibles (régression)



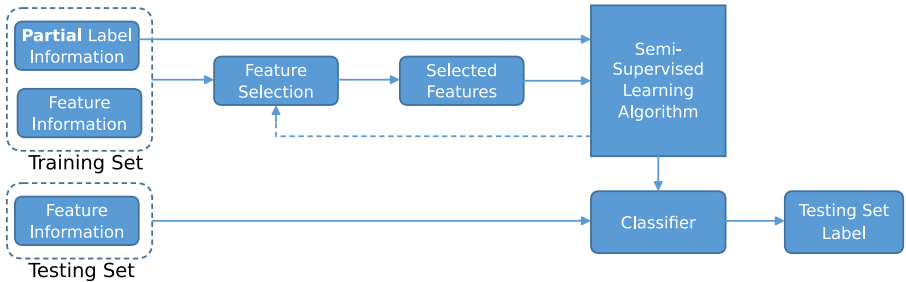
Sélection de caractéristiques non supervisée

- La sélection non supervisée sert souvent au regroupement (clustering)
- L'information d'étiquette est coûteuse à obtenir, en temps comme en effort
- Les méthodes non supervisées définissent la pertinence par d'autres critères

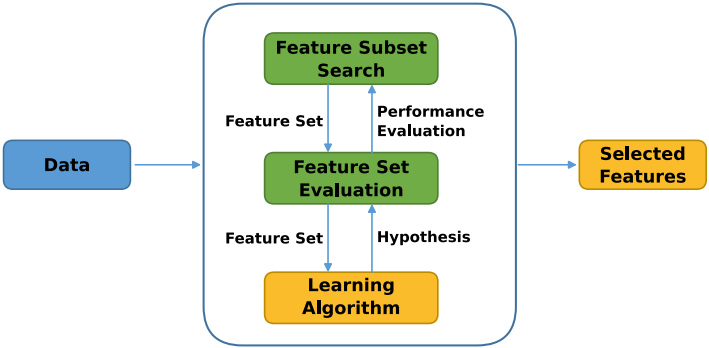


Sélection de caractéristiques semi-supervisée

- Souvent, il y a peu de données étiquetées et beaucoup de données non étiquetées
- Les méthodes semi-supervisées utilisent les deux types de données pour trouver les caractéristiques pertinentes



Méthodes enveloppantes



- Étape 1 : chercher un sous-ensemble de caractéristiques
- Étape 2 : évaluer les caractéristiques choisies
- Répéter les étapes 1 et 2 jusqu'à l'arrêt

Techniques de sélection de caractéristiques

- **Sélection de sous-ensemble : recherche avant et recherche arrière**
  - **Recherche avant (forward search)**
    - Commencer sans aucune caractéristique
    - Ajouter de façon gloutonne (greedy) la caractéristique la plus pertinente
    - Arrêter une fois le nombre voulu de caractéristiques atteint
  - **Recherche arrière (backward search)**
    - Commencer avec toutes les caractéristiques
    - Retirer de façon gloutonne la caractéristique la moins pertinente
    - Arrêter une fois le nombre voulu de caractéristiques atteint
  - Le critère d'ajout/retrait utilise la **validation croisée (cross-validation)**

Méthodes enveloppantes

- S'appliquent à **N'IMPORTE QUEL modèle.**
- Utilisent la **performance prédictive d'un algorithme d'apprentissage prédéfini** pour évaluer les caractéristiques
- **Réduire / agrandir l'ensemble** de caractéristiques par recherche gloutonne
- Répéter jusqu'à ce que **certains critères d'arrêt** soient satisfaits
- Obtiennent une **grande exactitude (accuracy)** pour une méthode donnée
- **Validation croisée / division entraînement-validation**
  - Pour chaque caractéristique
- **Coûteuses en calcul** (espace de recherche de 2^d au pire), quelques stratégies de recherche typiques :
  - Recherche séquentielle
  - Recherche meilleur d'abord (best-first)
  - Recherche par séparation et évaluation (branch-and-bound)

Méthodes de filtrage

- **Indépendantes** de tout algorithme d'apprentissage
- **Utilisent certaines propriétés** des données pour évaluer l'importance des caractéristiques (p. ex. corrélation, information mutuelle...)
- Plus **efficaces** que les méthodes enveloppantes
- Les caractéristiques choisies **peuvent ne pas être optimales** pour un algorithme ou un problème donné.



Techniques de sélection de caractéristiques

- **Évaluation d'une seule caractéristique : mesurer sa qualité avec toutes sortes de métriques**
  - Basées sur la fréquence
  - Dépendance entre caractéristique et étiquette (cooccurrence), p. ex. *information mutuelle (mutual information), statistique du khi-deux*
  - Théorie de l'information, divergence KL, gain d'information (information gain)
  - Indice de Gini

Méthodes intégrées

- Un compromis (tradeoff) entre méthodes enveloppantes et de filtrage, en intégrant la sélection dans l'apprentissage du modèle, p. ex. ID3
- Héritent des avantages des méthodes enveloppantes et de filtrage
  - Tiennent compte des interactions avec l'algorithme d'apprentissage
  - Plus efficaces que les méthodes enveloppantes
- Biaisées vers l'algorithme sous-jacent, comme les méthodes enveloppantes

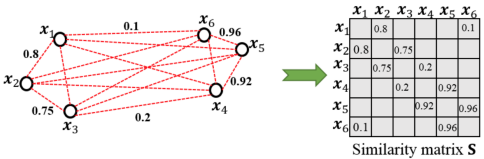


Critères de sélection

- **Sélection de caractéristiques traditionnelle**
  - Méthodes basées sur la similarité
  - Méthodes basées sur la théorie de l'information
  - Méthodes basées sur l'apprentissage parcimonieux (sparse learning)
  - Méthodes statistiques

Méthodes basées sur la similarité : technique de similarité

- La similarité entre paires de données est souvent encodée dans une matrice de similarité



- P. ex., sans étiquettes, elle peut être définie par le noyau RBF (RBF kernel)

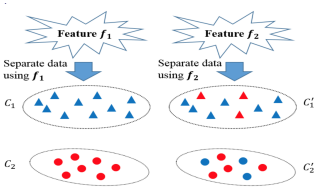
$$\mathbf{S}_{ij} = e^{-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}}$$

- P. ex., avec les étiquettes de classe, la similarité peut être obtenue par

$$\mathbf{S}_{ij} = \begin{cases} \frac{1}{n_l} & \text{si } y_i = y_j = l \\ 0 & \text{sinon} \end{cases}$$

Sélection de caractéristiques basée sur la similarité

- Les méthodes basées sur la similarité évaluent l'importance d'une caractéristique par sa capacité à préserver la similarité des données
- Une bonne caractéristique ne devrait pas assigner des valeurs au hasard aux instances
- Une bonne caractéristique devrait assigner des valeurs similaires aux instances proches les unes des autres – (la « proximité » vient de la matrice de similarité)
- Les formes différentes indiquent des valeurs différentes assignées par une caractéristique



Méthodes basées sur la similarité – cadre général

- Étant donné la matrice de similarité $\mathbf{S}$, les caractéristiques les plus pertinentes $\mathcal{S}$ maximisent :

$$\underbrace{\max_{\mathcal{S}} U(\mathcal{S})}_{\text{utilité de l'ensemble } \mathcal{S}} = \max_{\mathcal{S}} \sum_{f \in \mathcal{S}} \underbrace{U(f)}_{\text{utilité de la caractéristique } f} = \max_{\mathcal{S}} \sum_{f \in \mathcal{S}} \hat{\mathbf{f}}' \hat{\mathbf{S}} \hat{\mathbf{f}}$$

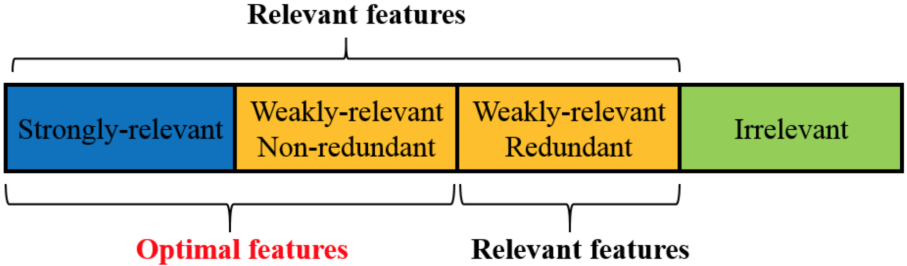
- Utilité $U(\cdot)$: à quel point l'ensemble préserve la similarité des données
- Le problème est souvent résolu en choisissant de façon gloutonne les caractéristiques qui maximisent leur utilité individuelle $U(f)$
- Les méthodes diffèrent par la façon dont le vecteur $\mathbf{f}$ et la matrice de similarité $\mathbf{S}$ sont transformés en $\hat{\mathbf{f}}$ et $\hat{\mathbf{S}}$

Méthodes basées sur la similarité – résumé

- Plusieurs autres méthodes se ramènent au cadre général basé sur la similarité
  - Score laplacien par lots (Nie *et al.*, 2008)
  - RelieF (Robnik-Šikonja and Kononenko, 2003)
  - Critère HSIC (Song *et al.*, 2007) ...
- Avantages :
  - Scores des caractéristiques simples et faciles à calculer
  - Les caractéristiques choisies se généralisent aux tâches d'apprentissage suivantes
- Inconvénients :
  - La plupart des méthodes ne gèrent pas la redondance entre caractéristiques

Méthodes basées sur la théorie de l'information

- Utilisent différents critères de filtrage heuristiques pour mesurer l'importance des caractéristiques
- Le but est de trouver ces caractéristiques « optimales »



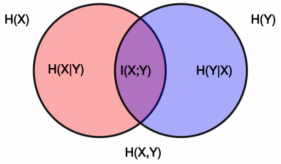
Préliminaires – mesures de théorie de l'information

- Entropie d'une variable discrète X :

$$H(X) = -\sum_{x_i \in X} P(x_i) \log P(x_i)$$

- Entropie conditionnelle de X étant donné Y :

$$H(X|Y) = -\sum_{y_j \in Y} P(y_j) \sum_{x_i \in X} P(x_i|y_j) \log P(x_i|y_j)$$



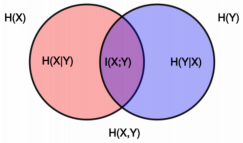
Préliminaires – mesures de théorie de l'information

- Gain d'information entre X et Y :

$$I(X;Y) = H(X) - H(X|Y) = \sum_{x_i \in X} \sum_{y_j \in Y} P(x_i, y_j) \log \frac{P(x_i, y_j)}{P(x_i)P(y_j)}$$

- Gain d'information conditionnel :

$$\begin{aligned} I(X;Y|Z) &= H(X|Z) - H(X|Y,Z) \\ &= \sum_{z_k \in Z} P(z_k) \sum_{x_i \in X} \sum_{y_j \in Y} P(x_i, y_j|z_k) \log \frac{P(x_i, y_j|z_k)}{P(x_i|z_k)P(y_j|z_k)} \end{aligned}$$



Théorie de l'information – cadre général

- Chercher le meilleur sous-ensemble est NP-difficile ; la plupart des méthodes utilisent des heuristiques de recherche séquentielle avant/arrière
- P. ex., en recherche avant, étant donné les caractéristiques choisies $\mathcal{S}$, la prochaine caractéristique f_k devrait :
  - Maximiser sa corrélation avec les étiquettes Y : $I(f_k; Y)$
  - Minimiser la redondance avec les caractéristiques de $\mathcal{S}$: $\sum_{f_j \in \mathcal{S}} I(f_j; f_k)$
  - Maximiser l'information complémentaire avec $\mathcal{S}$: $\sum_{f_j \in \mathcal{S}} I(f_j; f_k | Y)$

Théorie de l'information – cadre général

- Étant donné les caractéristiques choisies $\mathcal{S}$, le score de la prochaine caractéristique peut être déterminé par

$$score(f_k) = I(f_k; Y) + \sum_{f_j \in \mathcal{S}} g\left[I(f_j; f_k), I(f_j; f_k|Y)\right]$$

  - $g(*)$: une fonction
  - Plus le score est élevé, meilleure est la caractéristique choisie

Théorie de l'information – cadre général

- Étant donné les caractéristiques choisies $\mathcal{S}$, le score de la prochaine caractéristique peut être déterminé par

$$score(f_k) = I(f_k; Y) + \sum_{f_j \in \mathcal{S}} g\left[I(f_j; f_k), I(f_j; f_k|Y)\right]$$

  - $g(*)$: une fonction
  - Plus le score est élevé, meilleure est la caractéristique choisie

- Si $g(*)$ est une fonction linéaire, le score peut s'écrire

$$score(f_k) = I(f_k; Y) - \beta \sum_{f_j \in \mathcal{S}} I(f_j; f_k) + \lambda \sum_{f_j \in \mathcal{S}} I(f_j; f_k|Y)$$

  - β et λ sont entre 0 et 1

- En général, $g(*)$ peut être une fonction non linéaire

Sélection par information mutuelle (Battiti, 1994)

- Le gain d'information ne considère que la pertinence des caractéristiques
- Les caractéristiques ne devraient pas non plus être redondantes entre elles
- Le score d'une nouvelle caractéristique non choisie f_k :

$$score(f_k) = \underbrace{I(f_k; Y)}_{\text{maximiser la pertinence}} - \beta \underbrace{\sum_{f_j \in \mathcal{S}} I(f_k; f_j)}_{\text{minimiser la redondance}}$$

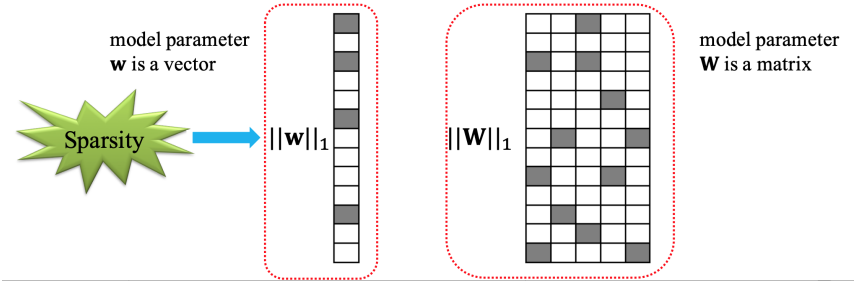
- C'est aussi un cas particulier de la fonction linéaire, avec $\lambda = 0$

Théorie de l'information – résumé

- Autres méthodes basées sur la théorie de l'information
  - Fast Correlation Based Filter (Yu and Liu, 2004)
  - Interaction Gain Feature Selection (El Akadi *et al.*, 2008)
  - Conditional MIFS (Cheng *et al.*, 2011)...
- Avantages :
  - Gèrent à la fois la pertinence et la redondance
  - Les caractéristiques choisies se généralisent aux tâches suivantes
- Inconvénients :
  - La plupart des algorithmes ne fonctionnent qu'en mode supervisé
  - Ne gèrent que des données discrétisées

Méthodes parcimonieuses : qu'est-ce que la parcimonie ?

- Les paramètres du modèle dans beaucoup de tâches de fouille de données (data mining) peuvent s'écrire comme un vecteur **w** ou une matrice **W**
- La parcimonie (sparsity) signifie que beaucoup d'éléments de **w** et **W** sont petits ou exactement nuls



Apprentissage parcimonieux – cadre général

- Partir du problème de classification binaire ou de régression univariée
- Soit $\mathbf{w}$ le paramètre du modèle (aussi appelé coefficient de caractéristique), obtenu en résolvant

$$\mathbf{w} = \arg\min_{\mathbf{w}} \; loss(\mathbf{w}; \mathbf{X}, \mathbf{y}) + \alpha \, penalty(\mathbf{w})$$

  - α : paramètre d'équilibre

- *loss* (perte) pour la classification ou la régression :
  - Perte des moindres carrés
  - Perte charnière (hinge loss)
  - Perte logistique
  - ...

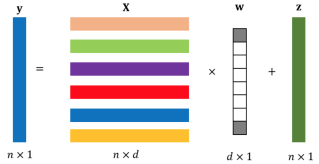
- *penalty* (pénalité) :
  - $\|\mathbf{w}\|_0$ vise les caractéristiques optimales
  - Mais ce n'est pas une vraie norme ; non convexe et NP-difficile
  - Souvent relaxée en $\|\mathbf{w}\|_1$ (Lasso), l'enveloppe convexe la plus serrée

Lasso (Tibshirani, 1996)

- Basé sur une régularisation par norme ℓ_1 sur les poids

$$\min_{\mathbf{w}} \; loss(\mathbf{w}; \mathbf{X}, \mathbf{y}) + \alpha \|\mathbf{w}\|_1$$

- Avec la perte des moindres carrés et un biais (offset), cela donne ...

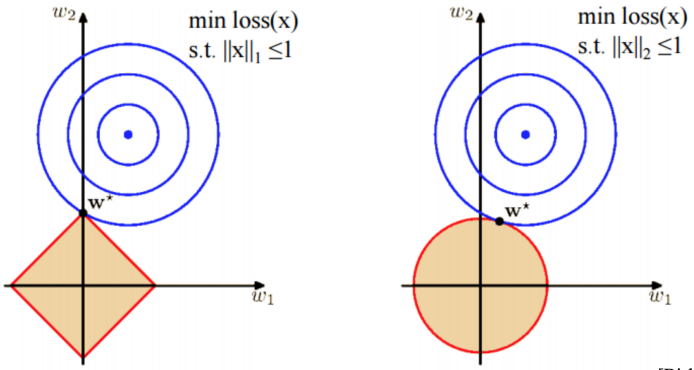


The feature score of the i-th feature is $|\mathbf{w}_i|$; the higher the value, the more important the feature is

- C'est aussi équivalent au modèle suivant

$$\min_{\mathbf{w}} \; loss(\mathbf{w}; \mathbf{X}, \mathbf{y}) \;\; \text{s.c.} \;\; \|\mathbf{w}\|_1 \leq t$$

Parcimonie et normes



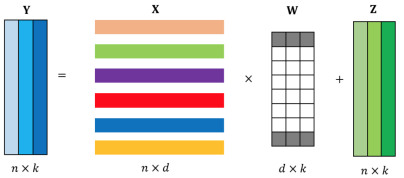
[Bishop, 2006],
[Hastie et al., 2009]

Extension aux problèmes multiclasses ou multivariés

- Exiger une sélection cohérente entre plusieurs cibles en classification multiclasse ou en régression multivariée

$$\min_{\mathbf{W}} \; loss(\mathbf{W}; \mathbf{X}, \mathbf{Y}) + \alpha \|\mathbf{W}\|_{2,1}$$

- $\|\mathbf{W}\|_{2,1}$ donne une parcimonie conjointe des caractéristiques entre cibles
- Avec la perte des moindres carrés et un biais, cela donne



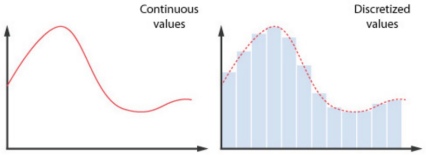
The feature score of the i-th feature is $||\mathbf{W}_{i*}||_2$; the higher the value, the more important the feature is

Apprentissage parcimonieux – résumé

- Autres méthodes basées sur l'apprentissage parcimonieux
  - Sélection guidée par plusieurs étiquettes (Jian *et al.*, 2016)
  - Sélection non supervisée intégrée (Wang *et al.*, 2015)
  - Sélection par apprentissage de structure adaptative (Du and Shen, 2015)
- Avantages :
  - Bonne performance pour la méthode d'apprentissage sous-jacente.
  - Bonne interprétabilité du modèle.
- Inconvénients :
  - Les caractéristiques choisies peuvent ne pas convenir à d'autres tâches.
  - Exigent de résoudre des problèmes d'optimisation non lisses coûteux en calcul.

Méthodes statistiques

- Cette famille d'algorithmes utilise différentes méthodes statistiques pour mesurer l'importance des caractéristiques
- La plupart sont des méthodes de filtrage
- La plupart évaluent chaque caractéristique séparément, donc la redondance est forcément ignorée
- La plupart ne gèrent que des données discrètes ; les caractéristiques numériques doivent d'abord être discrétisées



Score t (Davis and Sampson, 1986)

- Utilisé pour les problèmes de classification binaire
- Évaluer si la caractéristique rend la différence entre les moyennes des deux classes statistiquement significative
- Le score t de chaque caractéristique f_i est

$$t_score(f_i) = \frac{|\mu_1 - \mu_2|}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

  - μ_1, μ_2 : moyenne des échantillons de la première / deuxième classe
  - σ_1, σ_2 : écart-type des échantillons de la première / deuxième classe
- Plus le score t est élevé, plus la caractéristique est importante

Score du khi-deux (Liu and Setiono, 1995)

- Utilise un test d'indépendance pour évaluer si la caractéristique est indépendante de l'étiquette de classe
- Pour une caractéristique à r valeurs, son score est

$$Chi_square_score(f_i) = \sum_{j=1}^{r}\sum_{s=1}^{c}\frac{(n_{js}-\mu_{js})^2}{\mu_{js}}, \qquad \mu_{js} = \frac{n_{*s}\, n_{j*}}{n}$$

  - n_{js} : nb d'instances avec la j-ième valeur et dans la classe s
  - n_{j*} : nb d'instances avec la j-ième valeur de la caractéristique
  - n_{*s} : nb d'instances dans la classe s
- Un khi-deux plus élevé indique une caractéristique plus importante

Méthodes statistiques – résumé

- Autres méthodes statistiques
  - Faible variance – CFS (Hall and Smith, 1999)
  - Kruskal Wallis (McKnight and Najab, 2010)...
- Avantages :
  - Efficaces en calcul
  - Les caractéristiques choisies se généralisent aux tâches suivantes
- Inconvénients :
  - Ne gèrent pas la redondance entre caractéristiques
  - Exigent des techniques de discrétisation des données
  - Beaucoup de mesures statistiques sont peu efficaces en haute dimension

Autres types de méthodes

- Sélection basée sur la reconstruction
  - Minimiser l'erreur de reconstruction des données avec les caractéristiques choisies
  - La fonction de reconstruction peut être linéaire ou non linéaire
- Sélection hybride
  - Construire un ensemble de résultats de sélection différents
  - Agréger ces résultats en un résultat consensuel

Sélection avec caractéristiques structurées : un cadre

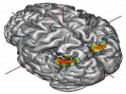
- Une approche populaire et efficace : minimiser l'erreur d'ajustement pénalisée par une régularisation structurelle

$$\mathbf{w} = \arg\min_{\mathbf{w}} \; loss(\mathbf{w}; \mathbf{X}, \mathbf{y}) + \alpha \, penalty(\mathbf{w}, \mathcal{G})$$

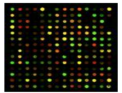
  - $\mathbf{w}$: poids des caractéristiques ; α : paramètre d'équilibre
  - La structure entre caractéristiques est encodée dans $\mathcal{G}$
- Cette formulation permet d'intégrer facilement différents types de structures entre caractéristiques

Structure de groupes – Lasso par groupes

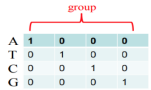
- Dans beaucoup d'applications, les caractéristiques forment des groupes



brain region



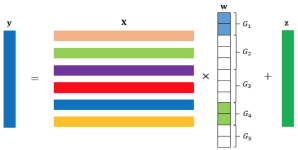
functional group



categorical variable

[Liu et al. SDM 2010]

- Le Lasso par groupes (group lasso) choisit ou rejette un groupe en entier

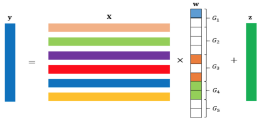


$$\min_{\mathbf{w}} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \alpha \sum_{i=1}^{k} h_i \|\mathbf{w}_{G_i}\|_2$$

- (Yuan and Lin, 2006) : article

Lasso par groupes parcimonieux

- Pour certaines applications, il est souhaitable de choisir des caractéristiques représentatives dans les groupes choisis
- Le Lasso par groupes parcimonieux (sparse group lasso) fait la sélection de groupes et de caractéristiques en même temps

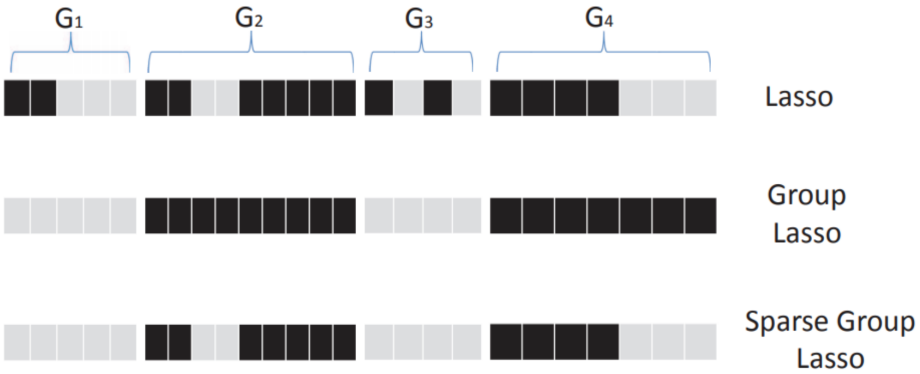


$$\min_{\mathbf{w}} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \alpha\|\mathbf{w}\|_1 + (1-\alpha)\sum_{i=1}^{k} h_i \|\mathbf{w}_{G_i}\|_2$$

- Sélection conjointe des groupes et des caractéristiques
- (Friedman *et al.*, 2010) : article

Structure de groupes – résumé

- Comparaison entre Lasso, Lasso par groupes et Lasso par groupes parcimonieux



Sélection avec caractéristiques structurées – résumé

- Intégrer la structure des caractéristiques comme connaissance a priori

Sélection avec caractéristiques structurées – résumé

- Intégrer la structure des caractéristiques comme connaissance a priori
- Avantages :
  - Améliorent la performance de l'apprentissage dans beaucoup de cas
  - Rendent l'apprentissage plus interprétable

Sélection avec caractéristiques structurées – résumé

- Intégrer la structure des caractéristiques comme connaissance a priori
- Avantages :
  - Améliorent la performance de l'apprentissage dans beaucoup de cas
  - Rendent l'apprentissage plus interprétable
- Inconvénients :
  - Exigent de l'information d'étiquette pour guider la sélection
  - Exigent de résoudre des problèmes d'optimisation complexes et non lisses

Sélection de caractéristiques personnalisée

- L'information de contenu des nœuds est très particulière à chacun
  - P. ex., les blogues, publications et images des utilisateurs peuvent être variés, avec des intérêts sociaux différents
  - P. ex., un même contenu peut avoir des sens différents : « Les prix des maisons sont de plus en plus élevés ! » : vendeur – *positif*, acheteur – *négatif* [Wang et al 2016]
- Mais les nœuds ont aussi des points communs dans une certaine mesure
- Comment traiter la particularité et les points communs des caractéristiques des nœuds pour des tâches comme la classification de nœuds ?

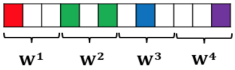
- (Li *et al.*, 2018) : article



Sélection de caractéristiques personnalisée

$$\min_{\tilde{\mathbf{W}},\mathbf{W}_i} \sum_{i=1}^{n} \|\mathbf{x}_i(\underbrace{\tilde{\mathbf{W}}}_{\text{global}} + \underbrace{\mathbf{W}_i}_{\text{local}}) - \mathbf{y}_i\|_2^2 + \beta \sum_{i=1}^{n} \underbrace{\|\mathbf{W}_i\|_{2,1}^2}_{\text{Lasso par groupes exclusif}} + \gamma \|\tilde{\mathbf{W}}\|_{2,1}$$

- $\tilde{\mathbf{W}}$: poids global des caractéristiques pour tous les nœuds ; $\mathbf{W}_i$: poids local pour le i-ième nœud
- Pour trouver des caractéristiques personnalisées, le but est la parcimonie dans chaque poids local
- Le Lasso par groupes exclusif encourage la compétition à l'intérieur des groupes mais décourage la compétition entre groupes



Sélection de caractéristiques personnalisée

- Les poids locaux sont regroupés pour réduire le surapprentissage

$$\min_{\mathbf{W}} \sum_{i,j=1}^{n} \mathbf{A}_{ij} \|\mathbf{W}_i - \mathbf{W}_j\|_F$$

  - Les nœuds connectés s'appuient les uns sur les autres

- La fonction objectif

$$\min_{\tilde{\mathbf{W}}, \mathbf{W}_i} J(\tilde{\mathbf{W}}, \mathbf{W}_i) = \sum_{i=1}^{n} \|\mathbf{x}_i(\tilde{\mathbf{W}} + \mathbf{W}_i) - \mathbf{y}_i\|_2^2 + \alpha \sum_{i,j=1}^{n} \mathbf{A}_{ij} \|\mathbf{W}_i - \mathbf{W}_j\|_F + \beta \sum_{i=1}^{n} \|\mathbf{W}_i\|_{2,1}^2 + \gamma \|\tilde{\mathbf{W}}\|_{2,1}$$

- (Li *et al.*, 2018) : article

Résumé

- La sélection de caractéristiques combat le fléau de la dimension (curse of dimensionality) et est essentielle en fouille de données et apprentissage automatique
- Les objectifs de la sélection de caractéristiques incluent
  - Construire des modèles plus simples et plus compréhensibles
  - Améliorer la performance de l'apprentissage
  - Préparer des données propres et compréhensibles
- La sélection reste aussi importante à l'ère de l'apprentissage profond (deep learning) et des données massives (big data)
- Un survol structuré de la sélection du point de vue des données
  - Sélection pour données classiques (quatre grandes catégories)
  - Sélection avec caractéristiques structurées
  - Sélection avec données hétérogènes
  - Sélection avec données multisources

Quiz/Sondage

Qu'est-ce qu'une caractéristique redondante ?

- (A) une caractéristique sans aucun lien avec la cible
- (B) une caractéristique qui duplique l'information d'autres caractéristiques
- (C) une caractéristique avec beaucoup de valeurs manquantes à imputer d'abord
- (D) la caractéristique la plus fortement corrélée avec la cible

Quiz/Sondage

Dans quels cas les méthodes de théorie de l'information sont-elles utilisables pour la sélection de caractéristiques ?

- (A) seulement si les caractéristiques sont continues et sans aucune étiquette
- (B) seulement si le modèle utilisé ensuite est linéaire
- (C) seulement après avoir entraîné un réseau de neurones profond
- (D) avec des étiquettes et des caractéristiques discrètes (ou discrétisées)

Ressources

- Matériel des années précédentes
- An introduction to Variable and feature Selection
- Billet de blogue sur la sélection de caractéristiques
- Plus sur le Lasso par groupes
- Feature Selection for Data and Pattern Recognition
- Computational Methods of Feature Selection
- A Survey of Feature Selection Techniques

Roberto Battiti. Using mutual information for selecting features in supervised neural net learning. *IEEE Transactions on Neural Networks*, 5(4):537–550, 1994.

H. Cheng, Z. Qin, C. Feng, Y. Wang, and F. Li. Conditional mutual information-based feature selection analyzing for synergy and redundancy. *ETRI Journal*, 33(2):210–218, 2011.

John C. Davis and Robert J. Sampson. *Statistics and Data Analysis in Geology*. Wiley, 1986.

Liang Du and Yi-Dong Shen. Unsupervised feature selection with adaptive structure learning. In *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, 2015.

Ali El Akadi, Abdeljalil El Ouardighi, and Driss Aboutajdine. A powerful feature selection approach based on mutual information. *International Journal of Computer Science and Network Security*, 2008.

Jerome Friedman, Trevor Hastie, and Robert Tibshirani. A note on the group lasso and a sparse group lasso. *arXiv preprint arXiv:1001.0736*, 2010.

Mark A. Hall and Lloyd A. Smith. Feature selection for machine learning: Comparing a correlation-based filter approach to the wrapper. In *Proceedings of*

the Twelfth International Florida Artificial Intelligence Research Society Conference (FLAIRS), 1999.

Ling Jian, Jundong Li, Kai Shu, and Huan Liu. Multi-label informed feature selection. In *Proceedings of the International Joint Conference on Artificial Intelligence (IJCAI)*, pages 1627–1633, 2016.

Jundong Li, Liang Wu, Harsh Dani, and Huan Liu. Unsupervised personalized feature selection. In *AAAI Conference on Artificial Intelligence*, 2018.

Huan Liu and Rudy Setiono. Chi2: Feature selection and discretization of numeric attributes. In *IEEE International Conference on Tools with Artificial Intelligence*, pages 388–391, 1995.

Patrick E. McKnight and Julius Najab. Kruskal-wallis test. In *The Corsini Encyclopedia of Psychology*. Wiley, 2010.

Feiping Nie, Shiming Xiang, Yangqing Jia, Changshui Zhang, and Shuicheng Yan. Trace ratio criterion for feature selection. In *Proceedings of the AAAI Conference on Artificial Intelligence*, pages 671–676, 2008.

Marko Robnik-Šikonja and Igor Kononenko. Theoretical and empirical analysis of ReliefF and RReliefF. *Machine Learning*, 53(1–2):23–69, 2003.

Le Song, Alex Smola, Arthur Gretton, Karsten M. Borgwardt, and Justin Bedo. Supervised feature selection via dependence estimation. In *Proceedings of the International Conference on Machine Learning (ICML)*, pages 823–830, 2007.

Robert Tibshirani. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1):267–288, 1996.

Suhang Wang, Jiliang Tang, and Huan Liu. Embedded unsupervised feature selection. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2015.

Lei Yu and Huan Liu. Efficient feature selection via analysis of relevance and redundancy. *Journal of Machine Learning Research*, 5:1205–1224, 2004.

Ming Yuan and Yi Lin. Model selection and estimation in regression with grouped variables. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 68(1):49–67, 2006.