Apprentissage pour la science des données

Cours 14 : Apprentissage non supervisé

Glen Berseth

Université de Montréal et Institut québécois d'intelligence artificielle (Mila)

October 13, 2026



Plan

Apprendre sans supervision

ACP : analyse en composantes principales

Regroupement

Regroupement hiérarchique

Apprendre sans supervision

Qu'est-ce que l'apprentissage non supervisé ?

- Apprentissage supervisé : apprendre une fonction $f : X \to Y$
- Apprentissage non supervisé :
  - *Que faire avec (x_i) ?*
  - *Explorer les données*
- Pas vraiment de notion de bonne réponse (contrairement à l'apprentissage supervisé)

Thèmes communs

- Beaucoup plus difficile à évaluer
- La plupart des méthodes sont de l'un de ces types :
  - Réduction de dimension (dimensionality reduction) : peu de caractéristiques (features) qui en résument beaucoup
  - Regroupement (clustering) : peu de « prototypes » représentatifs de tout le jeu de données
  - $\Rightarrow$ De meilleures représentations (c.-à-d. plus petites)
- Exemples classiques vus dans ce cours :
  - ACP (PCA) (réduction de dimension)
  - K-moyennes et regroupement hiérarchique (regroupement)





Comment est-ce fait ?

Données d'entraînement		Algorithme d'apprentissage automatique		Prédictions[1]
x_1 x_2 x_3 $\vdots$	$\longrightarrow$	Fonction d'hypothèse $? \approx h(x_i)$	$\longrightarrow$	Nouvel exemple x $? = h(x)$

[1] Crédit : Zico Kolter

Comment est-ce fait ?

Données d'entraînement		Algorithme d'apprentissage automatique		Prédictions[2]
(x_1, y_1) (x_2, y_2) (x_3, y_3) $\vdots$	$\longrightarrow$	Fonction d'hypothèse $y_i \approx h(x_i)$	$\longrightarrow$	Nouvel exemple x $\hat{y} = h(x)$

[2] Crédit : Zico Kolter

Comment est-ce fait ?

- En pratique, les mêmes idées d'apprentissage automatique sont utilisées :
  1. Définir la fonction d'hypothèse (hypothesis function) : ce qui est extrait des données
  2. Définir une fonction de perte (loss)
  3. Minimiser la perte

Cadre de l'apprentissage non supervisé

- **Caractéristiques d'entrée :** $x_i \in \mathbb{R}^n,\ i = 1, \ldots, m$
- **Paramètres du modèle :** $\theta \in \mathbb{R}^k$
- **Fonction d'hypothèse :** $h_\theta : \mathbb{R}^n \to \mathbb{R}^m$, approxime l'entrée à partir de l'entrée, c.-à-d. le but est $x_i \approx h_\theta(x_i)$
- **Fonction de perte :** $\ell : \mathbb{R}^n \times \mathbb{R}^m \to \mathbb{R}_+$, mesure l'écart entre une hypothèse et l'entrée réelle, p. ex. : $\ell(h_\theta(x), x) = \|h_\theta(x) - x\|_2^2$
- Même problème d'optimisation classique en apprentissage automatique :

$$\min_\theta \sum_{i=1}^{m} \ell(h_\theta(x_i), x_i)$$

Cadre de l'apprentissage non supervisé

- Quel est le but ici ????
- Pourquoi ne pas simplement utiliser $h_\theta(x) = x$?
- La fonction identité **est inutile.**
- Le but est de **compresser ! (représentations plus petites).**
  - Trouver des groupes : (décrire les données par un plus petit nombre de groupes et leur représentant)
  - Réduction de dimension (trouver une représentation plus petite de x)

Réduction de dimension : une représentation plus petite de l'entrée

Qu'est-ce que c'est ?



Réduction de dimension : une représentation plus petite de l'entrée

Qu'est-ce que c'est ?

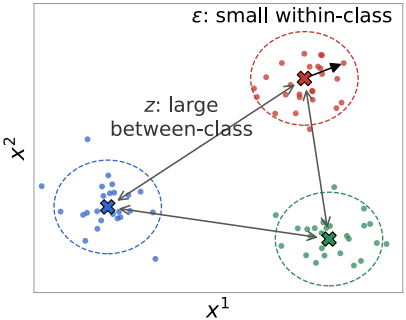


3

[3] Crédit pour l'idée : Pr Julie Josse

Une représentation plus petite de l'entrée

- Idée : certaines **vues** de données en haute dimension sont **plus informatives que d'autres**.
- Existe-t-il une représentation en basse dimension de variation maximale ?
- Pourquoi beaucoup de variation ? $x = z + \epsilon$
- Exemple (avec étiquettes) :
  - z : type général de la variable : grande variation entre les classes
  - ϵ : variation dans la classe : plus petite



ACP : analyse en composantes principales

- Existe-t-il une représentation en basse dimension de variation maximale ?
- Pour mettre en œuvre l'idée :
  - Quelle sera la famille de représentations candidates ?
    - → **Combinaisons linéaires des caractéristiques**
  - Comment choisir parmi tous les candidats ?
    - → **Meilleure reconstruction**

Analyse en composantes principales

- Considérons la représentation de x_i (les points sont projetés sur une direction) :

$$z_i = \sum_{j=1}^{d} \varphi_1^j x_i^j = \langle \varphi_1, x_i \rangle$$

- z_i donne un « résumé » de x_i par une combinaison linéaire de ses composantes.
- Analyse en composantes principales (Pearson, 1901)

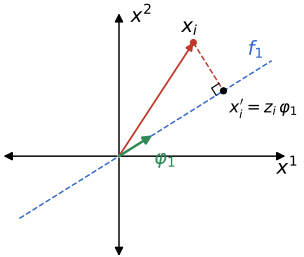
Critère de sélection : variance maximale

- Existe-t-il une représentation en basse dimension de **variation maximale** ?
- Problème d'optimisation :

$$\max_{\|\varphi_1\|=1} \frac{1}{n} \sum_{i=1}^{n} z_i^2$$

- Toutes les caractéristiques doivent avoir une **moyenne 0** (sur les points).
- Très bel exemple [ici]

Critère de sélection : variance maximale

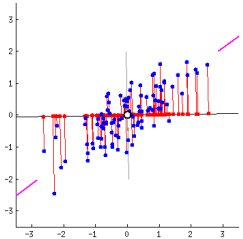


- Soit f_1 la direction de variance maximale et φ_1 un vecteur unitaire le long de celle-ci, c.-à-d. $\|\varphi_1\| = 1$.
- Soit x_i un point et x_i' sa projection sur φ_1. Sa coordonnée le long de φ_1 est z_i :

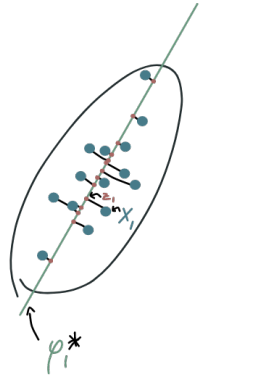
$$z_i = \frac{\varphi_1 \cdot x_i}{\|\varphi_1\|} = \varphi_1^{\mathrm{T}} x_i, \qquad x_i' = z_i \, \varphi_1$$

- L'objectif est de trouver φ_1 avec $\|\varphi_1\| = 1$ qui maximise $\mathrm{Var}_i(\varphi_1^{\mathrm{T}} x_i) = \frac{1}{n} \sum_{i=1}^{n} z_i^2$ (caractéristiques centrées).
- Rappel : un produit scalaire mesure le recouvrement/la similarité des vecteurs.
  - L'objectif est un vecteur qui recouvre bien les données (via le produit scalaire)

Critère de sélection : variance maximale

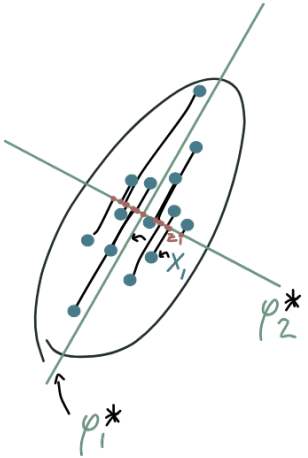






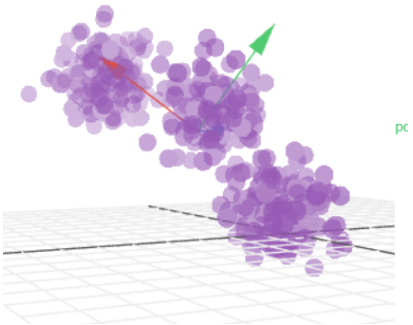
Deuxième, troisième directions de l'ACP

- Après la première direction, la deuxième direction principale peut être trouvée.
- **Même problème** avec la contrainte d'être **orthogonale à la direction précédente**.
- Interprétation : l'ACP trouve un nouveau et meilleur système de coordonnées pour les données



Deuxième, troisième directions de l'ACP

- Après la première direction, la deuxième direction principale peut être trouvée.
- **Même problème** avec la contrainte d'être **orthogonale à la direction précédente**.
- Interprétation : l'ACP trouve un nouveau et meilleur système de coordonnées pour les données



Vocabulaire

- φ_k : « direction » ou « composantes » de l'ACP.
- z^k : scores (scores) : coordonnées selon la k^{e} direction de l'ACP.

Importance de la Normalisation

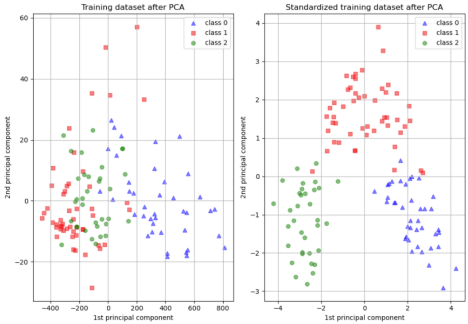
- Très important de « standardiser » les caractéristiques (standardization) !!!
- Exemple :
  - La taille humaine (1,50 m ± 1 m) varie moins que le poids humain (env. 70 kg ± 50 kg) (simplement **à cause du système d'unités !!!!!)**
  - Un changement de 1 m est plus important que 10 kg.
- Conséquence : l'ACP cherche les corrélations entre les variables.
- Soit X la variable aléatoire des données telle que : $x_1, \ldots, x_n \sim X$

$$\arg\max_{\|\varphi\|=1} \mathbb{E}\Big[\Big(\sum_{j=1}^{d} X^j \varphi^j\Big)^2\Big] = \arg\max_{\|\varphi\|=1} \sum_{1\leq j<l\leq d} \underbrace{\mathbb{E}[X^j X^l]\varphi^j \varphi^l}_{\text{Choisit les dimensions les plus corrélées de } X}$$

$$\mathbb{E}[X] = 0,\ \mathbb{V}[X^j] = 1 \quad \forall j$$

Importance de la mise à l'échelle des caractéristiques

- Jeu de données Wine
- Caractéristiques continues **d'échelles très différentes**, car elles mesurent des propriétés différentes (p. ex. taux d'alcool et acide malique).
- L'ACP est beaucoup plus efficace **après standardisation**.
- (SUR CE jeu de données PRÉCIS)



Lien

Importance de la mise à l'échelle des caractéristiques

- Standardiser les caractéristiques force l'ACP à regarder les corrélations.
  - Parfois, les caractéristiques ont toutes la même unité
  - Diviser par l'écart-type peut effacer le fait que certaines caractéristiques ont plus de variance « objective » que d'autres.

Autre interprétation : approximation linéaire

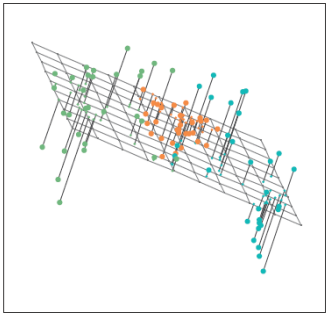
- Les K premières directions de l'ACP donnent la meilleure approximation linéaire de dimension K

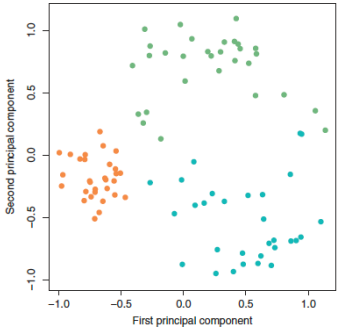
$$\min_{\varphi} \sum_{i=1}^{n} \| \underbrace{h_{\varphi}(x_i)}_{\text{de dimension } K} - x_i \|_2^2$$

$$h_{\varphi}(x) = \sum_{k=1}^{K} z^k(x) \varphi_k, \quad z^k(x) = \langle \varphi_k, x \rangle$$

Autre interprétation : approximation linéaire

- $h_\varphi(x) = \sum_{k=1}^{K} z^k \varphi_k$: approximation linéaire de x, $\quad h_\varphi(x) = \Phi x$





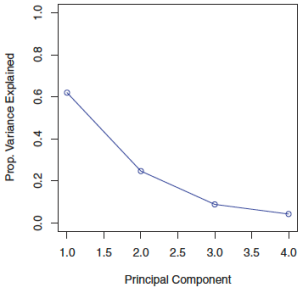
Variance expliquée

Part de la variance expliquée (explained variance) par les K premières composantes principales.

$$\frac{\sum_{k=1}^{K} \sum_{i=1}^{n} (z_i^k)^2}{\sum_{i=1}^{n} \|x_i - \bar{x}\|^2} \qquad \text{(entre 0 et 1)}$$

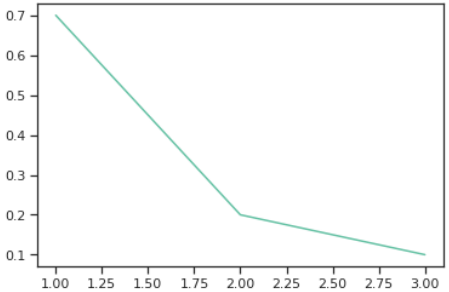
Variance expliquée

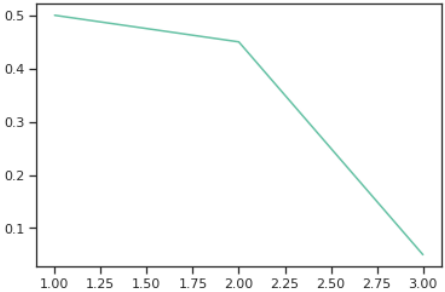
- 62 % de la variance des données est expliquée par la première composante
- 24,7 % par la deuxième composante
- Les deux premières composantes donnent une image assez fidèle de la variance des données.



Exercice

- À quoi ressemblerait la part de variance expliquée si :
  - Les données (3D) avaient la forme
    - D'une crêpe (deux directions longues, une courte) ?
    - D'un cigare (une direction longue, deux courtes) ?





Comment choisir K, le nombre de composantes

- Pas de consensus clair
- Dépend de l'application
- Utile de regarder la variance expliquée
- Règle empirique (rule of thumb) :
  - Rien d'intéressant dans la 1re composante : sans doute inutile de continuer
  - S'il y a quelque chose d'intéressant, augmenter K jusqu'à ce qu'il n'y ait plus rien d'intéressant

Gérer les valeurs manquantes

- Problème de reconstruction avec des valeurs manquantes (missing values) :

$$\min_{\varphi} \sum_{i=1}^{n} \sum_{j=1}^{d} \left([h_\varphi(x_i)]^j - x_i^j \right)^2$$

$$\Downarrow$$

$$\min_{\varphi} \sum_{(i,j)\in\mathcal{O}} \left([h_\varphi(x_i)]^j - x_i^j \right)^2, \qquad \mathcal{O} : \text{valeurs observées}$$

- Une fois résolu, il peut servir à prédire les valeurs manquantes !!!

Application : le défi Netflix

- Jeu de données :
  - $n = 480\ 189$
  - $p = 17\ 770$
  - 99 % de valeurs manquantes.
- But : suggérer des films pertinents.
- Défi à 1 M USD
- Idée : peu de caractéristiques devraient prédire les goûts d'un client.
- Trouver ces caractéristiques avec l'ACP

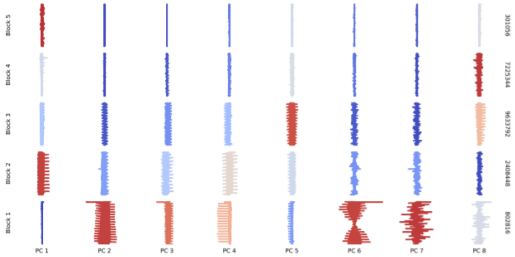
	Jerry Maguire	Oceans	Road to Perdition	A Fortunate Man	Catch Me If You Can	Driving Miss Daisy	The Two Popes	The Laundromat	Code 8	The Social Network	⋱
Customer 1	·	·	·	·	4	·	·	·	·	·	
Customer 2	·	·	3	·	·	·	3	·	·	3	⋯
Customer 3	·	2	·	4	·	·	·	·	2	·	⋯
Customer 4	3	·	·	·	·	·	·	·	·	·	⋯
Customer 5	5	1	·	·	4	·	·	·	·	·	⋯
Customer 6	·	·	·	·	·	2	4	·	·	·	⋯
Customer 7	·	·	5	·	·	·	·	3	·	·	⋯
Customer 8	·	·	·	·	·	·	·	·	·	·	⋯
Customer 9	3	·	·	·	5	·	·	1	·	·	⋯
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋱

Conclusion : conseils pratiques

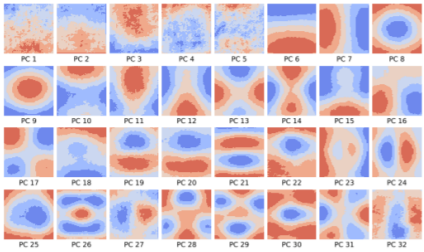
- Même si la méthode est simple à lancer, beaucoup de problèmes sont possibles :
  - Les variables peuvent être à des unités différentes, et il peut être ambigu de savoir s'il faut les remettre à l'échelle standard ou non.
  - Les directions ne sont **uniques qu'au signe près** (attention en interprétant le signe des valeurs z_i)
  - Peut gérer les valeurs manquantes !
  - Choisir K peut être délicat.

Des avancées récentes sur l'ACP

- Nouvelles techniques pour calculer l'ACP des activations d'un réseau profond (ResNet 200) sur Imagenet.
- $d = 20$ M
- $n = 1{,}2$ M
- La matrice de covariance fait 195 To (elle ne tiendra évidemment jamais en mémoire. . .)



(a) Principal Components



(b) Block-1 Mean Filter Maps

Lien

Méthodes non supervisées récentes à grande échelle

- CLIP : relier le texte et les images (Radford *et al.*, 2021)
- Et s'il existait une structure commune entre des parties de x ?
- $X = (X_{\text{image}}, X_{\text{text}})$
  - Les deux décrivent le même concept.
- Le but est alors
  - $f_{\text{image}}(X_{\text{image}}) \approx f_{\text{text}}(X_{\text{text}})$

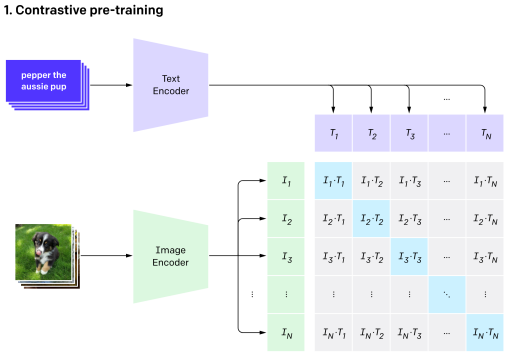


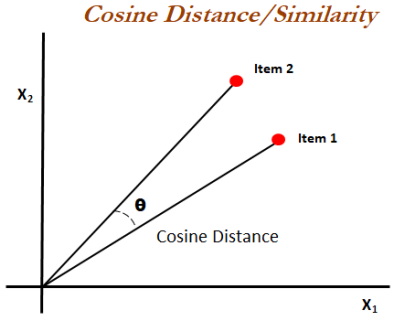
[4]

[4] https://openai.com/index/clip/

CLIP : relier le texte et les images

- Le but est alors
  - $f_{\text{image}}(X_{\text{image}}) \approx f_{\text{text}}(X_{\text{text}})$





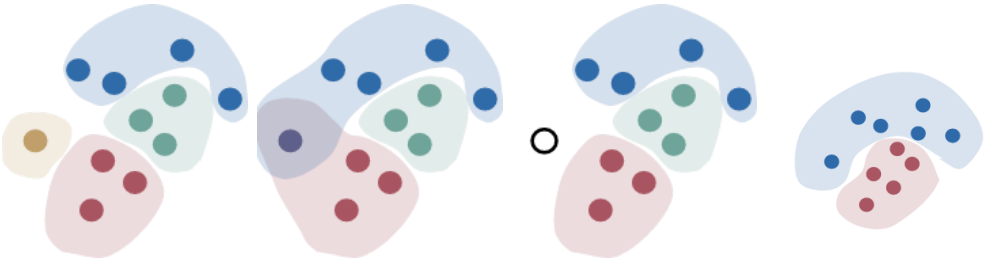
Similarité cosinus (cosine similarity)

Regroupement

- Idée : partitionner les observations pour regrouper celles qui se ressemblent
- Chercher des sous-groupes homogènes dans des données hétérogènes.

Formalisation

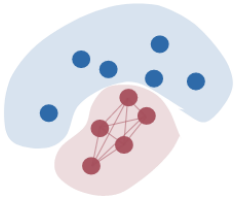
- Une partition $C_1, \ldots, C_K$ est une collection de sous-ensembles telle que :
  - Chaque exemple est dans un sous-ensemble : $C_1 \cup \cdots \cup C_K = \{1, \ldots, n\}$
  - Les sous-ensembles sont disjoints : pour toute paire, $C_k \cap C_{k'} = \emptyset$ pour $k \neq k'$



Formalisation du regroupement

Le but n'est pas n'importe quelle partition, mais celle qui **minimise la variation intra-groupe**, notée $W(C_k)$:

$$\min_{C_1,\ldots,C_K} \sum_{k=1}^{K} W(C_k)$$



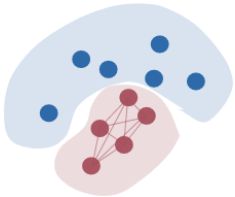
En général :

$$W(C_k) = \frac{1}{|C_k|} \sum_{i,i' \in C_k} \underbrace{\|x_i - x_{i'}\|^2}_{\text{Somme des distances}}$$

Formalisation du regroupement

Le but n'est pas n'importe quelle partition, mais celle qui **minimise la variation intra-groupe**, notée $W(C_k)$:

$$\min_{C_1,\ldots,C_K} \sum_{k=1}^{K} W(C_k)$$



En général :

$$W(C_k) = \frac{1}{|C_k|} \sum_{i,i' \in C_k} \underbrace{\|x_i - x_{i'}\|^2}_{\text{Somme des distances}}$$

Minimiser sur les sous-ensembles : insoluble en pratique

- Un algorithme est nécessaire pour trouver une solution approchée

K-moyennes

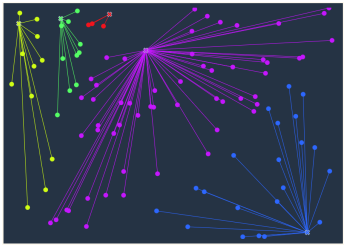
- Problème d'optimisation combinatoire : l'optimum global est difficile à calculer.
- Mais les K-moyennes (K-means) (Lloyd, 1982) trouvent souvent de bons optimums locaux :

1. Assigner arbitrairement chaque x_i à l'un des groupes $C_1, \ldots, C_K$.
2. Répéter jusqu'à convergence :
   a. Calculer la moyenne $\bar{x}_k$ des points de C_k.
   b. Réassigner chaque point x_i au groupe dont le centroïde est le plus proche.

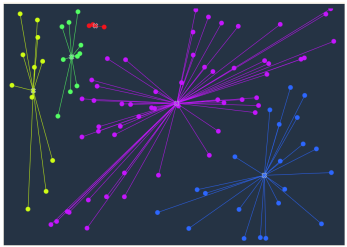
K-moyennes

Très belle démo : [ici]

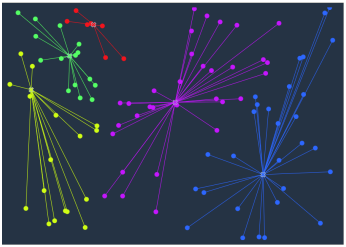
Étape 1 :



Étape 2 :

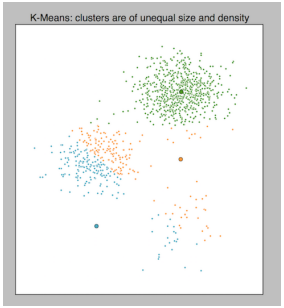


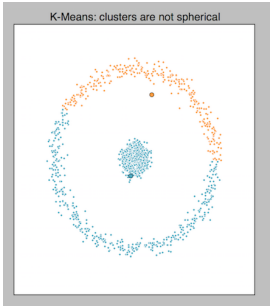
Étape 3 :



Limites

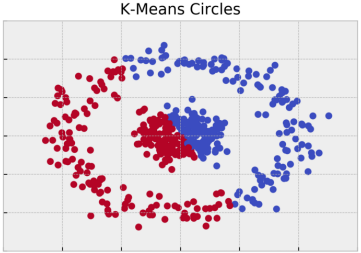
- Les K-moyennes regroupent souvent mal les données quand il y a :
  - Des variations de densité (groupes de tailles différentes)
  - **Des groupes non sphériques (à cause de la distance utilisée)**
  - Des valeurs aberrantes (outliers).

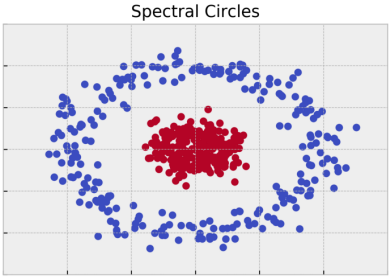




Comment corriger (certaines de) ces limites

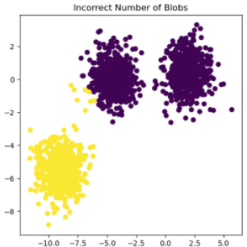
- Essayer d'autres notions de distance (voir plus loin)
- Extraire de meilleures caractéristiques pour le regroupement (p. ex. coordonnées polaires ou composante principale de la matrice laplacienne) [plus de détails ici]



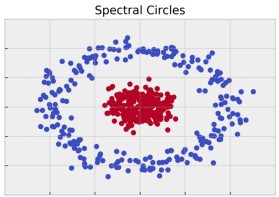


Évaluation supervisée des K-moyennes

- **Évaluation supervisée :** comparer à un jeu de données déjà étiqueté.
- Pas complètement trivial :
  - La valeur des **étiquettes est arbitraire**.
  - Peut-être pas le bon nombre de groupes.
  - **Impossible** d'utiliser la perte 0-1 sur les classes.



Rouge = 1, Bleu = 0



Lien

Évaluation supervisée des K-moyennes

- **Évaluation supervisée :** comparer à un jeu de données déjà étiqueté.
- Pas complètement trivial : la valeur des **étiquettes est arbitraire** + peut-être pas le bon nombre de groupes. **Impossible** d'utiliser la perte 0-1.

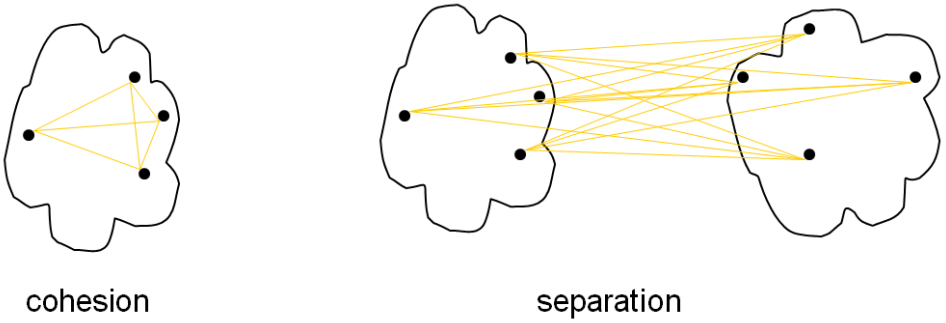
Évaluation supervisée des K-moyennes

- **Évaluation supervisée :** comparer à un jeu de données déjà étiqueté.
- Pas complètement trivial : la valeur des **étiquettes est arbitraire** + peut-être pas le bon nombre de groupes. **Impossible** d'utiliser la perte 0-1.
- **Homogénéité (homogeneity) :** chaque groupe ne contient que des membres d'une seule classe.
- **Complétude (completeness) :** chaque classe est assignée à un seul groupe
- Plusieurs mesures dans sklearn (avec leurs pour et contre)

```
>>> from sklearn import metrics
>>> labels_true = [0, 0, 0, 1, 1, 1]
>>> labels_pred = [0, 0, 1, 1, 2, 2]
>>> metrics.rand_score(labels_true, labels_pred)
0.66...
>>> labels_pred = [1, 1, 0, 0, 3, 3]
>>> metrics.rand_score(labels_true, labels_pred)
0.66...
```

Évaluation non supervisée

- Même idée, mais avec des distances au lieu des étiquettes
  - Minimiser la distance intra-groupe (**maximiser la cohésion intra-groupe**)
  - Maximiser la distance inter-groupes (**maximiser la séparation inter-groupes**)



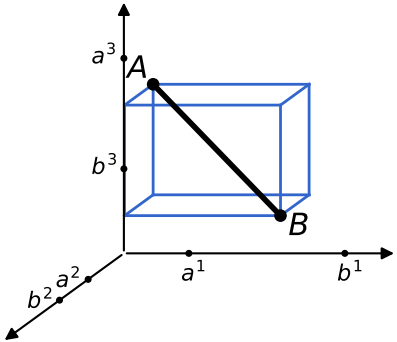
Distance euclidienne

En général, dans $\mathbb{R}^d$:

$$D(A,B) = \sqrt{\sum_{j=1}^{d} (a^j - b^j)^2}$$

Notation habituelle :

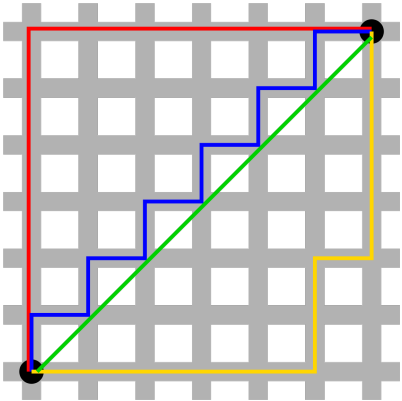
$$D(A,B) = \|a - b\|_2$$



Distance de Manhattan

- **Distance euclidienne : 8,5**
- **Distance de Manhattan : 12,0**
- **Distance de Manhattan : 12,0**
- **Distance de Manhattan : 12,0**

$$d_1(\mathbf{p}, \mathbf{q}) = \|\mathbf{p} - \mathbf{q}\|_1 = \sum_{j=1}^{n} |p^j - q^j|$$



Distance de Hamming

- Pour des séquences (symboles, bits) de **même longueur.**
- Distance de Hamming : **nombre de caractères à modifier** de X à Y :

$$H(x, y) = |\{j : x^j \neq y^j\}|$$

- Exemple :

```
x = intelligence
y = ixteuligncee
```

$$H(x, y) = 5$$

Distance de Hamming

a	b	$d_H(a, b)$	`len(a)`
`"0000"`	`"1111"`	4	4
`"1101"`	`"1111"`	1	4
`"2173896"`	`"2233796"`	3	7
`"hydroxychloroquine"`	`"idroxichloroquinne"`	16	18

Distance de Levenshtein

- Pour des séquences (symboles, bits) de **longueurs différentes.**
- **Nombre de caractères à modifier, ajouter ou retirer** de X à Y :
  - Remplacer : $x^j \rightarrow a$
  - Ajouter : $x^j \rightarrow x^j \cdot a$
  - Retirer : $x^{j-1} \cdot x^j \cdot x^{j+1} \rightarrow x^{j-1} \cdot x^{j+1}$
- Exemple :

```
x = intelligence
y = ixteulignceee
```

$$E(x, y) = 5$$

Distance de Levenshtein

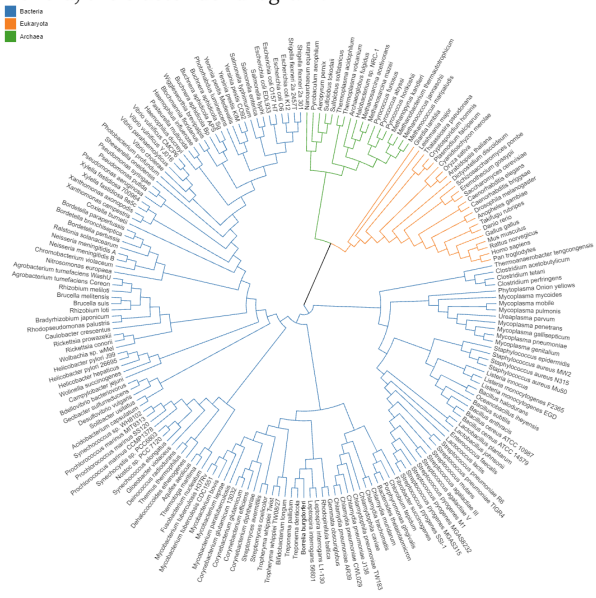
a	b	$d_L(a,b)$	$d_H(a,b)$	`len(a)`
`"0000"`	`"1111"`	4	4	4
`"1101"`	`"1111"`	1	1	4
`"2173896"`	`"2233796"`	3	3	7
`"hydroxychloroquine"`	`"idroxichloroquinne"`	4	16	18

Regroupement hiérarchique

- K contrôle le « grossissement » auquel le regroupement est fait.
- Et si le regroupement pouvait se faire à plusieurs échelles, en même temps ?
- Une hiérarchie de groupes définie par un arbre.

Regroupement hiérarchique

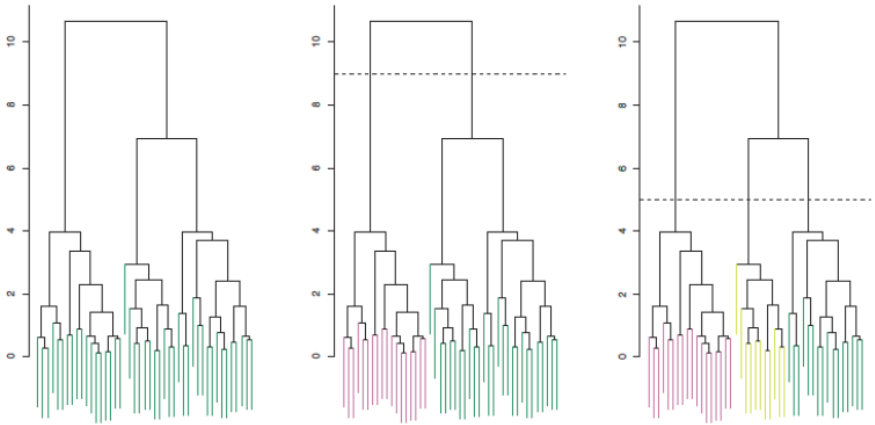
Lien



Interprétation

- Les exemples qui se ressemblent sont placés dans le même sous-arbre.
- Les paires d'exemples très semblables
  partagent des ancêtres communs très récents.
- Attention: des exemples peuvent être voisins dans les feuilles sans être proches au sens du sous-arbre.
- Pour un regroupement standard : « couper » l'arbre à un niveau horizontal

Interprétation : couper l'arbre



Très bien, mais comment construire ces arbres ?

- Ces arbres sont informatifs. Il faut une procédure automatique pour les créer.
  - **Agglomératif (agglomerative) :** ascendant
  - **Divisif (divisive) :** descendant
- Agglomératif :
  1. **Initialiser :** associer chaque point à un groupe
  2. **Répéter jusqu'à un seul groupe :** regarder toutes les paires de groupes. Fusionner la paire la plus semblable.



Très bien, mais comment construire ces arbres ?

- Ces arbres sont informatifs. Il faut une procédure automatique pour les créer.
  - **Agglomératif :** ascendant
  - **Divisif :** descendant
- Agglomératif :
  1. **Initialiser :** associer chaque point à un groupe
  2. **Répéter jusqu'à un seul groupe :** regarder toutes les paires de groupes. Fusionner la paire la plus semblable.



Très bien, mais comment construire ces arbres ?

- Ces arbres sont informatifs. Il faut une procédure automatique pour les créer.
  - **Agglomératif :** ascendant
  - **Divisif :** descendant
- Agglomératif :
  1. **Initialiser :** associer chaque point à un groupe
  2. **Répéter jusqu'à un seul groupe :** regarder toutes les paires de groupes. Fusionner la paire la plus semblable.



Très bien, mais comment construire ces arbres ?

- Ces arbres sont informatifs. Il faut une procédure automatique pour les créer.
  - **Agglomératif :** ascendant
  - **Divisif :** descendant
- Agglomératif :
  1. **Initialiser :** associer chaque point à un groupe
  2. **Répéter jusqu'à un seul groupe :** regarder toutes les paires de groupes. Fusionner la paire la plus semblable.



Très bien, mais comment construire ces arbres ?

- Ces arbres sont informatifs. Il faut une procédure automatique pour les créer.
  - **Agglomératif :** ascendant
  - **Divisif :** descendant
- Agglomératif :
  1. **Initialiser :** associer chaque point à un groupe
  2. **Répéter jusqu'à un seul groupe :** regarder toutes les paires de groupes. Fusionner la paire la plus semblable.



Très bien, mais comment construire ces arbres ?

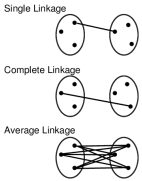
- Ces arbres sont informatifs. Il faut une procédure automatique pour les créer.
  - **Agglomératif :** ascendant
  - **Divisif :** descendant
- Agglomératif :
  1. **Initialiser :** associer chaque point à un groupe
  2. **Répéter jusqu'à un seul groupe :** regarder toutes les paires de groupes. Fusionner la paire la plus semblable.





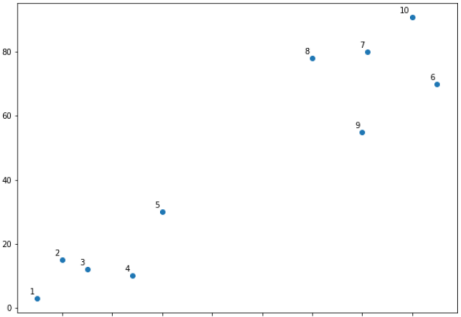
Similarité entre groupes

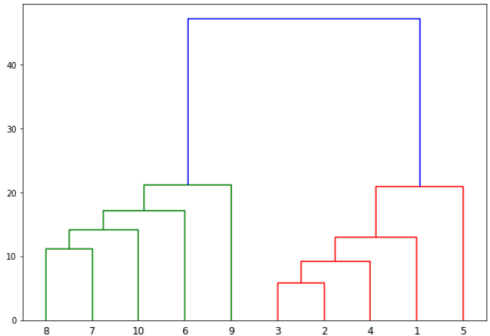
- La hauteur dans le dendrogramme (dendrogram) donne la similarité entre descendants.
- Mais quelle distance (lien, linkage) entre deux ensembles ?
  - **Simple (single) :** distance minimale entre deux points
  - **Complet (complete) :** distance maximale entre deux points
  - **Moyen (average) :** distance moyenne sur toutes les paires



Similarité entre groupes

- La distance entre les groupes à chaque itération peut être visualisée sur l'arbre
- Fusions plus basses dans l'arbre –> distance inter-groupes plus petite





Lien

Regroupement descendant

- Divisif :
  1. **Initialiser :** commencer avec un seul groupe contenant tous les points.
  2. **Répéter jusqu'à un point par groupe :** pour chaque groupe, créer K sous-groupes avec une méthode de regroupement (p. ex. les K-moyennes).

Comparaison des K-moyennes et du regroupement hiérarchique

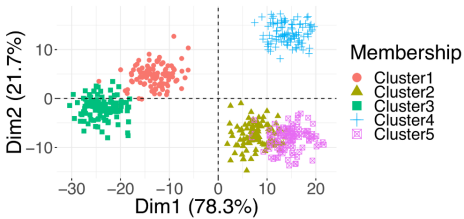
1. Les K-moyennes gèrent mieux les données massives que la méthode hiérarchique.
2. Les K-moyennes exigent de connaître K à l'avance. Avec le regroupement hiérarchique, il est possible de s'arrêter au nombre de groupes jugé approprié en interprétant le dendrogramme.
3. Les K-moyennes fonctionnent bien quand les groupes sont hypersphériques, alors que le regroupement hiérarchique fonctionne mieux pour des données non sphériques. (le regroupement hiérarchique est plus local)
4. Les résultats sont déterministes avec le regroupement hiérarchique, mais peuvent varier avec les K-moyennes selon le choix aléatoire des groupes initiaux

Conseils pratiques

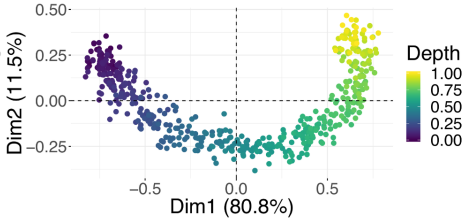
- Regroupement : méthode pour « grouper les points semblables ».
- Beaucoup d'algorithmes pour le faire :
  - Ce cours a présenté le **regroupement par K-moyennes**, mais il existe beaucoup d'autres techniques.
  - Le choix de la distance est crucial.
    - Données numériques : p. ex. euclidienne, euclidienne au carré, Manhattan, Mahalanobis, Minkowski
    - Texte ou autres données non numériques : Hamming, Levenshtein
  - Ne pas chercher une distance « parfaite ».
  - En essayer plusieurs, et évaluer la sensibilité des résultats.
  - Choisir K peut encore être délicat et mener à des résultats très différents

Conclusion : objectif de la réduction de dimension

- Compresser les données en gardant l'essentiel de l'information utile
- Quels sont les motifs latents dans les données ?
  - Changement discret des attributs : regroupement
  - Évolution graduelle des motifs : gradients



(a) Clusters



(b) Gradient

Lectures complémentaires

- Livre ISLR : chapitre 12
- Probabilistic machine learning : section V

Références utilisées pour ce cours

- Cours de Zico Kolter sur la science des données.
- https://medium.com/analytics-vidhya/mathematics-behind-principal-component-analysis-pca-1cdff0a808a9
- https://builtin.com/data-science/step-step-explanation-principal-component-analysis

Stuart Lloyd. Least squares quantization in PCM. *IEEE Transactions on Information Theory*, 28(2):129–137, 1982.

Karl Pearson. On lines and planes of closest fit to systems of points in space. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, 2(11):559–572, 1901.

Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning*, pages 8748–8763, 2021.